

Pronalaženje skrivenog znanja

Elektrotehnički fakultet Univerziteta u Beogradu

Master akademske studije

modul Računarska tehnika i informatika

2020/2021

Metoda potpornih vektora

Vuk Batanović, Elektrotehnički fakultet Univerziteta u Beogradu

Metoda potpornih vektora

- ▶ Metoda potpornih vektora (engl. *Support Vector Machines* - SVM)
- ▶ Binarni klasifikator
 - ▶ Najčešće se jedna klasa označava sa $y = +1$ a druga sa $y = -1$
- ▶ Osnovna verzija algoritma je linearni klasifikator
- ▶ Neprobabilistički klasifikator - izlaz modela je samo klasifikaciona odluka
- ▶ Pošto direktno modeluje granicu između klasa, metoda potpornih vektora spada u diskriminativne modele

Metoda potpornih vektora - istorijat

- ▶ Osnovnu varijantu metode potpornih vektora su predstavili Vladimir Vapnik i Aleksej Červonenkis 1963. godine
- ▶ 1992. godine je grupa autora (uključujući Vapnika) predložila proširenje na nelinearne slučajeve korišćenjem kernelskog trika (engl. *kernel trick*)
- ▶ Kortež i Vapnik su 1993. godine predložili, a 1995. godine objavili varijantu algoritma sa mekim marginama (engl. *soft margin*)

Izbor hiperravni razdvajanja

- ▶ Pri klasifikaciji podataka potrebno je pronaći hiperravan koja razdvaja podatke koji pripadaju različitim klasama
- ▶ Ako su podaci linearno separabilni moguće je pronaći beskonačno mnogo hiperravni koje su u stanju da izvrše razdvajanje podataka iz skupa za obučavanje
- ▶ Pitanje - po kom kriterijumu odabrati jednu od njih?
 - ▶ Logistička regresija - kriterijum je maksimalna entropija modela
 - ▶ Metoda potpornih vektora - kriterijum je maksimalna margina između klasa

Maksimalna margina razdvajanja i potporni vektori


- ▶ Ako su podaci linearno separabilni, onda je moguće zamisliti dve paralelne hiperravni takve da razdvajaju podatke različitih klasa i da se između njih ne nalazi ni jedan podatak
- ▶ Oblast prostora između ovih zamišljenih hiperravni se naziva *marginom*
- ▶ Cilj obučavanja modela u metodi potpornih vektora je da se pronađe maksimalna margina
- ▶ Obe zamišljene hiperravni efektivno naležu na jedan ili više podataka svoje klase - ti podaci su *potporni vektori* (engl. *support vectors*)
 - ▶ Potporni vektori „podupiru“ zamišljene hiperravni
 - ▶ Naziv *vektor* potiče od posmatranja svakog podatka kao vektora/tačke u n -dimenzionalnom prostoru

Maksimalna margina razdvajanja i potporni vektori

- ▶ Intuitivno gledano, hiperravan razdvajanja koja prolazi kroz sredinu praznine između podataka dveju klasa ima više smisla od one koja se nalazi blizu podataka bilo jedne bilo druge klase
- ▶ Biranjem hiperravni razdvajanja koja se nalazi najdalje od uočenih podataka efektivno se minimizuje greška generalizacije modela (tj. greška na novim podacima)
 - ▶ Pod pretpostavkom da će i novi podaci biti generisani iz iste raspodele kao i postojeći
- ▶ Ovo se razlikuje od pristupa u logističkoj regresiji gde se minimizuje empirijska greška na već raspoloživim podacima za obučavanje (tj. maksimizuju performanse modela na njima)

Maksimalna margina razdvajanja i potporni vektori

- ▶ Pri traženju hiperravni razdvajanja sa maksimalnom marginom položaj podataka koji su udaljeniji od hiperravni razdvajanja nije bitan - oni ne utiču na marginu razdvajanja podataka
- ▶ Hiperravan razdvajanja je određena malim brojem podataka obe klase koji su joj najbliži
 - ▶ Oni su najvažniji za pravilnu klasifikaciju kako postojećih tako i novih podataka
- ▶ Ovo je drugačije od logističke regresije gde hiperravan razdvajanja zavisi od položaja svih podataka



Ilustracija veličine margine razdvajanja i potpornih vektora

Slika preuzeta sa: <http://www.dtreg.com/solution/view/20>

Hipoteza metode potpornih vektora

- ▶ U metodi potpornih vektora model predstavlja jednačinu hiperravni razdvajanja
- ▶ Ako je n broj odlika koje se koriste u modelu tj. broj dimenzija prostora, onda je hipoteza oblika:

$$h(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n = W^T X + w_0$$

- ▶ Često se umesto oznake w_0 koristi oznaka b (engl. *bias term*)
- ▶ Jednačina hiperravni razdvajanja je:

$$h(x) = W^T X + w_0 = 0$$

- ▶ Vektor W je vektor normale na hiperravan razdvajanja

Skaliranje jednačine hiperravni razdvajanja

- ▶ Jednačina hiperravni razdvajanja se može pomnožiti/podeliti bilo kojim pozitivnim brojem bez promene položaja hiperravni
- ▶ Iako je faktore W i w_0 moguće proizvoljno skalirati, konvencionalno se usvaja takva kanonska vrednost da za potporne vektore $X^{(sv)}$ važi

$$y^{(sv)}(W^T X^{(sv)} + w_0) = 1$$

- ▶ To znači da jednačina hiperravni koja „naleže“ na potporne vektore iz klase $y = 1$ postaje:

$$W^T X + w_0 = 1$$

- ▶ dok je jednačina hiperravni koja „naleže“ na potporne vektore iz klase $y = -1$:

$$W^T X + w_0 = -1$$

Širina margine razdvajanja

- Udaljenost neke tačke/podatka $X^{(a)}$ od hiperravni razdvajanja Π je:


$$\text{dist}(X^{(a)}, \Pi) = \frac{|W^T X^{(a)} + w_0|}{\|W\|_2}$$

- Sledi da je udaljenost potpornih vektora $X^{(sv)}$ od hiperravni razdvajanja:

$$\text{dist}(X^{(sv)}, \Pi) = \frac{|W^T X^{(sv)} + w_0|}{\|W\|_2} = \frac{1}{\|W\|_2}$$

- Pošto se potporni vektori nalaze sa obe strane hiperravni razdvajanja, širina margine je dvostruko veća - nju treba maksimizovati:

$$\operatorname{argmax}_{W, w_0} \frac{2}{\|W\|_2}$$



Udaljenost potpornih vektora od hiperravni razdvajanja

Slika preuzeta sa: <http://jap.physiology.org/content/115/11/1714>

Cilj obučavanja u metodi potpornih vektora

- ▶ Pošto marginu treba maksimizovati, sledi da treba minimizovati $\|W\|_2$
- ▶ Pošto je

$$\|W\|_2 = \sqrt{w_1^2 + w_2^2 + \dots + w_n^2}$$

- ▶ sa stanovišta optimizacije lakše je izbeći korenu funkciju i minimizovati $\frac{1}{2} \|W\|_2^2$
 - ▶ Ovu zamenu je moguće sprovesti jer minimizovanje kvadrata norme minimizuje i samu normu
- ▶ Stoga je cilj obučavanja u metodi potpornih vektora pronaći

$$\operatorname{argmin}_{W, w_0} \frac{1}{2} \|W\|_2^2$$

Uslovi pri traženju maksimalne margine

- ▶ Prilikom pronalaženja maksimalne margine treba sprečiti da neki podatak bilo prve bilo druge klase upadne u marginu, što znači da treba da važi:

$$W^T X^{(+1)} + w_0 \geq 1$$

- ▶ gde su $X^{(+1)}$ podaci klase $y = +1$, odnosno:

$$W^T X^{(-1)} + w_0 \leq -1$$

- ▶ gde su $X^{(-1)}$ podaci klase $y = -1$

- ▶ Navedeni uslovi se mogu uprostiti na:

$$y^{(i)}(W^T X^{(i)} + w_0) \geq 1$$

Optimizacioni problem

- ▶ Optimizacioni problem ima sledeći oblik:

$$\operatorname{argmin}_{W, w_0} \frac{1}{2} \|W\|_2^2, \quad y^{(i)}(W^T X^{(i)} + w_0) \geq 1, \quad i = 1, 2, \dots, m$$

- ▶ gde je m broj podataka u skupu za obučavanje
- ▶ Ovo je problem konveksne optimizacije sa ograničenjem, tj. kvadratnog programiranja
- ▶ Do rešenja se može doći tehnikom Lagranžovih multiplikatora uz *Karush-Kuhn-Tucker*-ove (KKT) uslove
- ▶ Ovo rešenje podrazumeva kreiranje tzv. dualne reprezentacije problema u kojoj se za svaku nejednakost navedenog oblika kreira po jedan Lagranžov multiplikator α_k

Dualna formulacija hipoteze metode potpornih vektora

- ▶ U dualnoj reprezentaciji problema dobija se da je:

$$W = \sum_{i=1}^m \alpha_i y^{(i)} X^{(i)}$$

$$h(x) = W^T X + w_0 = \sum_{i=1}^m \alpha_i y^{(i)} (X^{(i)})^T X + w_0$$

- ▶ Pokazuje se da su optimalne vrednosti α_i dodeljene svakoj tački jednake nuli za sve tačke osim za potporne vektore
 - ▶ Njih obično ima mnogo manje od ukupnog broja tačaka
- ▶ Stoga vrednost hipoteze (i jednačina hiperravni razdvajanja) zavise samo od potpornih vektora

Dualna formulacija hipoteze metode potpornih vektora

- Vrednost hipoteze $h(x^{(k)})$ za neki nov podatak $x^{(k)}$ zavisi od proizvoda

$$(X^{(i)})^T X^{(k)} = X^{(i)} \cdot X^{(k)}$$

- tj. od sličnosti potpornih vektora $X^{(i)}$ sa vektorom novog podatka $X^{(k)}$
- Klasifikovanje podatka predstavlja proveru sa koje strane hiperravni razdvajanja se on nalazi:

$$\hat{y} = \text{sign}(h(x))$$

Meka margina

- ▶ Insistiranje na linearnoj separabilnosti klasa, čak i ako je ona moguća, može da dovede do preterane prilagođenosti modela podacima
 - ▶ Pravi probleme u slučaju prisustva *outlier*-a - pronađeno rešenje će imati malu marginu tj. slabu generalizaciju na nove podatke
- ▶ Umesto toga, bolje je (u ograničenoj meri) dozvoliti ulaske podataka u marginu ili njihov prelazak na pogrešnu stranu hiperravni razdvajanja
- ▶ Margina u kojoj je ovo dozvoljeno se naziva mekom marginom (engl. *soft margin*)


Meka margina

- ▶ Korišćenje meke margine dovodi do reformulacije optimizacionog problema:

$$\operatorname{argmin}_{W, w_0} \frac{1}{2} \|W\|_2^2, \quad y^{(i)}(W^T X^{(i)} + w_0) \geq 1 - \xi_i, \quad \xi_i \geq 0, \\ i = 1, 2, \dots, m$$

- ▶ gde su ξ_i prekoračenja u položaju svake tačke izvan granice njene klase (engl. *slack variables*)
- ▶ Ukoliko je
 - ▶ $\xi_i = 0$ - podatak je pravilno klasifikovan i izvan margine
 - ▶ $1 \geq \xi_i > 0$ - podatak je pravilno klasifikovan ali unutar margine
 - ▶ $\xi_i > 1$ - podatak nije pravilno klasifikovan - nalazi se sa suprotne strane hiperravni razdvajanja u odnosu na njegovu klasu

$$K(x_i, x_j) = \phi^t(x_i)\phi(x_j)$$



Ilustracija meke margine u metodi potpornih vektora

Slika preuzeta sa: <http://steve-cronin.blogspot.rs/2010/09/modern-analytics-look-at-smo.html>

Funkcija gubitka kod SVM-a sa mekom marginom

- ▶ Svaki podatak koji uđe u marginu ili pređe na pogrešnu stranu hiperravni razdvajanja treba penalizovati proporcionalno njegovoj udaljenosti od ivice margine na strani klase kojoj pripada
- ▶ Funkcija gubitka može imati dva oblika

- ▶ L_1 oblik funkcije gubitka:

$$L(h(x), y) = \xi$$

- ▶ L_2 oblik funkcije gubitka:

$$L(h(x), y) = \xi^2$$

Gubitak u obliku šarke

- ▶ Funkcija gubitka SVM-a sa mekom marginom se naziva i gubitkom u obliku šarke (engl. *hinge loss*)
- ▶ Uslov meke margine za jedan podatak se može preformulisati kao:

$$y(W^T X + w_0) \geq 1 - \xi$$

$$yh(x) \geq 1 - \xi$$

$$\xi \geq 1 - yh(x)$$

- ▶ Ako se uzme u obzir i uslov da je $\xi \geq 0$, sledi:

$$\xi = \max(0, 1 - yh(x))$$

- ▶ Ako se usvoji da je $z = y(W^T X + w_0)$, onda je gubitak u obliku šarke:

$$\xi = \max(0, 1 - z)$$

Reformulacija logističke funkcije gubitka za $y \in \{-1, 1\}$

- Logistička funkcija gubitka ima sledeći oblik za $y \in \{0, 1\}$:

$$L(h(x), y) = -\ln(P(y|x)) = \begin{cases} -\ln(P(y = 1|x)) = -\ln(h(x)), & y = 1 \\ -\ln(P(y = 0|x)) = -\ln(1 - h(x)), & y = 0 \end{cases}$$

- Ako se koriste oznake $y \in \{-1, 1\}$ za klase, onda važi:

$$P(y = 1|x) = \frac{1}{1 + e^{-(W^T X + w_0)}}$$

$$P(y = -1|x) = \frac{1}{1 + e^{W^T X + w_0}}$$

$$P(y|x) = \frac{1}{1 + e^{-y(W^T X + w_0)}}$$

Reformulacija logističke funkcije gubitka za $y \in \{-1, 1\}$

- Sledi da je za $y \in \{-1, 1\}$:

$$-\ln(P(y|x)) = -\ln \frac{1}{1 + e^{-y(W^T X + w_0)}} = \ln(1 + e^{-y(W^T X + w_0)})$$


- Logistička funkcija gubitka za $y \in \{-1, 1\}$ se obično skalira sa $\frac{1}{\ln 2}$:

$$L(h(x), y) = \frac{1}{\ln 2} \ln(1 + e^{-y(W^T X + w_0)})$$

- Razlog za skaliranje - ako se usvoji da je $z = y(W^T X + w_0)$, onda logistička funkcija gubitka

$$L(z) = \frac{1}{\ln 2} \ln(1 + e^{-z})$$

- prolazi kroz tačku (0,1)



Poređenje oblika različitih funkcija gubitka

Legenda: 0-1 gubitak (crna), gubitak u obliku šarke (plava), logistička funkcija gubitka (crvena), kvadratna funkcija gubitka (zelena)

Slika preuzeta iz: Christopher Bishop, Pattern Recognition and Machine Learning

Funkcija greške kod SVM-a sa mekom marginom

- ▶ U metodi potpornih vektora sa mekom marginom postoje dva različita (i ponekad suprotstavljena) cilja optimizacije
 - ▶ Maksimizacija margine
 - ▶ Minimizacija greške klasifikacije na pojedinačnim primerima tj. gubitka u obliku šarke

- ▶ Funkcija greške kod SVM-a sa mekom marginom ima oblik:

$$J(w) = C \sum_{i=1}^m L(h(x^{(i)}), y^{(i)}) + \frac{1}{2} \sum_{j=1}^n w_j^2$$

- ▶ C je hiperparametar modela koji određuje balans između dva cilja optimizacije
- ▶ Cilj obučavanja je minimizacija funkcije greške $J(w)$

Funkcija greške kod SVM-a sa mekom marginom

- Ukoliko se koristi L_1 oblik funkcije gubitka, onda je funkcija greške:

$$\begin{aligned} J(w) &= C \sum_{i=1}^m \xi_i + \frac{1}{2} \sum_{j=1}^n w_j^2 \\ &= C \sum_{i=1}^m \max(0, 1 - y^{(i)} h(x^{(i)})) + \frac{1}{2} \sum_{j=1}^n w_j^2 \end{aligned}$$

- Ukoliko se koristi L_2 oblik funkcije gubitka, onda je funkcija greške:

$$\begin{aligned} J(w) &= C \sum_{i=1}^m \xi_i^2 + \frac{1}{2} \sum_{j=1}^n w_j^2 \\ &= C \sum_{i=1}^m \left(\max(0, 1 - y^{(i)} h(x^{(i)})) \right)^2 + \frac{1}{2} \sum_{j=1}^n w_j^2 \end{aligned}$$

Funkcija greške kod SVM-a sa mekom marginom

- ▶ L_2 oblik funkcije gubitka
 - ▶ Rešenje je stabilnije (male promene u podacima za obučavanje manje utiču na rešenje)
 - ▶ Manja otpornost na uticaj *outlier*-a
- ▶ L_1 oblik funkcije gubitka
 - ▶ Rešenje je manje stabilno (male promene u podacima za obučavanje više utiču na izgled rešenja)
 - ▶ Veća otpornost na uticaj *outlier*-a


Regularizacija kod SVM sa mekom marginom

- ▶ Veća margina povećava generalizaciju modela - minimizovanje norme vektora W predstavlja regularizaciju modela
- ▶ Moguće je koristiti L_1 ili L_2 regularizaciju
 - ▶ U L_2 regularizaciji se minimizuje do sada korišćen izraz $\frac{1}{2} \|W\|_2^2$
 - ▶ U L_1 regularizaciji se minimizuje vrednost $\|W\|_1$
 - ▶ Sve ranije prikazane razlike između ova dva tipa regularizacije važe i kod metode potpornih vektora

Hiperparametar C

- ▶ Velika vrednost C - model se pri obučavanju fokusira na smanjivanje greške klasifikacije, po cenu manje margine razdvajanja, čime se smanjuje stepen regularizacije
- ▶ Mala vrednost C - model se pri obučavanju fokusira na povećanje margine razdvajanja, čime se povećava stepen regularizacije, po cenu veće greške klasifikacije
- ▶ Po svojoj funkciji hiperparametar C je inverzan hiperparametru λ koji određuje jačinu regularizacije u linearnoj i logističkoj regresiji:

$$C = \frac{1}{\lambda}$$




Ilustracija efekta vrednosti hiperparametra C na odabir optimalne hiperravni razdvajanja

Slika preuzeta iz: Sebastian Raschka, Python Machine Learning

Nelinearna klasifikacija

- ▶ Metod potpornih vektora se može lako proširiti tako da je u stanju da se nosi i sa klasama podataka koje nisu linearno separabilne
- ▶ To se ostvaruje preslikavanjem problema u veći broj dimenzija
 - ▶ Ako podaci nisu linearno separabilni u zadatom broju dimenzija, moguće ih je preslikati u prostor sa većim brojem dimenzija u kome će biti moguće linearno ih razdvojiti
 - ▶ Linearna granica razdvajanja u prostoru sa više dimenzija, nakon preslikavanja nazad u originalni broj dimenzija, može da bude ekvivalentna sa nelinearnom granicom proizvoljnog oblika
 - ▶ Problem - transformacija svih podataka u prostor sa većim brojem dimenzija je računski izuzetno zahtevna operacija



Linearna separacija podataka kroz projekciju u veći broj dimenzija

Slika preuzeta sa: http://www.eric-kim.net/eric-kim-net/posts/1/kernel_trick.html

Kernel funkcije

- ▶ Hipoteza metode potpornih vektora je sledećeg oblika (u dualnom domenu) za neki podatak $x^{(k)}$:

$$h(x^{(k)}) = \sum_{i=1}^m \alpha_i y^{(i)} (X^{(i)})^T X^{(k)} + w_0 = \sum_{i=1}^m \alpha_i y^{(i)} X^{(i)} \cdot X^{(k)} + w_0$$

- ▶ Potrebna je vrednost skalarnih proizvoda vektora tj. mera njihove sličnosti

Kernel funkcije

- ▶ Postoje funkcije koje za zadate vektore $X, Z \in \mathbb{R}^n$ implicitno računaju njihov skalarni proizvod u nekom prostoru sa više dimenzija $\mathbb{R}^q$
- ▶ To računanje se ostvaruje *bez* eksplicitnog transformisanja vektora X i Z u prostor $\mathbb{R}^q$
- ▶ Takve funkcije se nazivaju *kernel funkcijama*

$$K(X, Z) = \phi(X) \cdot \phi(Z)$$

- ▶ Korišćenjem kernel funkcija skup podataka se implicitno prebacuje u višedimenzioni prostor

$$\mathbb{R}^n \longrightarrow \mathbb{R}^q, \quad q > n$$

- ▶ Pri tome se ne troši nikakva dodatna računarska memorija a cena računanja se svodi na računanje $K(X, Z)$ - kernelski trik (engl. *kernel trick*)

Kernel funkcije

- ▶ Ovo omogućava da SVM efikasno nauči nelinearne granice razdvajanja zamenom skalarnih proizvoda vektora odabranom kernel funkcijom:

$$\begin{aligned} h(x^{(k)}) &= \sum_{i=1}^m \alpha_i y^{(i)} \phi(X^{(i)}) \cdot \phi(X^{(k)}) + w_0 \\ &= \sum_{i=1}^m \alpha_i y^{(i)} K(X^{(i)}, X^{(k)}) + w_0 \end{aligned}$$

- ▶ Kernel funkcija $K(X^{(i)}, X^{(k)})$ se sada koristi kao mera sličnosti vektora

Kernel funkcije

- ▶ Ono što se eksplicitno bira je kernel funkcija K , a ne funkcija preslikavanja ϕ
 - ▶ Funkcija preslikavanja ϕ je implicitno definisana odabirom kernel funkcije K
 - ▶ Eksplicitne reprezentacije podataka u višedimenzionalnom prostoru - $\phi(X)$ - se ne konstruišu
- ▶ Kernel funkcija mora da ispunjava uslove da bi mogla da se koristi kao mera sličnosti vektora:
 - ▶ $K(X, X) = 1$
 - ▶ $0 \leq K(X, Z) \leq 1$
 - ▶ $K(X, Z) = K(Z, X)$

Neki često korišćeni tipovi kernel funkcija

- ▶ Linearni kernel - $K(X, Z) = X \cdot Z$
- ▶ Polinomijalni kerneli
- ▶ Kerneli sa radijalnom osnovom
- ▶ Kerneli za strukturirane podatke
 - ▶ String kerneli
 - ▶ Kerneli stabla
 - ▶ Grafovski kerneli

Polinomijalni kerneli

- ▶ Imaju oblik:

$$K(X, Z) = (c + \gamma X \cdot Z)^d$$

- ▶ Za $d = 1$, $c = 0$, $\gamma = 1$ dobija se već prikazan model bez kernela tj. linearni kernel
- ▶ Često se koristi i kvadratni kernel koji se dobija za $d = 2$
- ▶ Polinomijalni kerneli omogućavaju modeliranje kombinacija odlika, sve do stepena polinoma

Polinomijalni kerneli

- Primer - funkcija preslikavanja ϕ polinomijalnog kernela za $n = 2$, $d = 2$, $c = 0$, $\gamma = 1$:

$$\begin{aligned} K(X, Z) &= (X \cdot Z)^2 = ((x_1, x_2) \cdot (z_1, z_2))^2 = (x_1 z_1 + x_2 z_2)^2 \\ &= x_1^2 z_1^2 + 2x_1 z_1 x_2 z_2 + x_2^2 z_2^2 \\ &= (x_1^2, \sqrt{2}x_1 x_2, x_2^2) \cdot (z_1^2, \sqrt{2}z_1 z_2, z_2^2) \\ &= \phi(X) \cdot \phi(Z) \end{aligned}$$

- Sledi da je za navedene vrednosti parametara funkcija preslikavanja polinomijalnog kernela:

$$\phi(X) = (x_1^2, \sqrt{2}x_1 x_2, x_2^2)$$

Kerneli sa radijalnom osnovom

- ▶ Kerneli sa radijalnom osnovom (engl. *radial basis function kernels* - *RBF kernels*) imaju oblik:

$$K(X, Z) = \phi(\|X - Z\|_2)$$


- ▶ Najčešće korišćena varijanta kernel funkcije sa radijalnom osnovom je Gausova, u obliku:

$$K(X, Z) = e^{-\frac{\|X-Z\|_2^2}{2\sigma^2}} = e^{-\gamma\|X-Z\|_2^2}$$

- ▶ gde je $\gamma = \frac{1}{2\sigma^2}$ preciznost, a σ^2 širina Gausove krive (engl. *bandwidth*)
- ▶ Kernel funkcije sa radijalnom osnovom su ekvivalentne mapiranju u prostor sa beskonačno mnogo dimenzija


Gausov RBF kernel

- ▶ Parametar γ kod Gausovog RBF kernela ima veliki uticaj na ponašanje modela
- ▶ γ je inverzno širini Gausove krive
 - ▶ Jako mala vrednost γ znači da je Gausova kriva izuzetno široka i da svaki potporni vektor X (donekle) ima efekat na klasifikaciju svih podataka
 - ▶ Izlaz hipoteze se menja vrlo polako sa promenom vrednosti ulaza - veliko sistematsko odstupanje (engl. *bias*) modela tj. nedovoljna prilagođenost modela podacima
 - ▶ Jako velika vrednost γ znači da je Gausova kriva izuzetno uska i da svaki potporni vektor X ima efekat na klasifikaciju samo onih podataka koji se nalaze u njegovoj neposrednoj blizini
 - ▶ Izlaz hipoteze se menja izuzetno brzo sa promenom vrednosti ulaza - velika varijansa modela tj. preterana prilagođenost modela podacima




Ilustracija različitih vrednosti hiperparametra γ kod Gausovog RBF kernela

Slika preuzeta sa: <http://amueller.github.io/aml/02-supervised-learning/07-support-vector-machines.html>




Ilustracija ponašanja različitih SVM kernela - raspodela podataka

Slika preuzeta sa: http://chrisalbon.com/machine_learning/support_vector_machines/svc_parameters_using_rbf_kernel/




Ilustracija ponašanja različitih SVM kernela - linearni kernel (tj. SVM bez kernela), $C = 1$

Slika preuzeta sa: http://chrisalbon.com/machine_learning/support_vector_machines/svc_parameters_using_rbf_kernel/




Ilustracija ponašanja različitih SVM kernela - Gausov RBF
kernel, $\gamma = 0.01$, $C = 1$

Slika preuzeta sa: http://chrisalbon.com/machine_learning/support_vector_machines/svc_parameters_using_rbf_kernel/




Ilustracija ponašanja različitih SVM kernela - Gausov RBF kernel, $\gamma = 1$, $C = 1$

Slika preuzeta sa: http://chrisalbon.com/machine_learning/support_vector_machines/svc_parameters_using_rbf_kernel/




Ilustracija ponašanja različitih SVM kernela - Gausov RBF kernel, $\gamma = 10$, $C = 1$

Slika preuzeta sa: http://chrisalbon.com/machine_learning/support_vector_machines/svc_parameters_using_rbf_kernel/




Ilustracija ponašanja različitih SVM kernela - Gausov RBF
kernel, $\gamma = 100$, $C = 1$

Slika preuzeta sa: http://chrisalbon.com/machine_learning/support_vector_machines/svc_parameters_using_rbf_kernel/




Ilustracija ponašanja različitih SVM kernela - Gausov RBF kernel, $\gamma = 0.01$, $C = 10$

Slika preuzeta sa: http://chrisalbon.com/machine_learning/support_vector_machines/svc_parameters_using_rbf_kernel/




Ilustracija ponašanja različitih SVM kernela - Gausov RBF kernel, $\gamma = 0.01$, $C = 1000$

Slika preuzeta sa: http://chrisalbon.com/machine_learning/support_vector_machines/svc_parameters_using_rbf_kernel/



Ilustracija ponašanja različitih SVM kernela - Gausov RBF kernel, $\gamma = 0.01$, $C = 100000$

Slika preuzeta sa: http://chrisalbon.com/machine_learning/support_vector_machines/svc_parameters_using_rbf_kernel/



Ilustracija povezanosti efekata hiperparametara γ i C kod Gausovog RBF kernela

Slika preuzeta sa: <http://amueller.github.io/aml/02-supervised-learning/07-support-vector-machines.html>

Video prikazi delovanja različitih kernela

- ▶ Polinomijalni kernel
 - ▶ <http://www.youtube.com/watch?v=3liCbRZPrZA>
 - ▶ <http://www.youtube.com/watch?v=ndNE8he7Nnk>
- ▶ Gausov RBF kernel
 - ▶ <http://www.youtube.com/watch?v=9NrALgHFwTo>
 - ▶ <http://www.youtube.com/watch?v=RtajnP3tGsc>

Odabir kernela

- ▶ Odabiranje najpogodnijeg kernela zavisi od konkretnog zadatka i može da bude netrivialno
- ▶ Bez obzira koji kernel je odabran, njegovi parametri su hiperparametri modela
 - ▶ I izbor kernela može da se tretira kao hiperparametar
- ▶ Vrednosti hiperparametara je neophodno optimizovati da bi se dobile dobre performanse klasifikacije
 - ▶ To se čini putem (ugneždene) unakrsne validacije
 - ▶ Vrednosti različitih hiperparametara mogu da interaguju, tako da je potrebno pretraživanje po mreži (engl. *grid search*)

SVM optimizacija u primalnom domenu

- ▶ Funkciju greške je moguće minimizovati i u primalnom domenu, bez korišćenja Lagranžovih multiplikatora i prelaska u dualni domen
- ▶ Dualni pristup može biti spor kada je količina podataka u skupu za obučavanje jako velika, pošto je tada obično i broj potpornih vektora veliki
- ▶ Ograničenje u primalnom domenu - nepostojanje kernela
 - ▶ Moguće je rešavanje samo za linearni SVM
- ▶ Primenuju se naprednije tehnike numeričke optimizacije, kao što je subgradijentni spust
 - ▶ Često se traži aproksimacija optimalnog rešenja, a ne tačno rešenje
- ▶ Kada je broj odlika znatno veći od broja podataka u skupu za obučavanje može biti preporučljivije da se optimizacija radi u dualnom domenu

Višeklasna klasifikacija

- ▶ Metoda potpornih vektora se može primeniti i u slučaju prisustva većeg broja klasa, i to kombinovanjem rezultata većeg broja nezavisnih binarnih klasifikacija
 - ▶ Princip „jedan nasuprot svima“ (engl. *one-versus-all*) / „jedan nasuprot ostalima“ (engl. *one-versus-rest*)
 - ▶ Podatak se svrstava u onu klasu čiji binarni klasifikator klasifikuje dati podatak u tu klasu sa najvećom udaljenošću između njegove hiperravni razdvajanja i podatka (umesto najveće verovatnoće pripadanja određenoj klasi u slučaju logističke regresije)
 - ▶ Princip „jedan nasuprot jednom“ (engl. *one-versus-one*)
- ▶ Postoje i pristupi koji istovremeno modeluju prisustvo više klasa
 - ▶ Crammer & Singer algoritam

Prednosti i mane metode potpornih vektora

► Prednosti

- Veoma dobre performanse na širokom spektru problema
- Metoda sama odabira koji podaci su potporni vektori i koliko ih ima
- Manja sklonost *overfitting*-u od mnogih drugih metoda
- Interakcije odlika se mogu implicitno modelovati preko kernela

► Mane

- SVM može da bude primetno sporiji od drugih metoda, u zavisnosti od broja odlika i količine podataka u skupu za obučavanje
 - Korišćenje kernela dodatno usporava rad algoritma
- Izlaz nije probabilističkog tipa
 - Moguća probabilistička procena preko udaljenosti od hiperravni razdvajanja
- Varijanta sa čvrstom marginom je osetljiva na *outlier*-e