

Pronalaženje skrivenog znanja

Elektrotehnički fakultet Univerziteta u Beogradu

Master akademske studije

modul Računarska tehnika i informatika

2021/2022

Naivni Bajesov klasifikator

Vuk Batanović, Elektrotehnički fakultet Univerziteta u Beogradu

Thomas Bayes (1701 - 1761)

- ▶ Engleski statističar i filozof
- ▶ Autor teoreme o verovatnoći:

$$P(A|B) = \frac{P(A, B)}{P(B)} = \frac{P(B|A)P(A)}{P(B)}$$



Primena Bajesove teoreme u klasifikaciji

$$P(y|x) = \frac{P(y, x)}{P(x)} = \frac{P(x|y)P(y)}{P(x)}$$

- ▶ y je klasa, x je podatak
- ▶ $P(y)$ - prethodna/apriorna verovatnoća klase (engl. *prior probability*)
- ▶ $P(y|x)$ - aposteriorna verovatnoća klase (engl. *posterior probability*)
- ▶ $P(y, x)$ - zajednička verovatnoća klase i podatka (engl. *joint probability*)
- ▶ $P(x|y)$ - funkcija izvesnosti (engl. *likelihood function*)

Primena Bajesove teoreme u klasifikaciji

$$P(y|x) = \frac{P(y, x)}{P(x)} = \frac{P(x|y)P(y)}{P(x)}$$

- ▶ Klasifikaciona odluka - podatak svrstati u onu klasu koja je za njega najverovatnija tj. ima najveću aposteriornu verovatnoću
- ▶ Ovakvo odlučivanje se naziva *Maximum a posteriori* - MAP

$$\begin{aligned} y_{MAP} &= \operatorname{argmax}_y P(y|x) \\ &= \operatorname{argmax}_y \frac{P(x|y)P(y)}{P(x)} \\ &= \operatorname{argmax}_y P(x|y)P(y) \end{aligned}$$

Primena Bajesove teoreme u klasifikaciji

- ▶ Da bi se izvršila klasifikacija potrebni su $P(y)$ i $P(x|y)$
- ▶ $P(y)$ - zastupljenost klase y u skupu podataka za obučavanje:

$$P(y) = \frac{\text{Count}(y)}{\text{Count}(x)}$$

- ▶ Podatak x se predstavlja pomoću nekih njegovih odlika, kojih ima n :

$$P(x|y) = P(x_1, x_2, x_3, \dots, x_n|y)$$

- ▶ Koristeći pravilo ulančavanja uslovnih verovatnoća sledi:

$$\begin{aligned} P(x_1, x_2, x_3, \dots, x_n|y) &= P(x_1|y)P(x_2, x_3, \dots, x_n|y, x_1) \\ &= P(x_1|y)P(x_2|y, x_1)P(x_3, \dots, x_n|y, x_1, x_2) \\ &= P(x_1|y)P(x_2|y, x_1) \cdots P(x_n|y, x_1, x_2, \dots, x_{n-1}) \end{aligned}$$

Naivna pretpostavka o statističkoj nezavisnosti odlika

- ▶ Pretpostavka: odlike koje se koriste pri odlučivanju nisu statistički zavisne jedna od druge - poznavanje vrednosti jedne odlike ništa ne govori o vrednosti neke druge
- ▶ Ako je tako, onda važi:

$$\begin{aligned}P(x|y) &= P(x_1, x_2, x_3, \dots, x_n|y) \\&= P(x_1|y)P(x_2|y) \cdots P(x_n|y) \\&= \prod_{i=1}^n P(x_i|y)\end{aligned}$$

- ▶ Time uslovna verovatnoća svake odlike zavisi samo od klase podatka
- ▶ Raspodela te verovatnoće - multinomijalna, Bernulijeva, Gausova,...

“

Essentially, all models are wrong,
but some are useful.

”

britanski statističar George Box

- ▶ Iako je praktično uvek pogrešna, pretpostavka o međusobnoj statističkoj nezavisnosti odlika znatno olakšava modeliranje
- ▶ U praksi, naivni Bajesovi modeli često ostvaruju dobre rezultate - za pravilnu klasifikaciju nije neophodno poznavanje tačnih vrednosti $P(y|x)$ za sve y , već samo njihovog međusobnog redosleda

Formula za određivanje pripadnosti klasi

$$y_{MAP} = \operatorname{argmax}_y P(x|y)P(y)$$

$$= \operatorname{argmax}_y P(y) \prod_{i=1}^n P(x_i|y)$$

- ▶ Broj odlika je često veoma veliki, a verovatnoće su u opsegu [0,1]
- ▶ Da bi se izbegao *floating point underflow* umesto množenja verovatnoća vrši se sabiranje njihovih logaritama:

$$y_{MAP} = \operatorname{argmax}_y \left(\log P(y) + \sum_{i=1}^n \log P(x_i|y) \right)$$

Raspodele uslovnih verovatnoća odlika

- ▶ Različite raspodele $P(x_t|y)$ su pogodne za različite tipove vrednosti odlika x_t
- ▶ Multinomijalna raspodela
 - ▶ Pogodna za odlike sa vrednostima koje predstavljaju broj javljanja nečega
- ▶ Bernulijeva raspodela
 - ▶ Pogodna za odlike sa binarnim/indikatorskim vrednostima
- ▶ Gausova raspodela
 - ▶ Pogodna za odlike sa kontinualnim numeričkim vrednostima

Multinomijalni naivni Bajesov klasifikator

- ▶ Engl. *Multinomial Naïve Bayes*
- ▶ Pogodan kada vrednosti odlika predstavljaju broj javljanja nečega
- ▶ Verovatnoća $P(x_t|y)$ - odnos između zbirne vrednosti odlike x_t u podacima klase y i zbirne vrednosti svih odlika u podacima te klase:

$$P(x_t|y) = \frac{\text{Count}(x_t, y)}{\sum_{i=1}^n \text{Count}(x_i, y)}$$

- ▶ Ovakav metod određivanja verovatnoća $P(x_t|y)$ se naziva metod najveće izvesnosti (engl. *Maximum Likelihood Estimation - MLE*) jer se njime maksimizuje uslovna verovatnoća/funkcija izvesnosti podataka nad kojima se model obučava

Metod najveće izvesnosti

- ▶ Šta se dešava kada se odlika x_t nikad ne javlja u podacima klase y u skupu za obučavanje ?
 - ▶ $P(x_t|y) = 0$
 - ▶ Model odbacuje klasu y na osnovu samo jedne odlike
- ▶ Ovakvo rezonovanje je problematično jer odsustvo odlike x_t u podacima klase y iz skupa za obučavanje može da bude slučajno
 - ▶ Naročito ako je broj odlika veliki, a skup za obučavanje mali - problem proređenosti podataka (engl. *data sparsity*)
 - ▶ Preterana prilagođenost modela (engl. *overfitting*)
- ▶ Korekcija - umesto $P(x_t|y) = 0$ staviti da je $P(x_t|y)$ jednako nekoj maloj nenuljoj vrednosti

Laplasovo poravnanje

- ▶ Laplasovo poravnanje (engl. *Laplace smoothing*) ili aditivno poravnanje - brojanje zbirne vrednosti odlika u svakoj klasi ne počinje od nule već od neke predefinisane vrednosti α
 - ▶ Obično se uzima $\alpha = 1$
- ▶ Verovatnoća $P(x_t|y)$ se stoga računa kao:

$$P(x_t|y) = \frac{\text{Count}(x_t, y) + 1}{\sum_{i=1}^n (\text{Count}(x_i, y) + 1)} = \frac{\text{Count}(x_t, y) + 1}{n + \sum_{i=1}^n \text{Count}(x_i, y)}$$

- ▶ Laplasovo poravnanje se može smatrati oblikom regularizacije modela
- ▶ Deo verovatnoća javljanja odlika viđenih u klasi y u skupu za obučavanje se preraspodeljuje na odlike koje u toj klasi nisu (još uvek) opažene

Poziciona nezavisnost odlika

- ▶ Multinomijalni naivni Bajesov model implicitno pretpostavlja da ne postoji zavisnost između uslovne verovatnoće odlika i njihove pozicije u podacima
 - ▶ Primer: raspored reči u tekstu pri klasifikaciji dokumenata
- ▶ Ukoliko su podaci tako strukturirani da postoji redosled između odlika koje se razmatraju, taj redosled se u modelu ignoriše
 - ▶ U modeliranju tekstualnih podataka ovaj pristup je poznat kao vreća reči (engl. *bag-of-words*), pri čemu su individualne reči odlike koje se uzimaju u obzir
- ▶ Ovakva pretpostavka omogućava da se broj parametara modela drastično smanji

Multinomijalni naivni Bajesov klasifikator

- ▶ $Count(x_t, y)$ govori o zbirnoj vrednosti odlike x_t u podacima klase y
- ▶ Ponekad se odlike binarizuju - tada $Count(x_t, y)$ govori u koliko podataka klase y se odlika x_t javlja, a ne koja je njena zbirna vrednost u tim podacima
- ▶ U računanju $P(x|y)$ učestvuju samo one odlike koje se javljaju (imaju nenultu vrednost) u podatku x

Primer klasifikacije teksta - multinomijalni naivni Bajesov klasifikator

	doc	Reči u dokumentu	Klasa
Skup za obučavanje	1	Chinese Beijing Chinese	C
	2	Chinese Chinese Shanghai	C
	3	Beijing Macao	C
	4	Tokyo Japan Chinese	J
Skup za testiranje	5	Chinese Chinese Chinese Tokyo Japan	?

$$P(C) = \frac{3}{4}$$

$$P(J) = \frac{1}{4}$$

$$P(\text{Chinese}|C) = \frac{4 + 1}{6 + 8} = \frac{5}{14}$$

$$P(\text{Tokyo}|C) = \frac{0 + 1}{6 + 8} = \frac{1}{14}$$

$$P(\text{Japan}|C) = \frac{0 + 1}{6 + 8} = \frac{1}{14}$$

$$P(\text{Chinese}|J) = \frac{1 + 1}{6 + 3} = \frac{2}{9}$$

$$P(\text{Tokyo}|J) = \frac{1 + 1}{6 + 3} = \frac{2}{9}$$

$$P(\text{Japan}|J) = \frac{1 + 1}{6 + 3} = \frac{2}{9}$$

Primer klasifikacije teksta - multinomijalni naivni Bajesov klasifikator

	doc	Reči u dokumentu	Klasa
Skup za obučavanje	1	Chinese Beijing Chinese	C
	2	Chinese Chinese Shanghai	C
	3	Beijing Macao	C
	4	Tokyo Japan Chinese	J
Skup za testiranje	5	Chinese Chinese Chinese Tokyo Japan	?

$$P(C|d5) \propto P(C)P(\text{Chinese}|C)^3P(\text{Tokyo}|C)P(\text{Japan}|C) = \frac{3}{4} \times \left(\frac{5}{14}\right)^3 \times \frac{1}{14} \times \frac{1}{14} \approx 0,000174$$

$$P(J|d5) \propto P(J)P(\text{Chinese}|J)^3P(\text{Tokyo}|J)P(\text{Japan}|J) = \frac{1}{4} \times \left(\frac{2}{9}\right)^3 \times \frac{2}{9} \times \frac{2}{9} \approx 0,000135$$

Multivarijacioni Bernulijev naivni Bajesov klasifikator

- ▶ U čestoj upotrebi u klasifikaciji teksta je i multivarijacioni Bernulijev naivni Bajesov klasifikator (engl. *Multivariate Bernoulli Naïve Bayes*)
- ▶ Odlike su binarnog/indikatorskog tipa
- ▶ $Count(x_t, y)$ govori u koliko podataka klase y se odlika x_t javlja
- ▶ U računanju $P(x|y)$ učestvuju sve odlike koje se koriste u modelu, čak i one koje se ne javljaju (imaju nultu vrednost) u podatku x
- ▶ Pretpostavka o pozicionoj nezavisnosti odlika ovde nije neophodna, jer Bernulijev model po definiciji uzima u obzir samo prisustvo/odsustvo odlika

Multivarijacioni Bernulijev naivni Bajesov klasifikator

- Verovatnoća $P(x_t|y)$ - procenat podataka klase y u kojima je odlika x_t prisutna:

$$P(x_t|y) = \frac{\text{Count}(x_t, y)}{\text{Count}(y)}$$

- Laplasovo poravnanje:

$$P(x_t|y) = \frac{\text{Count}(x_t, y) + 1}{K + \text{Count}(y)} = \frac{\text{Count}(x_t, y) + 1}{2 + \text{Count}(y)}$$

- K je broj mogućih ishoda tj. vrednosti odlike x_t
- $K = 2$ kad je odlika x_t binarna

Primer klasifikacije teksta - multivarijacioni Bernulijev naivni Bajesov klasifikator

	doc	Reči u dokumentu	Klasa
Skup za obučavanje	1	Chinese Beijing Chinese	C
	2	Chinese Chinese Shanghai	C
	3	Beijing Macao	C
	4	Tokyo Japan Chinese	J
Skup za testiranje	5	Chinese Chinese Chinese Tokyo Japan	?

$$P(C) = \frac{3}{4}$$

$$P(J) = \frac{1}{4}$$

$$P(\text{Chinese}|C) = \frac{2+1}{2+3} = \frac{3}{5}$$

$$P(\text{Tokyo}|C) = \frac{0+1}{2+3} = \frac{1}{5}$$

$$P(\text{Japan}|C) = \frac{0+1}{2+3} = \frac{1}{5}$$

$$P(\text{Chinese}|J) = \frac{1+1}{2+1} = \frac{2}{3}$$

$$P(\text{Tokyo}|J) = \frac{1+1}{2+1} = \frac{2}{3}$$

$$P(\text{Japan}|J) = \frac{1+1}{2+1} = \frac{2}{3}$$

Primer klasifikacije teksta - multivarijacioni Bernulijev naivni Bajesov klasifikator

	doc	Reči u dokumentu	Klasa
Skup za obučavanje	1	Chinese Beijing Chinese	C
	2	Chinese Chinese Shanghai	C
	3	Beijing Macao	C
	4	Tokyo Japan Chinese	J
Skup za testiranje	5	Chinese Chinese Chinese Tokyo Japan	?

$$P(C) = \frac{3}{4}$$

$$P(J) = \frac{1}{4}$$

$$P(Beijing|C) = \frac{2+1}{2+3} = \frac{3}{5}$$

$$P(Shanghai|C) = \frac{1+1}{2+3} = \frac{2}{5}$$

$$P(Macao|C) = \frac{1+1}{2+3} = \frac{2}{5}$$

$$P(Beijing|J) = \frac{0+1}{2+1} = \frac{1}{3}$$

$$P(Shanghai|J) = \frac{0+1}{2+1} = \frac{1}{3}$$

$$P(Macao|J) = \frac{0+1}{2+1} = \frac{1}{3}$$

Primer klasifikacije teksta - multivarijacioni Bernulijev naivni Bajesov klasifikator

	doc	Reči u dokumentu	Klasa
Skup za obučavanje	1	Chinese Beijing Chinese	C
	2	Chinese Chinese Shanghai	C
	3	Beijing Macao	C
	4	Tokyo Japan Chinese	J
Skup za testiranje	5	Chinese Chinese Chinese Tokyo Japan	?

$$\begin{aligned}
 P(C|d5) &\propto P(C) \times P(\text{Chinese}|C) \times P(\text{Tokyo}|C) \times P(\text{Japan}|C) \\
 &\quad \times (1 - P(\text{Beijing}|C)) \times (1 - P(\text{Shanghai}|C)) \times (1 - P(\text{Macao}|C)) = \\
 &\quad \frac{3}{4} \times \frac{3}{5} \times \frac{1}{5} \times \frac{1}{5} \times \frac{2}{5} \times \frac{3}{5} \times \frac{3}{5} \approx 0,0026
 \end{aligned}$$

Primer klasifikacije teksta - multivarijacioni Bernulijev naivni Bajesov klasifikator

	doc	Reči u dokumentu	Klasa
Skup za obučavanje	1	Chinese Beijing Chinese	C
	2	Chinese Chinese Shanghai	C
	3	Beijing Macao	C
	4	Tokyo Japan Chinese	J
Skup za testiranje	5	Chinese Chinese Chinese Tokyo Japan	?

$$P(J|d5) \propto P(J) \times P(\text{Chinese}|J) \times P(\text{Tokyo}|J) \times P(\text{Japan}|J) \\ \times (1 - P(\text{Beijing}|J)) \times (1 - P(\text{Shanghai}|J)) \times (1 - P(\text{Macao}|J)) =$$

$$\frac{1}{4} \times \frac{2}{3} \times \frac{2}{3} \times \frac{2}{3} \times \frac{2}{3} \times \frac{2}{3} \times \frac{2}{3} \approx 0,022$$

Razlike između multinomijalnog i Bernulijevog modela u klasifikaciji teksta

	Multinomijalni model	Bernulijev model
$Count(x_t, y)$	Broje se (sabiraju) vrednosti odlike x_t u podacima klase y	Broje se javljanja odlike x_t u podacima klase y
x_t	Nije binarnog tipa (ali se može binarizovati)	Binarnog tipa
$P(x_t y)$	Odnos zbirne vrednosti odlike x_t i zbirne vrednosti svih odlika u podacima klase y	Procenat podataka klase y u kojima je odlika x_t prisutna
$P(x y)$	Uključuje samo odlike koje se javljaju (imaju nenultu vrednost) u podatku x	Uključuje sve odlike koje se koriste u modelu
Laplasovo poravnanje	$\frac{Count(x_t, y) + 1}{n + \sum_{i=1}^n Count(x_i, y)}$	$\frac{Count(x_t, y) + 1}{K + Count(y)}$

Razlike između multinomijalnog i Bernulijevog modela u klasifikaciji teksta

- ▶ Pretpostavka o pozicionoj nezavisnosti odlika
 - ▶ Multinomijalni model - potrebna
 - ▶ Bernulijev model - nepotrebna
- ▶ Binarizovan multinomijalni model nije jednak Bernulijevom!

Gausov naivni Bajesov klasifikator

- ▶ Mnoge odlike po prirodi imaju kontinualne numeričke vrednosti
 - ▶ Npr. temperatura u nekom mestu, cena akcija na berzi, visina plate, starost, itd.
- ▶ Čest pristup: pretpostaviti normalnu/Gausovu raspodelu vrednosti za uslovne verovatnoće takvih odlika $P(x_t|y)$
- ▶ Srednja vrednost odlike x_t u podacima klase y :

$$\mu_y = \frac{1}{m_y} \sum x_t \quad , \quad m_y - \text{broj podataka klase } y$$

- ▶ Standardna devijacija vrednosti odlike x_t u podacima klase y :

$$\sigma_y = \sqrt{\frac{1}{m_y} \sum (x_t - \mu_y)^2}$$

Gausov naivni Bajesov klasifikator

- ▶ Gausova/normalna raspodela vrednosti uslovnih verovatnoća odlika $P(x_t|y)$:

$$P(x_t|y) = \frac{1}{\sqrt{2\pi}\sigma_y} e^{-\frac{(x_t-\mu_y)^2}{2\sigma_y^2}}$$

- ▶ Moguće je primenjivati različite raspodele vrednosti uslovnih verovatnoća za različite odlike
 - ▶ Npr. Gausova raspodela za odlike sa kontinualnim numeričkim vrednostima i Bernulijeva raspodela za odlike sa binarnim/indikatorskim vrednostima

Gausov naivni Bajesov klasifikator - primer upotrebe

	Podatak	Temperatura	Vlažnost	Klasa
Skup za obučavanje	d1	32	84	Kiša
	d2	29	80	Suvo
	d3	26	92	Kiša
	d4	37	78	Suvo
Skup za testiranje	d5	33	82	?

$$P(Kiša) = \frac{1}{2}$$

$$P(Suvo) = \frac{1}{2}$$

Temperatura

$$\mu_{Kiša} = \frac{32 + 26}{2} = 29 \quad \mu_{Suvo} = \frac{29 + 37}{2} = 33 \quad \sigma_{Kiša} = \sqrt{\frac{3^2 + 3^2}{2}} = 3 \quad \sigma_{Suvo} = \sqrt{\frac{4^2 + 4^2}{2}} = 4$$

Vlažnost

$$\mu_{Kiša} = \frac{84 + 92}{2} = 88 \quad \mu_{Suvo} = \frac{80 + 78}{2} = 79 \quad \sigma_{Kiša} = \sqrt{\frac{4^2 + 4^2}{2}} = 4 \quad \sigma_{Suvo} = \sqrt{\frac{1^2 + 1^2}{2}} = 1$$

Gausov naivni Bajesov klasifikator - primer upotrebe

	Podatak	Temperatura	Vlažnost	Klasa
Skup za obučavanje	d1	32	84	Kiša
	d2	29	80	Suvo
	d3	26	92	Kiša
	d4	37	78	Suvo
Skup za testiranje	d5	33	82	?

$$P(\text{Temperatura} = 33 | \text{Kiša}) = \frac{1}{3\sqrt{2\pi}} e^{-\frac{(33-29)^2}{2 \cdot 9}} \approx 0,0547$$

$$P(\text{Temperatura} = 33 | \text{Suvo}) = \frac{1}{4\sqrt{2\pi}} e^{-\frac{(33-33)^2}{2 \cdot 16}} \approx 0,0998$$

$$P(\text{Vlažnost} = 82 | \text{Kiša}) = \frac{1}{4\sqrt{2\pi}} e^{-\frac{(82-88)^2}{2 \cdot 16}} \approx 0,0324$$

$$P(\text{Vlažnost} = 82 | \text{Suvo}) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(82-79)^2}{2 \cdot 1}} \approx 0,0044$$

Gausov naivni Bajesov klasifikator - primer upotrebe

	Podatak	Temperatura	Vlažnost	Klasa
Skup za obučavanje	d1	32	84	Kiša
	d2	29	80	Suvo
	d3	26	92	Kiša
	d4	37	78	Suvo
Skup za testiranje	d5	33	82	?

$$P(Kiša|d5) \propto P(Kiša) \times P(Temperatura = 33|Kiša) \times P(Vlažnost = 82|Kiša) \\ \approx 0,00089$$

$$P(Suvo|d5) \propto P(Suvo) \times P(Temperatura = 33|Suvo) \times P(Vlažnost = 82|Suvo) \\ \approx 0,00022$$

Generativni modeli

- ▶ Modeliraju zajedničku verovatnoću klase i podataka $P(y, x)$
- ▶ Na taj način se modelira proces generisanja podataka određenog tipa
- ▶ Naivni Bajesov klasifikator je generativni model - aposteriorna verovatnoća klase se dobija iz zajedničke verovatnoće preko Bajesove teoreme:

$$P(y|x) = \frac{P(y, x)}{P(x)}$$

- ▶ U generativne modele spadaju:
 - ▶ skriveni Markovljevi lanci (engl. HMM - *Hidden Markov Models*)
 - ▶ Bajesovske mreže (engl. *Bayesian networks*)
 - ▶ latentna Dirihleova alokacija (engl. LDA - *Latent Dirichlet Allocation*)

Prednosti naivnog Bajesovog klasifikatora

- ▶ Jednostavnost
- ▶ Brzina učenja i klasifikacije - dovoljan jedan prolaz kroz podatke
- ▶ Nije osetljiv na irelevantne odlike
- ▶ Dobro se ponaša kada postoji veći broj podjednako važnih odlika
- ▶ Interpretabilnost - veća težina pridružena određenoj odlici znači da je ona važnija pri odlučivanju
- ▶ Direktno je primenjiv na višeklasnu klasifikaciju
- ▶ Model se lako može ažurirati novopristiglim podacima

Mane naivnog Bajesovog klasifikatora

- ▶ (Netačna) pretpostavka o statističkoj nezavisnosti odlika
 - ▶ Kada su dve odlike korelisane dolazi do duplog brojanja - daje iskrivljene procene o važnosti odlika
- ▶ Vrednosti aposteriornih verovatnoća koje model daje su često znatno iskrivljene u korist najverovatnije klase

Upotreba naivnog Bajesovog klasifikatora

- ▶ Često se koristi kao *baseline* zbog svoje jednostavnosti i brzine
- ▶ Često postiže bolje performanse od složenijih modela kada je dostupno malo podataka za obučavanje
- ▶ Zbog brzine je kompetitivan i kada je dostupno puno podataka
- ▶ Raširen algoritam u klasifikaciji tekstualnih podataka
 - ▶ Multinomijalna varijanta (sa binarizovanim odlikama) obično najbolja
 - ▶ Primene - detekcija spama, analiza sentimenta, klasifikacija teksta po temama, analiza autorstva,...
- ▶ Koristi se i u medicinskoj dijagnostici, analizi genomskih podataka,...