

Uvod u analizu podataka

Pronalaženje skrivenog znanja, *Elektrotehnički fakultet Univerziteta u Beogradu*
Prof. dr Dražen Drašković


Ciljevi

- Osnovni koraci analize podataka u kontekstu mašinskog učenja.
- Prepoznati i obraditi nedostatke i nepravilnosti u sirovim podacima.
- Osnovne metode preprocesiranja i inženjeringa osobina (eng. *feature engineering*).
- Sprovoditi deskriptivnu i vizualnu analizu podataka (eng. *exploratory data analysis*).
- Pripremiti skup podataka za ulaz u mašinski model.



Šta je analiza podataka?

- Analiza podataka je proces:
 - Ekstrakcije korisnih informacija iz sirovih podataka.
 - Razumevanja strukture, obrazaca i odnosa među podacima.
 - Donošenja zaključaka koji vode ka modelovanju, odlučivanju i/ili daljoj obradi.
- Ključne komponente:
 - Deskriptivna analiza (eng. *descriptive analytics*) - Šta se dogodilo?
 - Istraživačka analiza (eng. *exploratory data analysis*) - Kako podaci izgledaju i kako se ponašaju?
 - Inferencijalna analiza (eng. *inferential data analysis*) - Šta možemo da zaključimo i predvidimo?




Proces analize podataka



Uloga analize podataka u ML ciklusu




- Zašto je analiza podataka ključna u mašinskom učenju?
 - 70-80% vremena u ML projektu odlazi na razumevanje i pripremu podataka.
 - Kvalitet modela direktno zavisi od kvaliteta ulaznih podataka.
 - EDA pomaže u:
 - otkrivanju obrazaca i odnosa među promenljivim;
 - uočavanju problema (outliers, nedostajuće vrednosti, neuravnotežene klase);
 - donošenju odluka o izboru modela i metrika.
- **Dobar model ne može ispraviti loš skup podataka!**



Tok podataka - od izvora do modela

- Tipičan tok pripreme i analize podataka za ML projekte:
 1. **Prikupljanje podataka** - iz CSV/XLS fajlova, baza, API, sa senzora,...
 2. **Razumevanje podataka (EDA #1)** - osnovna statistika, tipovi podataka, distribucije, nedostajuće vrednosti.
 3. **Pretprocesiranje** - čišćenje, skaliranje, kodiranje, eliminacija outliera.
 4. **Inženjering osobina** - kreiranje i selekcija korisnih osobina.
 5. **Napredna analiza (EDA #2)** - vizualizacije, korelacije, otkrivanje obrazaca.
 6. **Modelovanje i evaluacija**



Vrste podataka u analizi

- Podaci dolaze u različitim oblicima - razumevanje njihove prirode ključno je za pravilan odabir analiza i modela.
- **Numerički podaci**
 - Kontinualne (neprekidne) vrednosti (npr. visina osobe, temperatura)
 - Diskretne (prekidne) vrednosti (npr. broj dece u odeljenju, broj klikova po reklamama)
- **Kategorijalni podaci**
 - Nominalni podaci (npr. boja: crvena, plava, žuta)
 - Ordinalni podaci (npr. veličina: S, M, L)
- **Tekstualni podaci**
 - Recenzije, komentari, članci
- **Vremenske serije**
 - Vrednosti u vremenskom nizu (npr. cena akcija kompanije po danu, vrednost kriptovalute)
- **Multimedijalni podaci (slike, zvučni zapisi, video zapisi)**



Vrste podataka u analizi




Vrsta	Primer	Tip vrednosti	Specifičnosti
numerički	godine, plata	int, float/double	skaliranje, deskriptivna statistika
kategorijalni	pol, boja	string	kodiranje u numerički oblik
tekstualni	komentar korisnika, i-mejl	string	NLP tehnike, tokenizacija
vremenske serije	temperatura (po danima), kurs RSD vs EUR (po danima)	float/double	sezonski obrasci, trendovi i pravimo „lag“ promenljive

Strukture podataka


- Podaci su spakovani u različitim strukturama.
- Tabelarni podaci (DataFrame)**
 - Redovi su instance, kolone su osobine (eng. *feature*)
 - Primer: Excel, CSV, SQL tabele
- Matrice i nizovi**
 - NumPy matrice, slike (vrednosti u px), podaci iz senzora
 - Koriste se direktno u ML modelima
- Hijerarhijski podaci**
 - Podaci sa ugnježdenom strukturom, na primer: JSON, XML.
 - Često se javljaju kod veb API i mobilnih aplikacija.
- Grafovi**
 - Čvorovi i veze (npr. društvene mreže, transportne mreže, itd.)
 - Potrebni posebni alati i biblioteke za obradu (npr. PyG za GNN, NetworkX i sl.)

	A
1	70172,Male,13,aviation,3,4,3,1,5,5,5,4,5,5,neutral or dissatisfied
2	5047,Male,25,tourism,3,2,3,3,1,1,1,1,4,1,neutral or dissatisfied
3	110028,Female,26,tourism,2,2,2,2,5,5,5,4,4,5,satisfied
4	24026,Female,25,tourism,2,5,5,5,2,2,2,1,4,2,neutral or dissatisfied
5	119299,Male,61,aviation,3,3,3,3,4,5,3,3,3,3,satisfied
6	111157,Female,26,business,3,4,2,1,1,1,1,4,4,1,neutral or dissatisfied
7	82113,Male,47,academic,2,4,2,3,2,2,2,3,5,2,neutral or dissatisfied
8	96462,Female,52,aviation,4,3,4,4,5,5,5,4,5,4,satisfied
9	79485,Female,41,tourism,1,2,2,2,4,3,1,4,1,2,neutral or dissatisfied
10	65725,Male,20,academic,3,3,3,4,2,3,2,4,3,2,neutral or dissatisfied
11	34991,Female,24,academic,4,5,5,4,2,2,2,3,5,2,neutral or dissatisfied
12	51412,Female,12,tourism,2,4,2,2,1,1,1,5,5,1,neutral or dissatisfied
13	98628,Male,53,tourism,1,4,4,4,1,1,1,4,4,1,neutral or dissatisfied

3D array



```
{
  "students": [
    {
      "name": "Nina",
      "marks": {
        "math": 10,
        "programming": 9,
        "physics": 8
      }
    },
    {
      "name": "Ana",
      "marks": {
        "math": 7,
        "programming": 10,
        "physics": 9
      }
    },
    {
      "name": "Uroš",
      "marks": {
```



Izvori - Gde nalazimo podatke?

- Analitički i ML projekti počinju nalaženjem podataka. Podaci mogu dolaziti iz:

- **Lokalnih datoteka**

- Primer: CSV, Excel, JSON, XML, TXT fajlovi



- **Baza podataka**

- Relacionih (MySQL, PostgreSQL, i dr.) ili nerelacionih (MongoDB, Redis, i dr.)



- **Veb interfejsa (API) i servisa**

- RESTful API, GraphQL – omogućavaju preuzimanje podataka u realnom vremenu



- **Dostupnih skupova podataka na onlajn platformama**

- Primer: [Kaggle](#) (za takmičenja), [UC Irvine DSR](#), [Google Datasets](#), [USA open data](#), [EU open data](#), [SRB open data](#)



- **Senzora i IoT uređaja**

- Podaci u realnom vremenu poput temperatura, vazdušnog pritiska, brzina, pokreta, itd.



- **Prikupljanje podataka iz veb izvora (eng. *web scraping*)**

- Prikupljanje podataka pomoću alata kao što su BeautifulSoup, Selenium i slični.



Preprocesiranje podataka

Pronalaženje skrivenog znanja, *Elektrotehnički fakultet Univerziteta u Beogradu*

Pretprocesiranje podataka - prvi korak ka uspešnom modelu

- Sirovi podaci nisu često odmah upotrebljivi.

Oni mogu sadržati:

- **Nedostajuće vrednosti** (*missing values*)
- **Duplikate**
- **Ekstremne vrednosti** (*outliers*)
- **Nekonzistentne formate**
- **Skale koje nisu uporedive**

Pretprocesiranje podrazumeva pripremu podataka za analizu i modelovanje:

- čišćenje podataka,
- transformaciju,
- normalizaciju/skaliranje,
- kodiranje kategorijalnih vrednosti,
- detekciju i obradu ekstremnih vrednosti.

1	Age	Gender	Salary	JoinDate
2	-----	-----	-----	-----
3	25.0	Male	50000	2021-01-01
4	30.0	Female	54000	2022-02-02
5	22.0	Female	48000	2023-03-01
6	35.0	Male	60000	2024-01-04
7	NaN	Male	52000	2024.09.18
8	30.0	Female	54000	2021-01-06
9	29.0	Female	54000	2021-01-06
10	1000.0	Male	58000	2020/07/22
11	30.0	Female	54000	2020-01-08
12	22.0	Female	48000	2023-03-01
13	22.0	Female	48000	2022-01-03

Uklanjanje nedostajućih vrednosti



- U realnim podacima često se pojavljuju nedostajuće vrednosti - NaN, null, prazna polja
- Moguće strategije za njihovo rešavanje su:

- Brisanje:**

- Redova ili kolona

- Imputacija (popunjavanje):**

- Srednjom vrednošću (mean)
 - Medijanom
 - Najčešćom vrednošću (mode)
 - Grupna imputacija (npr. po polu, regionu)
 - Naprednije metode (KNN, regresija, itd.)



- Način imputacije zavisi od konteksta i tipa podataka!

Uklanjanje duplikata u podacima

- Duplikati su redovi koji se potpuno ili delimično ponavljaju.
- Nastaju usled greške u unosu, spajanja više izvora ili lošeg preprocesiranja.

- Posledice duplikata:

- Iskrivljuju statistike i analize
- Utiču na performanse modela



- Strategije koje koristimo:

- Pronalaženje duplikata (metod u Pandas: `df.duplicated()`)
- Uklanjanje duplikata (metod: `df.drop_duplicates()`)
- Uklanjanje po ključnim kolonama (metod: `df.drop_duplicates(subset=['ime', 'prezime'])`)

Ime	Prezime	Godine	Grad
Ana	Petrović	25	Beograd
Marko	Nikolić	30	Novi Sad
Ana	Petrović	25	Beograd
Jovan	Janković	28	Niš
Marko	Nikolić	30	Novi Sad


Detakcija i obrada ekstremnih vrednosti (*outliers*)

- **Ekstremumi** su vrednosti koje značajno odstupaju od ostalih. Mogu se javiti zbog grešaka u unosu podataka, merenju, ili biti potpuno validni (ali retko).
- **Zašto ih tretirati?** Mogu značajno uticati na performanse modela.
- **Pristupi za detekciju:**
 - **Interkvartalni raspon - IQR (*Interquartile Range*):** koristi kvartile (Q1 i Q3); $IQR = Q3 - Q1$.
Q1 = 25% podataka leži između minimuma i Q1; Q3 = 75% podataka leži između minimuma i Q3.
Donja granica: $(Q1 - 1.5 \cdot IQR)$ Gornja granica: $(Q3 + 1.5 \cdot IQR)$
 - **Z-skor:** koliko standardna devijacija odstupa od srednje vrednosti.
 - $$Z_{score} = \frac{(x - mean)}{std.deviation}$$
 - Z-skor može biti i pozitivan i negativan.
 - $Z > 3$ je ekstreman.



Skaliranje podataka (*feature scaling*)

- Skaliranje je proces dovođenja svih numeričkih vrednosti na sličan opseg.
- Neophodno je za mnoge algoritme mašinskog učenja (linearnu regresiju, SVM, kNN).
- Najčešće metode skaliranja:
 - Min-Max skaliranje: svede podatke u opseg $[0, 1]$
 - StandardScaler: transformiše podatke da imaju srednju vrednost 0 i standardnu devijaciju 1.
 - RobustScaler: najbolji izbor - koristi medijanu i interkvartilni raspon IQR, otporan na ekstremume.




Kodiranje kategorijalnih promenljivih

- Mašinski algoritmi rade sa brojevima - kategorijalne promenljive treba transformisati.
- Vrste kodiranja:
 - *Label Encoding*: svakoj kategoriji dodeljuje se broj (npr. crveno=0, zeleno=1, plavo=2)
 - *One-Hot Encoding*: binarne kolone za svaku klasu (crveno=[1,0,0], zeleno=[0,1,0], itd.)
 - *Ordinal Encoding*: koristi se kad kategorije imaju prirodan redosled (malo=1, srednje=2, veliko=3)
- Izbor metode zavisi od algoritma i prirode podataka.

Boja	Label	One-Hot	Ordinal
Crveno	0	[1, 0, 0]	1
Zeleno	1	[0, 1, 0]	2
Plavo	2	[0, 0, 1]	3


Detekcija i uklanjanje irelevantnih promenljivih

- Šta su irelevantne promenljive?
 - Promenljive koje **ne doprinose** tačnosti modela.
 - Mogu da **unesu šum**, **dovedu do preobučavanja** (*overfitting*), ili **produže vreme treniranja**.
- Primeri irelevantnih osobina:
 - Različiti identifikatori (ID, JMBG, korisničko ime u sistemu)
 - Nasumične kolone bez značenja (npr. Random_Code)
 - Redudantne informacije (npr. datum_rodjenja, i ponovo dan_rodjenja, mesec_rodjenja, godina_rodjenja)
- Kako ih detektovati?
 - Korelacija sa ciljem (metoda `df.corrwith(y)`)
 - Vizuelizacija korelacija (primer preko heatmap)
 - Automatizovane metode selekcije osobina: Filter metode (*SelectKBest*), Omotačke metode (*RFE*), Ugrađene metode (*Lasso*, *RandomForest feature importance*)



Diskretizacija: Pretvaranje kontinualnih vrednosti u kategorije

- Diskretizacija (*binning*) je tehnika koja pretvara numeričke (kontinualne) promenljive u diskretne (kategorijalne) vrednosti.
- Koristi se za:
 - pojednostavljivanje modela,
 - otkrivanje obrazaca,
 - smanjenje uticaja ekstremuma.
- Tipovi diskretizacije:
 - Jednaka širina (*equal-width*) - vrednosti se dele na jednake intervale;
 - Jednak broj (*equal-frequency*) - svaka kategorija da ima približno isti broj uzoraka;
 - Na osnovu domena ili pravila - predefinisani pragovi (npr. starosne grupe: 0-18, 19-35, 36-65, 65+)



Inženjering osobina / karakteristika

Pronalaženje skrivenog znanja, *Elektrotehnički fakultet Univerziteta u Beogradu*

Inženjering osobina


- Inženjering osobina (*feature engineering*) predstavlja proces kreiranja, transformacije, i selekcije osobina (*features*) iz sirovih podataka, kako bi se poboljšale performanse modela mašinskog učenja.
- Koristimo domensko znanje, da bismo izdvojili osobine (karakteristike).
- Obuhvata:
 - Kreiranje novih kolona na osnovu postojećih.
 - Transformaciju postojećih kolona (log-transformacije, skaliranje)
 - Uklanjanje irelevantnih osobina.
- Dobar skup osobina je ključan za uspešan model.

Primer: kreiranje nove osobine iz postojećih

- Primer: Titanic skup podataka
- Iz kolona *SibSp* (broj braće/sestara/supružnika na brodu) i *ParCh* (broj roditelja/dece na brodu) možemo napraviti novu osobinu:
 $FamilySize = SibSp + ParCh + 1$


```
data['family members'] = data['parch'] + data['sibsp']  
data['survived'].groupby(data['family members']).mean().plot(kind='bar')
```

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked
0	1	1	Allen, Miss. Elisabeth Walton	female	29.00	0	0	24160	211.3375	B5	S
1	1	1	Allison, Master. Hudson Trevor	male	0.92	1	2	113781	151.5500	C22 C26	S
2	1	0	Allison, Miss. Helen Loraine	female	2.00	1	2	113781	151.5500	C22 C26	S
3	1	0	Allison, Mr. Hudson Joshua Creighton	male	30.00	1	2	113781	151.5500	C22 C26	S
4	1	0	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	female	25.00	1	2	113781	151.5500	C22 C26	S
5	1	1	Anderson, Mr. Harry	male	48.00	0	0	19952	26.5500	E12	S
6	1	1	Andrews, Miss. Kornelia Theodosia	female	63.00	1	0	13502	77.9583	D7	S
7	1	0	Andrews, Mr. Thomas Jr	male	39.00	0	0	112050	0.0000	A36	S
8	1	1	Appleton, Mrs. Edward Dale (Charlotte Lamson)	female	53.00	2	0	11769	51.4792	C101	S
9	1	0	Artagaveytia, Mr. Ramon	male	71.00	0	0	PC 17609	49.5042	NaN	C



Izbor relevantnih osobina (karakteristika)

- Zašto bирамо osobine?
 - Nisu sve osobine jednako korisne za model.
 - Suvišne ili neinformativne osobine mogu degradirati performanse.
- Tri glavne metode za selekciju osobina:
 - Filter metode – koriste statistike (korelacija, chi-square, varijansa)
 - Omotačke (*Wrapper*) metode – koriste performanse modela da odaberu najbolje osobine (npr. RFE)
 - Ugrađene (*Embedded*) metode – uče koje osobine su važne tokom treniranja (npr. Lasso ili Stabla odlučivanja).



Osobina	Korelacija	Varijansa	Komentar
Age	0.45	12.3	Srednje jaka korelacija, korisna osobina
Fare	0.62	55.8	Jaka korelacija, vrlo korisna osobina
SibSp	0.10	2.5	Slaba korelacija, moguće za odbacivanje
Parch	0.08	1.8	Slaba korelacija, isto malo značajna osobina
Cabin	0.01	0.0	Niska varijansa, može se odbaciti
Embarked	0.12	0.7	Kategorijalna osobina, potrebno kodiranje

Analiza glavnih komponenti i redukcija dimenzionalnosti

- Šta je redukcija dimenzionalnosti?
 - Tehnika za smanjenje broja osobina u skupu podataka, zadržavajući što više informacija.
 - Pomaže u vizualizaciji, smanjenju šuma i ubrzavanju učenja modela.
- Analiza glavnih komponenti (PCA)
 - Linearna transformacija koja pronalazi nove osobine (komponente).
 - Komponente su nezavisne i sortirane po objašnjenoj varijansi.
 - Prvih nekoliko komponenti može sačuvati većinu informacija iz originalnih podataka.

```
print(titanic.corr())
```

	Survived	Pclass	Age	SibSp	Parch	Fare	\
Survived	1.000000	-0.338481	-0.041805	-0.035322	0.081629	0.257307	
Pclass	-0.338481	1.000000	-0.349576	0.083081	0.018443	-0.549500	
Age	-0.041805	-0.349576	1.000000	-0.205511	-0.130641	0.115054	
SibSp	-0.035322	0.083081	-0.205511	1.000000	0.414838	0.159651	
Parch	0.081629	0.018443	-0.130641	0.414838	1.000000	0.216225	
Fare	0.257307	-0.549500	0.115054	0.159651	0.216225	1.000000	
Sex_male	-0.543351	0.131900	0.081373	-0.114631	-0.245489	-0.182333	
Embarked_Q	0.003650	0.221009	-0.065647	-0.026354	-0.081228	-0.117216	
Embarked_S	-0.149683	0.074053	0.019145	0.068734	0.060814	-0.162184	

	Sex_male	Embarked_Q	Embarked_S
Survived	-0.543351	0.003650	-0.149683
Pclass	0.131900	0.221009	0.074053
Age	0.081373	-0.065647	0.019145
SibSp	-0.114631	-0.026354	0.068734
Parch	-0.245489	-0.081228	0.060814
Fare	-0.182333	-0.117216	-0.162184
Sex_male	1.000000	-0.074115	0.119224
Embarked_Q	-0.074115	1.000000	-0.499421
Embarked_S	0.119224	-0.499421	1.000000


Izrada polinomskih i interaktivnih osobina

- Šta su polinomske osobine?
 - Kreiranje novih osobina kao polinomske kombinacije postojećih (npr. kvadrati, kubovi).
- Šta su interaktivne osobine?
 - Kombinovanje dve ili više osobina kroz množenje, deljenje ili druge operacije.
- Zašto ih koristimo?
 - Da model može da uhvati nelinearne odnose između promenljivih.
- Primer: polinomska osobina x_1^2 i interaktivna osobina $x_1 \times x_2$
- U Python-u se koristi: `PolynomialFeatures` iz `sklearn.preprocessing`

ID	x_1	x_2	x_1^2	x_2^2	$x_1 \times x_2$
1	2	3	4	9	6
2	4	1	16	1	4
3	0	5	0	25	0
4	3	2	9	4	6

Uloga domenskog znanja u kreiranju osobina

- Razumevanje problema i podataka je ključno.
- Stručnjaci iz oblasti daju smernice za relevantne osobine.
- Primenjuju se specifične transformacije, agregacije, ili izračunavanja.
- Znanje pomaže u otkrivanju skrivenih veza i značajnih obrazaca.
- Povećava interpretabilnost modela i kvalitet predikcija.




Istraživačka analiza podataka (EDA)

Pronalaženje skrivenog znanja, *Elektrotehnički fakultet Univerziteta u Beogradu*

Ciljevi EDA

Ciljevi:

- Razumevanje osnovnih karakteristika podataka
- Otkrivanje obrazaca i odnosa između varijabli
- Detekcija nedostajućih vrednosti i ekstremnih vrednosti
- Provera distribucije i normalnosti podataka
- Provera korelacija između osobina
- Otkrivanje mogućih grešaka i nekonzistencija u podacima
- Priprema za selekciju i transformaciju osobina



Deskriptivna statistika


- Srednja vrednost (*mean*)
 - Aritmetički prosek vrednosti
- Medijana (*median*)
 - središnja vrednost - otpornija na ekstremne vrednosti, od srednje vrednosti
- Mod (*mode*)
 - najčešće korišćena vrednost
- Standardna devijacija (*std. dev*)
 - prosečno odstupanje od srednje vrednosti – meri rasipanje podataka
- Opseg (*range*), kvartili, IQR
 - mere varijabilnosti i distribucije

Osobina	Srednja vr.	Medijana	Std. Dev	Min	Max
Age	29.7	28	14.5	0.42	80
Fare	32.2	14.5	49.7	0	512
SibSp	0.52	0	1.10	0	8

Korelacije između promenljivih

- Korelacija meri snagu i pravac odnosa između dve numeričke promenljive.
- Vrednosti su između **-1** i **+1**:
 - Savršena pozitivna korelacija (**+1**)
 - Nema korelacije (**0**)
 - Savršena negativna korelacija (**-1**)
- Najčešće korišćene metrike:
 - **Pearson** - za linearne odnose
 - **Spearman** - za monotone, nelinearne odnose
- Bitno za detekciju redundantnih osobina (multikolinearnost) i razumevanje odnosa sa ciljem.
- Ako su dve promenljive u korelaciji, ne znači da jedna uzrokuje drugu.

Titanic	Age	Fare	SibSp	ParCh	Survived
Age	1.00	0.09	-0.31	-0.18	-0.08
Fare	0.09	1.00	0.16	0.22	0.26
SibSp	-0.31	0.16	1.00	0.41	-0.04
ParCh	-0.18	0.22	0.41	1.00	0.08
Survived	-0.08	0.26	-0.04	0.08	1.00



Vizuelizacija podataka



- Predstaviti osnovne načine za vizuelnu analizu pojedinačnih i povezanih karakteristika podataka.
- **Univarijantna analiza** (jedna promenljiva):
 - Distribucije podataka (*histogram, boxplot*)
 - Procenjena gustina verovatnoće (*Kernel Density Estimation*, skr. KDE)
- **Bivarijantna analiza** (dve promenljive):
 - *Scatter plot* (raspršeni dijagram)
 - *Boxplot* (za poređenje kategorija)
 - *Bar chart* (za frekvencije po klasama)
 - *Violin plot*

Vizuelizacija podataka: Univarijantna analiza

Broj putnika broda Titanic čije se godine znaju:

Age range	Count	Age range	Count
0-5	36	31-35	76
6-10	19	36-40	74
11-15	18	41-45	54
16-20	99	46-50	50
21-25	139	51-55	26
26-30	121	56-60	22


Age range	Count
61-65	16
66-70	3
71-75	3



Vizuelizacija podataka: Bivarijantna analiza


Scatter Plot

Test Score vs. Hours





Box Plot

Recovery Time (Days) by Treatment Type




Bar Chart

The counts plot of passenger class




How many Men and Women Survived by Passenger Class



Prikaz distribucije podataka


- Distribucija opisuje **način na koji su vrednosti promenljive raspoređene** u skupu podataka.
- Koriste se vizualizacije da bi se identifikovali obrasci: simetrija, pristrasnost, multimodalnost, itd.
- Najčešći grafički alati:
 - **Histogrami** - prikazuje frekvenciju vrednosti po opsezima (dobar za uočavanje simetrije, vrha i repova)
 - **Gustinski (KDE) grafikoni** - glatka verzija histograma kroz gustinu verovatnoće (prikazuje oblik distribucije)
 - **Boxplot** dijagrami - prikazuje kvartile, medijanu i ekstremume (dobri za otkrivanje pristrasnosti)
 - **Q-Q (quantile-quantile) plot** – upoređivanje kvantila dva skupa podataka ili skupo podataka naspram kvantila normalne distribucije (ako su tačke na pravoj liniji, znači da su podaci normalni)
- **Koeficijent asimetrije** (iskrivljenosti) – numerička metrika:
0 normalno, < 0 leva iskrivljenost, > 0 desna iskrivljenost
- Vizualizacija distribucije je ključna za:
 - izbor odgovarajućih **modela i tehnika obrade podataka**
 - otkrivanje **ekstremuma** i potencijalnih **problema sa skaliranjem**




Vizuelizacija kategorijalnih podataka

- Trakasti grafikovni (*Bar plot*) i grafikoni pite (*pie chart*)


Procentualni odnos broja automobila po menjaču




Raspodela brojnosti po godištu proizvodnje



Raspodela brojnosti po pređenoj kilometraži





Broj automobila po menjaču



Detekcija anomalija kroz grafike i njihov tretman

- Ekstremne vrednosti (*outliers*) su one koje odstupaju od ostatka podataka.
- **Mogu uticati negativno na modele, statistike i vizuelizacije.**
- **Detekcija:** IQR metoda, Z-skor, vizuelizacija (histogram, boxplot, scatter plot, itd.)
- **Treman:** uklanjanjem, transformacijama, ograničavanjem vrednosti.
- Dobro analizirati: nekada zavisi od konteksta – nisu uvek greška!



Pregled i priprema za modelovanje

- Skup podataka očišćen - sređivanje nedostajućih vrednosti, duplikata i ekstremuma
 - Odabrane osobine (karakteristike)
 - Promenljive spremne (kategorizovane i numeričke)
 - Izvršena standardizacija / normalizacija (po potrebi)
 - Definisana ciljna promenljiva
 - Skup podataka podeljen na podskup za treniranje i testni podskup (80/20 odnos)
-
- Sledeći korak: primena modela nadgledanog učenja
 - Cilj: precizna predikcija

Pitanja?

Hvala na pažnji.