

Tehnike mašinskog učenja

Pronalaženje skrivenog znanja, *Elektrotehnički fakultet Univerziteta u Beogradu*
Prof. dr Dražen Drašković

Ciljevi

- Osnovni principi mašinskog učenja, sa fokusom na nagledano učenje
- Razlike između klasifikacionih i regresionih problema
- Ključni algoritmi za klasifikaciju i regresiju
- Razumeti pojmove preobučavanja i podobučavanja
- Primene metrika za evaluaciju performansi modela
- Razlikovati trening, validacioni i testni skup podataka, i unakrsnu validaciju
- Prepoznati važnost interpretabilnosti modela
- Naučiti da koristimo popularne alate i biblioteke za ML



Šta je mašinsko učenje?



- Oblast veštačke inteligencije koja omogućava računarima da *uče iz podataka* i *donose odluke* ili *predikcije* bez eksplicitnog programiranja (Arthur Samuel, 1959).
 - Kombinacija primenjene statistike, veštačke inteligencije, matematičke optimizacije, računarskih nauka.
 - Učenje zasnovano na iskustvu.
 - Cilj: generalizacija – tačna predviđanja na novim, do sada neviđenim podacima.
- Čemu služi?
 - Problemi za koje je vrlo teško ručno definisati kako ih treba rešiti - klasično programiranje nije moguće.
 - Izvlačenje korisnih informacija iz velike količine sirovih podataka - istraživanjem podataka (*data mining*) ili predviđanje budućih trendova korišćenjem trenutno dostupnih podataka (*predictive analytics*).
 - Kada ručna analiza nije moguća ili je previše spora.
 - Primena u kompleksnim sistemima, koji se dinamički prilagođavaju okruženju.



Uređeni podaci



Model



Predikcija / odluka

Šta je mašinsko učenje?




Klasično programiranje	Mašinsko učenje
Pravila + Podaci => Rezultat	Podaci + Rezultat => Pravila (model)
Programer definiše logiku	Model uči logiku (iz podataka)
Dobro za jednostavne i determinističke zadatke	Neophodno za kompleksne, nestrukturisane probleme
Pravila se retko menjaju	Model se može adaptirati i menjati

- Primeri:
 - Klasično programiranje: ako je broj_poena ≥ 91 na ETF-u, ocena je 10.
 - Mašinsko učenje: na osnovu istorije ocenjivanja na predmetu i/ili ranijim ocenama tog studenta, na drugim predmetima, model predviđa ocenu studentu.




Tipovi učenja

- Nadgledano učenje (*Supervised Learning*)
 - Podaci sa oznakama (labelama) - znamo tačne odgovore
 - Cilj: naučiti funkciju koja predviđa oznaku
 - Primer: predikcija cene stana/automobila, klasifikacija poruka e-pošte ka spam/ne spam
- Nenadgledano učenje (*Unsupervised Learning*)
 - Podaci bez oznaka (labela)
 - Cilj: otkriti obrasce ili strukture u podacima
 - Primer: grupisanja korisnika po nekom ponašanju, redukcija dimenzionalnosti
- Učenje podsticajem / sa podrškom (*Reinforcement Learning*)
 - Agent uči kroz nagrade i kazne
 - Cilj: maksimizovati kumulativnu nagradu kroz interakciju sa okruženjem
 - Primer: autonomna vožnja, igre (npr. AlphaGo), robotski pokreti
- Polunadgledano učenje (*Semi-supervised learning*)
 - Kombinuje mali broj označenih i veliki broj neoznačenih podataka
 - Cilj: poboljšati tačnost modela koristeći dodatne informacije iz neoznačenih podataka
 - Primer: klasifikacija dokumenata gde je samo podskup dokumenata ručno označen



ML aplikacije u stvarnom svetu


- Prepoznavanje obrazaca
 - Predikcija cena stanova ili automobila
 - Predviđanje bolesti (dijagnoze) ili najadekvatnije terapije u medicini (*Computer Aided Diagnosis, CAD*)
 - Prepoznavanje rukopisa
 - Detekcija prevara na internetu, u bankarstvu, itd.
- Kompjuterska vizija
 - Prepoznavanje rukopisa/karaktera (Optical character recognition, OCR), prepoznavanje lica na mobilnim telefonima ili na pasoškoj kontroli, prepoznavanje pokreta
- Obrada prirodnih jezika (engleskog, kineskog, španskog, srpskog, i dr.)
 - Analiza sentimenta (pozitivan, negativan, neutralan), sumarizacija teksta i mašinsko prevođenje
 - Detekcija neželjene (*spam*) elektronske pošte
- Robotika
 - Kretanje robota kroz prostor
- Sistemi za preporučivanje - preporuke na platformama Netflix, Amazon, YouTube
- Autonomna vozila (prepoznavanje ulice, prepreka, saobraćajnih znakova, itd.)
- Igranje igara (šah, Go, i drugih kompleksnih)



ML pipeline - od podataka do previđanja



- Prikupljanje podataka
- Čišćenje i priprema podataka
- Modelovanje (Trening modela)
- Evaluacija
- Primena (*Deployment*)



Zašto je priprema podataka ključna?

- Kvalitet podataka utiče na performanse modela
- Uklanjanje nedostajućih ili nepravilnih vrednosti
- Normalizacija / standardizacija podataka
- Odabir relevantnih karakteristika (*feature selection proces*)



Nadgledano učenje

(Supervised Learning)


Pronalaženje skrivenog znanja, *Univerzitet u Beogradu - Elektrotehnički fakultet*

Osnovni pojmovi nadgledanog učenja - Modeli

- Pod terminom **Model** podrazumevamo:
 - Algoritam mašinskog učenja (model u širem smislu). Npr. Linearna regresija ili Stabla odlučivanja.
 - Konkretna funkcija preslikavanja ulaza u izlaz, tj. konkretna hipoteza $h(x)$, dobijena primenom odabranog algoritma mašinskog učenja nad nekim konkretnim skupom podataka (model u užem smislu). Npr. Neka konkretna regresiona funkcija ili neko konkretno stablo odlučivanja.
- **Parametarski modeli** - imaju tačno određen broj parametara, kao što su Linearna regresija, Logistička regresija, Naivni Bajesov klasifikator, Metoda potpornih vektora bez kernela.
- **Neparametatski modeli** - mogu teorijski imati beskonačan broj parametara, tj. broj i priroda parametara zavise od samih vrednosti podataka, kao kod metode K najbližih suseda, Stabala odlučivanja, Metode potpornih vektora sa kernelom sa radijalnom osnovom.


Osnovni pojmovi nadgledanog učenja - Obučavanje modela

- Nadgledano učenje je vrsta mašinskog učenja gde model uči na označenim podacima (tj. ulaznim podacima i odgovarajućim ciljevima).
- Ulazi (X): skup karakteristika ili atributa (npr. visina, težina, starost)
- Ciljevi (y): očekivane vrednosti ili kategorije (npr. cena, jeste neželjena pošta ili nije, bolest ili ne)
- Pod obučavanjem modela podrazumevamo optimizaciju modela korišćenjem raspoloživih parova (x, y). Optimizacija zavisi od konkretnog algoritma.
- **Cilj:**
Naučiti model koji može da predvidi ciljeve (y) za nove, nepoznate ulazne podatke (X).
Naći optimalnu hipotezu $h(x)$, koja je najbližija pravoj funkciji preslikavanja $X \rightarrow y$.



Osnovni pojmovi nadgledanog učenja - Parametri modela

- Parametri ponašanja su faktori ponašanja modela koje je sam algoritam učenja u stanju da optimizuje tokom procesa obučavanja (treniranja).
- Skup podataka na osnovu kojih se model optimizuje naziva se skup za obučavanje (*training set*).
- Kako znamo da li je model A bolji od modela B na određenom zadatku?
 - Evaluiramo modele A i B nad istim skupom podataka i izračunamo i uporedimo njihove performanse, izrađene pomoću odgovarajuće metrike.
 - Nad kojim skupom podataka je ispravno izvršiti evaluaciju? Da li smemo da koristimo u tu svrhu skup za obučavanje?




Razlika između regresije i klasifikacije

- Regresija:
 - Problem u kome model predviđa kontinuiranu vrednost (ceo ili realan broj).
 - Primer: predviđanje cene kuće ili automobila, temperature, troškova obrade kredita, i sl.
- Klasifikacija:
 - Problem u kome model dodeljuje ulazu kategoriju ili klasu.
 - Primer: neželjena (spam) ili željena pošta, prepoznavanje rukopisa, detekcija bolesti.
- Tipovi izlaza:
 - Regresija: realne, neograničene vrednosti (npr. 250.75 EUR).
 - Klasifikacija: diskretne kategorije ili klase (npr. 'imaCovid' ili 'nemaCovid').

Primeri problema klasifikacije

- Spam detekcija:
 - Ulazni podaci: sadržaj poruke, naslov poruke, pošiljalac, itd.
 - Cilj: klasifikovati poruka kao „spam“ ili „ne spam“.
- Identifikacija bolesti na osnovu krvne slike:
 - Ulazni podaci: leukociti, neutrofili, limfociti, trombociti, srednja zapremina trombocita, CRP, itd.
 - Cilj: klasifikovati da li je osoba pod upalom „Covid-19“ ili nije.
- Zašto su ovi problemi klasifikacije?
 - Model mora da odredi kojoj od unapred definisanih kategorija/klasa pripada ulazni podatak.



Primeri problema regresije

- Predikcija cene kuće na osnovu karakteristika:
 - Ulazni podaci: kvadratura, spratnost, broj soba, lokacija, starost objekta, veličina dvorišta, garaže, itd.
 - Cilj: predvideti tržišnu cenu kuće u određenoj valuti (dinar/EUR/USD).
- Procena plate zaposlenog:
 - Ulazni podaci: obrazovanje (diploma/univerzitet), godine iskustva, poznavanje tehnologija, broj kompanija ili projekata na/u kojima je radio/la.
 - Cilj: predvideti zaradu za novog zaposlenog, prema tržištu i njegovom/njenom znanju/iskustvu 😊
- Zašto su ovi problemi regresija?
 - Zato što model predviđa numeričku vrednost, koja može biti bilo koja realna brojčana vrednost.

Algoritmi klasifikacije za nadgledano učenje

- Logistička regresija (*Logistic Regression*)
- K-najbližih suseda (*K-Nearest Neighbors*)
- Stabla odlučivanja (*Decision Tree*)
- Slučajna šuma (*Random Forest*)
- SVM (*Support Vector Machines*)
- Naivni Bajes (*Naive Bayes*)
- Neuralne mreže (*Neural Networks*)


Algoritmi regresije za nadgledano učenje

- Linearni modeli
 - Linearna regresija (*Linear Regression*)
 - Regresija grebena (*Ridge Regression*)
 - Laso regresija (*Lasso and Multi-task Lasso Regression*)
 - Bajesovska grebena regresija (*Bayesian Ridge Regression*)
- Modeli zasnovani na stablima
 - Stabla odlučivanja (*Decision Tree Regressor*)
 - Slučajna šuma (*Random Forest Regressor*)
 - Pojačani gradijent (*Gradient Boosting Regressor*)
 - Visoko optimizovani pojačani gradijent (*XGBoost Regressor*)
- Mašine za podršku vektorima
 - SVR (*Support Vector Regression*)
- Drugi modeli:
 - Stohastička regresija gradijentnog spusta (*Stochastic Gradient Descent Regressor*)
 - Regresija jezgrastog grebena (*Kernel Ridge Regression*)
 - Neuralne mreže (*Neural Networks*)

Vizualizacija modela

- Granice odlučivanja za klasifikatore:
 - Prikazivanje granica koje razdvajaju različite klase u 2D prostoru.
 - Na primer, granica između spam i ne-spam, ili dve klase u dvodimenzionalnom prostoru.
- Pravci regresije:
 - Prikazivanje pravca ili krive koji najbolje odgovara podacima u regresionom problemu.
 - Na primer, linearni pravac koji predviđa cenu na osnovu dve karakteristike.
- Zašto je vizuelizacija važna?
 - Pomaže u razumevanju kako model funkcioniše.
 - Omogućava identifikaciju problema kao što su preobučavanje (*overfitting*) ili podobučavanje (*underfitting*).
 - Pomaže u komunikaciji rezultata ne-stručnim sagovornicima.

A Plot to Assess the Performance of the SVM Classifier in the Pancreatic Biomarker Dataset



Prilagođenost modela podacima - preobučavanje i podobučavanje


- Pri obučavanju modela važno je da se izbegne
 - Preterana prilagođenost modela podacima tzv. **preobučavanje** (*overfitting*):
 - Model je previše složen, nije u stanju da se ograniči na pravilnosti koje realno postoje u podacima, već ih uočava i uči i tamo gde ih realno nema, već su proizvod šumova i slučajnosti u podacima za treniranje, odnosno model se previše oslonio na date podatke za obučavanje.
 - Oblik usvojene hipoteze $h(x)$ je isuviše kompleksan u odnosu na stvarnu funkciju preslikavanja $X \rightarrow y$.
 - Rezultat: odlični rezultati na treningu, ali loši na testu.
 - Nedovoljna prilagođenost modela podacima, tzv. **podobučavanje** (*underfitting*):
 - Model je previše jednostavan da bi uhvatio pravilnosti u podacima koje realno postoje, tj. nije iskoristio podatke za obučavanje.
 - Oblik usvojene hipoteze $h(x)$ je isuviše jednostavan u odnosu na stvarnu funkciju preslikavanja $X \rightarrow y$.
 - Rezultat: loše na treningu i loše na testu.
- Pod šumom se podrazumevaju neželjene anomalije u podacima.
- Uzroci šuma: nepreciznosti u merenju, greške u unosu podataka, greške u anotaciji podataka, subjektivnost, itd.
- Model može da počne da se prilagođava šumu, tj. da uči šum => preterano prilagođen model.

Prilagođenost modela podacima - vizuelizacija

- Vizuelizacija:
 - Preterana prilagođenost / Preobučavanje - model koji previše prati podatke, složene krive koje gotovo dodiruju sve tačke.
 - Nedovoljna prilagođenost / Podobučavanje - model koji je previše jednostavan, npr. linearna linija koja ne prati podatke i ne hvata pravilnosti.
 - Zašto je važno da prepoznamo probleme?
Da bismo prilagodili složenost modela i postigli najbolju generalizaciju.
- Pronalaženje balansa između nedovoljne i preterane prilagođenosti modela podacima je poznato i kao problem kompromisa između pristrasnosti i varijanse (*bias/variance trade-off*).


Kompromis između pristrasnosti i varijanse

- Greške zbog sistematskog odstupanja / pristrasnost (*bias*) su posledica ograničene fleksibilnosti korišćenog modela mašinskog učenja
 - Nedostatak fleksibilnosti sprečava model da nauči da prepoznaje pravilnosti u podacima za obučavanje.
 - Ovakvi modeli su u proseku konzistentni, ali netačni.
- Greške zbog varijanse (*variance*) su posledica preterane osetljivosti korišćenog modela mašinskog učenja.
 - Prevelika osetljivost modela ga tera da pronalazi pravilnosti u sitnim, nebitnim varijacijama ulaznih podataka.
 - Ovakvi modeli su u proseku tačni, ali nekonzistentni.
- Složenost modela se povećava sa povećanjem broja parametara, što dovodi do preobučavanja modela, što u osnovi povećava varijansu i smanjuje pristrasnost.



Zašto nam treba kompromis?


- Algoritmi sa malo grešaka zbog varijanse (*low variance*) su oni koji su jednostavniji, ali su zbog jednostavnosti i rigidniji, te skloniji greškama zbog pristrasnosti (*bias*):
 - Parametarski modeli i Linearni modeli
 - Npr. Linearna regresija, Logistička regresija
- Algoritmi sa malo grešaka zbog pristrasnosti (*low bias*) su oni koji su fleksibilniji, ali su zbog fleksibilnosti i složeniji, te skloniji greškama zbog varijanse (*variance*):
 - Naparametarski modeli i Nelinearni modeli



Efekti nedovoljne i preterane prilagođenosti modela podacima


- Regresija

Visoka pristrasnost (*underfit*)




Size
 $\theta_0 + \theta_1 x$

Dobra prilagođenost



Size
 $\theta_0 + \theta_1 x + \theta_2 x^2$


Visoka varijansa (*overfit*)




Size
 $\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$

- Klasifikacija


Visoka
pristrasnost
(*underfit*)



$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$
(g = sigmoid function)



$g(\theta_0 + \theta_1 x_1 + \theta_2 x_2$
 $+ \theta_3 x_1^2 + \theta_4 x_2^2$
 $+ \theta_5 x_1 x_2)$



$g(\theta_0 + \theta_1 x_1 + \theta_2 x_1^2$
 $+ \theta_3 x_1^2 x_2 + \theta_4 x_1^2 x_2^2$
 $+ \theta_5 x_1^2 x_2^3 + \theta_6 x_1^3 x_2 + \dots)$


Visoka
varijansa
(*overfit*)

Evaluacija modela

Pronalaženje skrivenog znanja, *Univerzitet u Beogradu - Elektrotehnički fakultet*

Podela skupa: trening i test skup

- Zašto delimo podatke?
 - Da bismo procenili performanse modela na neviđenim podacima i izbegli pretranu prilagođenost / preobučavanje.
- Osnovna podela:
 - Trening skup - podaci na kojima treniramo model.
 - Test skup – podaci na kojima procenjujemo kako model radi na novim, nepoznatim podacima.
- Razlika: model se uči na trening skupu, a njegova validacija i evaluacija se vrše na test skupu.
- Ako bi se evaluacija radila nad istim podacima, složeniji/fleksibilniji model bi uvek bio bolji, jer je sposobniji da se prilagodi podacima od rigidnijeg modela
 - To znači da složeniji model bolje modelira šum, a ne željene pravilnosti.
- Da bi se dobila objektivna, nepristrasna procena performansi modela, evaluacija je neophodno sprovesti nad novi, do tog trenutka neditnutim skupom podataka.
- Npr. ako koristimo 80% podataka za trening i 20% za test (ili nekom drugom podelom %), to nam omogućava da proverimo koliko je model sposoban da generalizuje.



Stratifikacija

- Važno je da i podaci za obučavanje i podaci za testiranje budu odabrani iz iste opšte populacije podataka tj. da podaci iz oba skupa imaju slične karakteristike.
- **Stratifikacija** - pri podeli podataka na skup za obučavanje i skup za testiranje, obezbediti da oba skupa imaju istu raspodelu podataka.
- Ovo je dosta teško uraditi za složenije probleme te se koriste jednostavnija varijanta stratifikacije gde se obezbeđuje ista raspodela izlazne vrednosti y :
 - Klasifikacija - ista frekventnost svih klasa u oba skupa podataka;
 - Regresija - (približno) ista frekventnost svih izlaznih vrednosti u oba skupa podataka.
- Ako nije došlo do preterane prilagođenosti modela, performanse na skupu za testiranje su obično slične ili blago niže od onih na skupu za obučavanje.
- Ako je došlo do preterane prilagođenosti modela, performanse na skupu za testiranje su приметно lošije od onih na skupu za obučavanje.
 - Preterano prilagođen model ima veoma slabu sposobnost generalizacije.

Kako izbeći nedovoljnu prilagođenost modela?

- Odabrati dovoljno fleksibilan algoritam mašinskog učenja za zadati problem.
- Odabrati pogodne aspekte ulaznih podataka za njihove odlike/atribute koje se koriste pri obučavanju modela.
- Pružiti modelu dovoljan broj kvalitetno odabranih odlika.


Kako izbeći preteranu prilagođenost modela?

- Izbeći korišćenje nepotrebno složenih algoritama za posmatrani problem.
- Koristiti neki poseban metod za kontrolisanje složenosti modela (npr. regularizaciju, potkresivanje stabla odlučivanja, itd.)
- Povećati broj podataka u skupu za obučavanje.
- Eliminirati suvišne odlike modela (kod nekih algoritama nepotrebno).
- Ukoliko je obučavanje iterativan proces, zaustaviti ga u trenutku kada model počne da se preterano prilagođava
 - Da bi se ispravno procenilo u kom trenutku do ovoga dolazi, neophodno je pratiti performanse modela ne samo nad podacima za obučavanje, nego i još nekom skupu podataka - skupu za validaciju (ili validacioni skup).

Validacija modela


- Pod greškom modela nad nekim podacima (x, y) podrazumeva se odstupanje između izlaza modela za te podatke i njima pridruženih tačnih odgovora.
- Različiti algoritmi mašinskog učenja koriste različite oblike funkcije greške.
- Ako je obučavanje iterativan proces, prilikom obučavanja se greška modela nad podacima kontinualno smanjuje.
- Kod nekih drugih skupova podataka iste prirode, greška modela opada tokom obučavanja do nekog trenutka, a onda počinje da raste.

To je signal da je model ušao u zonu preterane prilagođenosti prema podacima za obučavanje.




Validacioni skup i testni skup

- Razlika između validacionog i testnog skupa:
 - validacioni skup - koristi se tokom procesa treniranja za podešavanje hiperparametara i izbor najboljeg modela;
 - testni skup - koristi se nakon što je model potpuno treniran i optimizovan, za konačnu evaluaciju performansi.
- Zašto su oba potrebna?
 - validacioni skup - pomaže u izboru i prilagođavanju modela bez uticaja na konačnu evaluaciju;
 - testni skup - daje nepristrasnu procenu kako će model raditi na novim podacima.
- Tipično se podaci dele na trening, validacioni i test skupu u odnosu 60% : 20% : 20% ili drugačije.
- Model se:
 - trenira na trening skupu,
 - podešava na validacionom skupu,
 - procenjuje na testnom skupu.



Validacioni skup

- Ako bi se skup za testiranje, koristio isto i kao validacioni skup, time bi on postao deo optimizacije modela.
- Evaluacija sprovedena nad tako upotrebljenim skupom za testiranje ne bi više bila objektivna i nepristrasna, a rezultati bi bili bolji od realnih.
- I za kreiranje validacionog skupa važno je koristiti stratifikovanu podelu.
- Validacioni skup se ponekad naziva i skupom za razvoj (*development set*).



Hiperparametri i njihova optimizacija


- Parametri modela - faktori ponašanja modela koje sam algoritam učenja optimizuje tokom procesa obučavanja.
- Pored parametara, ponašanje modela može zavisiti i od određenih faktora koje algoritam učenja nije u stanju da optimizuje. Takvi parametri se zovu hiperparametri modela.
- Vrednosti hiperparametara se moraju zadati ručno, pre početka obučavanja modela.
- Optimizacija hiperparametara se vrši istraživanjem različitih kombinacija njihovih vrednosti.
- Najjednostavniji pristup: pretraga po mreži (*grid search*) - sistemski se ispituje svaka moguća kombinacija vrednosti hiperparametara.
- Da bi evaluacija modela ostala nepristrasna, hiperparametri se moraju optimizovati pomoću validacije modela - usvaja se onaj skup hiperparametara koji na skupu za validaciju daje najbolje rezultate.
- Optimizacija vrednosti hiperparametara se naziva i odabirom modela (model selection), jer se odabirom njenih vrednosti vrši i odabir jedne određene vrste modela iz šire familije modela
 - npr. kvadratne funkcije iz familije polinomijalnih funkcija

Alternativna rešenja validacije modela


- Validacija modela pomoću odvojenog validacionog skupa ima dva nedostatka
 - Ovim pristupom se efektivno smanjuje količina podataka koje model koristi pri učenju. Samim tim, osim ako je umanjeni skup za obučavanje (treniranje) ionako izuzetno veliki, realno je očekivati nešto slabije performanse modela nego što bi bile pri obučavanju sa celokupnim skupom podataka za obučavanje.
 - Optimalni hiperparametri mogu da dosta variraju u zavisnosti od nasumične podele podataka na deo za obučavanje i deo za validaciju (što manje podataka je na raspolaganju, to je ovaj efekat приметniji!)
- Alternativno rešenje za validaciju modela je unakrsna validacija (*cross-validation*).

Unakrsna validacija

- Šta je k-fold unakrsna validacija (*cross-validation*)?
 - Metoda procene performansi modela, gde se skup podataka deli na **k** podskupova/slojeva (*foldova*).
 - Model se trenira na **k-1** podskupova, a evaluira na preostalom, i ovaj proces se ponavlja tako da svaki podskup bude jednom testni.
- Kako funkcioniše?
 - Podaci se ravnomerno dele na k delova. U svakoj iteraciji se vrši validacija na k-1 sloju/podskupu, a obučava se na svim ostalim slojevima zajedno.
 - Finalni rezultat: Prosečna performansa svih k iteracija, daje pouzdanu procenu modela.
- Zašto koristiti k-fold unakrsnu validaciju?
 - Omogućava da svaki podatak bude i trening i test primer, smanjujući pristrasnost procene.
 - Pomaže u izboru najboljih hiperparametara i modela.
- Najčešće se koristi stratifikovana unakrsna validacija, sa tipičnim vrednostima k=3, 5 ili 10 slojeva
 - Više slojeva – celokupan proces obučavanja traje duže; manja varijansa rezultata.
 - Manje slojeva – manji % podataka se koristi za obučavanje u svakom prolazu; veća varijansa rezultata.




Finalni rezultat unakrsne validacije




Unakrsna validacija za evaluaciju modela

- Postupak unakrsne validacije se može koristiti i za evaluaciju modela.
- Terminološka zabuna: treba razlikovati validaciju kao deo procesa optimizacije modela, od unakrsne validacije kao metode sprovedanja validacije i/ili evaluacije.
- Evaluacija pomoću izdvojenog skupa podataka za testiranje ima slične nedostatke kao i validacija pomoću izdvojenog skupa za validaciju.
 - Smanjivanje količine podataka koje model koristi pri očuvanju.
 - Velika varijansa dobijenih rezultata evaluacije, jer zavise od samo jedne nasumične podele početnog skupa na deo za obučavanje i deo za testiranje.
 - Što manje podataka je na raspolaganju, to je ovaj efekat приметniji.
- Unakrsnom validacijom se svi podaci koriste za evaluaciju, pa je procena performansi pouzdanija.



Ugnežđena unakrsna validacija

- Ukoliko je potrebna i validacija i evaluacija modela, onda se validacija sprovodi u ugnežđenoj unakrsnoj validaciji, dok se evaluacija modela sprovodi u spoljnoj.
- Svi slojevi za obučavanje u spoljnoj unakrsnoj validaciji se tretiraju kao jedan skup, koji se zatim deli na nove slojeve u ugnežđenoj unakrsnoj validaciji.
- Broj slojeva u spoljnoj i unutrašnjoj/ugnežđenoj unakrsnoj validaciji se može proizvoljno razlikovati
 - Neretko se za ugnežđenu unakrsnu validaciju koristi manji broj slojeva, zbog povećanja brzine obučavanja.



Matrica zabune (konfuzije)

- Matrica koja prikazuje performanse klasifikacionog modela, odnosno raspodelu podataka u zavisnosti od njihove stvarne klase i one u koju ih je model svrstao:
 - TP (*True Positives*): tačno pozitivni/ispravno klasifikovani podaci poziv. klase
 - TN (*True Negatives*): tačno negativni/ispravno klasifikovani podaci negat. klase
 - FP (*False Positives*): lažno pozitivni/podaci negativne klase koji su pogrešno klasifikovani u pozitivnu
 - FN (*False Negatives*): lažno negativni/podaci pozitivne klase koji su pogrešno klasifikovani u negativnu
- Ukoliko je model tačno identifikovao sve pozitivne primere, TP će biti visok, a FN nizak.
- Ako model često pogrešno označava negativne kao pozitivne, FP će biti visok.

Primer matrice zabune za neželjenu e-poštu

		Predicted	
		Spam	Non-spam
Actual	Spam	600 (True positive)	300 (False negative)
	Non-spam	100 (False positive)	9000 (True negative)

Zašto je važna matrica zabune?

- Omogućava detaljnu analizu gde model pravi greške i koje metrike treba poboljšati.

P

ce biti visok.

		Predicted Class		
		Positive	Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) Type II Error	Sensitivity $\frac{TP}{(TP + FN)}$
	Negative	False Positive (FP) Type I Error	True Negative (TN)	Specificity $\frac{TN}{(TN + FP)}$
		Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$

Primer matrice zabune za neželjenu poštu

n=192	Predicted: 0	Predicted: 1	
Actual: 0	TN = 118	FP = 12	130
Actual: 1	FN = 47	TP = 15	62
	165	27	

- TP (*True Positives*): tačno pozitivni / ispravno klasifikovani podaci poziv. Klase
- TN (*True Negatives*): tačno negativni / ispravno klasifikovani podaci negat. Klase
- FP (*False Positives*): lažno pozitivni / podaci negativne klase koji su pogrešno klasifikovani u pozitivnu
- FN (*False Negatives*): lažno negativni / podaci pozitivne klase koji su pogrešno klasifikovani u negativnu

Metrike za evaluaciju klasifikacije

■ Tačnost (*Accuracy*)

$$\text{Accuracy} = \frac{(TP + TN)}{(TP + FP + TN + FN)}$$

- Odnos broja tačno klasifikovanih primera i ukupnog broja primera.
- Koristi se kada su klase uravnotežene.
- Kada je više podataka jedne klase od druge, tačnost nije korisna.

■ Preciznost (*Precision*)

$$\text{Precision} = \frac{TP}{TP + FP}$$

- Odnos tačno klasifikovanih pozitivnih primera i svih koje je model označio kao pozitivne.
- Koristi se kada je važno minimizovati lažno pozitivne rezultate (npr. detekcija bolesti).

■ Odziv / Osetljivost (*Recall*)


$$\text{Recall} = \frac{TP}{TP + FN}$$

- Odnos tačno klasifikovanih pozitivnih primera i svih stvarnih pozitivnih primera.
- Koristi se kada je važno da se uhvati što više pravih pozitivnih (npr. detekcija kancera u medicini).


■ F mera/ F1 skor (*F-measure* / *F1-score*)

$$F_1 = 2 * \frac{\text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}}$$


- Harmonijska sredina između preciznosti i odziva, pruža balans između te dve metrike.
- Koristi se kada želimo da uravnotežimo preciznost i odziv, kod nebalansiranih skupova.




Low accuracy
Low precision



Low accuracy
High precision



High accuracy
Low precision



High accuracy
High precision

TP: Tačno pozitivan,
TN: Tačno negativan,
FP: Lažno pozitivan,
FN: Lažno negativan.

Primer izračunavanja metrika za merenje performansi u binarnoj klasifikaciji

		Actual class	
		Cat	Non-cat
Predicted class	Cat	5 True Positives	2 False Positives
	Non-cat	3 False Negatives	17 True Negatives

$$A = \frac{5 + 17}{5 + 17 + 2 + 3} = 0.815$$



$$P = \frac{5}{5 + 2} = 0.714$$

$$R = \frac{5}{5 + 3} = 0.625$$

$$F = \frac{2 \times 0.714 \times 0.625}{0.714 + 0.625} = 0.666$$

ROC kriva i AUC

- Šta je ROC kriva?
 - *Receiver Operating Characteristic* (ROC) kriva prikazuje odnos između Odziva / *Recall* (TPR) i FPR (*False Positive Rate*) za različite granice odlučivanja modela.
 - Na X-osi je $FPR = FP / (FP + TN)$, a na Y-osi je $TPR = TP / (TP + FN)$
- Kako izgleda ROC kriva?
 - Grafikon koji pokazuje kako se model ponaša pri različitim pragovima klasifikacije.
 - Viša kriva (bliža gornjem levom uglu) ukazuje na bolji model.
- AUC (*Area Under the Curve*) - površina ispod ROC krive
 - Vrednosti od 0.5 (nasumično predviđanje) do 1.0 (savršeni model).
 - Viša AUC znači da je bolji model.
- Ove grafičke predstave nam omogućuju da procenimo modelu u odnosu na sve moguće pragove odlučivanja.



Metrike za evaluaciju regresije

- Srednja apsolutna greška (*Mean Absolute Error, MAE*)
 - Prosečna apsolutna razlika između predviđenih i stvarnih vrednosti.
 - Jednostavno za interpretaciju, manje je osetljiv na velike greške od MSE.
- Srednja kvadratna greška (*Mean Squared Error, MSE*)
 - Prosečna kvadratna razlika između predviđenih i stvarnih vrednosti.
 - Veoma je osetljiv na velike greške (velike greške se više kažnjavaju).
- Koren srednje kvadratne greške (*Root Mean Squared Error, RMSE*)
 - Koren od MSE, vraća grešku u originalnim jedinicama. Lakše za interpretaciju od MSE.
- Koren relativne kvadratne greške (*Root Relative Squared Error, RRSE*)
- Relativna apsolutna greška (*Relative Absolute Error, RAE*)

$$RAE = \frac{\sum_{i=1}^m |h(x^{(i)}) - y^{(i)}|}{\sum_{i=1}^m |\bar{y} - y^{(i)}|}$$

$h(x^{(i)})$ - vrednost hipoteze za i
 $y^{(i)}$ - tačna izlazna vrednost za i
 m - broj podataka koji se koristi za testiranje

$$MAE = \frac{\sum_{i=1}^m |h(x^{(i)}) - y^{(i)}|}{m}$$

$$\frac{\sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2}{m}$$

$$RMSE = \sqrt{\frac{\sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2}{m}}$$

$$RRSE = \sqrt{\frac{\sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2}{\sum_{i=1}^m (\bar{y} - y^{(i)})^2}}$$

$\bar{y}$ - srednja vred. Izlazne promenljive u skupu za obučavanje

Metrike za evaluaciju regresije (2)

- Za sve navedene metrike važi da su niže vrednosti bolje
- RMSE i MAE
 - Izražavaju se u istim jedinicama kao izlazna promenljiva y .
 - Posebno korisni ako se zna kolika greška je prihvatljiva u posmatranom domenu.
- RRSE i RAE
 - Relativne metrike tako da nemaju jedinicu.
 - Pogodniji za poređenje performansi modela između više različitih domena.

Metrike za merenje performansi u višeklasnoj klasifikaciji

- Tačnost (odnos broja tačno klasifikovanih primera i ukupnog broja primera) se može koristiti i u višeklasnoj klasifikaciji, kada je skup podataka izbalansiran po klasama.
- Često se koriste mikro-uprosečene i makro-uprosečene vrednosti preciznosti, odziva i F-mere.
- **Mikro-uprosečavanje** je uprosečavanje po podacima, gde je k broj klasa:

$$P_{micro} = \frac{TP_1 + \dots + TP_k}{TP_1 + \dots + TP_k + FP_1 + \dots + FP_k}$$

$$R_{micro} = \frac{TP_1 + \dots + TP_k}{TP_1 + \dots + TP_k + FN_1 + \dots + FN_k} = P_{micro}$$

$$F_{micro} = \frac{2P_{micro}R_{micro}}{P_{micro} + R_{micro}} = P_{micro} = R_{micro} = A$$

Metrike za merenje performansi u višeklasnoj klasifikaciji (2)

- **Makro-uprosečavanje** je uprosečavanje binarnih vrednosti metrika po klasama:

$$P_{macro} = \frac{P_1 + \dots + P_k}{k} \quad R_{macro} = \frac{R_1 + \dots + R_k}{k}$$

$$F_{macro} = \frac{2P_{macro}R_{macro}}{P_{macro} + R_{macro}}$$

- Pored ove definicije, na nekim mestima se F_{macro} računa kao:

$$F_{macro} = \frac{F_1 + \dots + F_k}{k}$$

- Makro-uprosečavanje je pogodnije za nebalansirane skupove, jer daje podjednaku težinu svim klasama.

Primer izračunavanja za mikro-uprosečavanja

		Actual class		
		Cat	Dog	Rabbit
Predicted class	Cat	5	2	0
	Dog	3	3	2
	Rabbit	0	1	11

$$A = P_{micro} = R_{micro}$$

$$= \frac{5 + 3 + 11}{5 + 3 + 11 + 2 + 0 + 3 + 2 + 0 + 1}$$
$$= 0.7037$$

Primer izračunavanja za makro-uprosečavanja

		Actual class		
		Cat	Dog	Rabbit
Predicted class	Cat	5	2	0
	Dog	3	3	2
	Rabbit	0	1	11

$$P_{cat} = \frac{5}{5 + 2 + 0} = 0.714$$

$$R_{cat} = \frac{5}{5 + 3 + 0} = 0.625$$

$$P_{dog} = \frac{3}{3 + 3 + 2} = 0.375$$

$$R_{dog} = \frac{3}{2 + 3 + 1} = 0.5$$

$$P_{rabbit} = \frac{11}{0 + 1 + 11} = 0.917$$

$$R_{rabbit} = \frac{11}{0 + 2 + 11} = 0.846$$

$$P_{macro} = \frac{P_{cat} + P_{dog} + P_{rabbit}}{3} = 0.669$$

$$R_{macro} = \frac{R_{cat} + R_{dog} + R_{rabbit}}{3} = 0.657$$

$$F_{macro} = \frac{2P_{macro}R_{macro}}{P_{macro} + R_{macro}} = 0.663$$

Ili alternativno za F:

$$F_{macro} = \frac{F_{cat} + F_{dog} + F_{rabbit}}{3} = 0.658$$

Težinsko uprosečavanje

- Kod drugog navedenog načina makro-uprosečavanja F-mere moguće je da njena vrednost ne bude jednaka harmonijskoj sredini preciznosti i odziva.
- Pored mikro- i makro-uprosečavanja koristi se i težinsko uprosečavanje, gde se metrike za svaku klasu ponderišu težinama određenim zastupljenošću te klase u celom skupu podataka.
 - I u ovom pristupu, F-mera može da ne bude jednaka harmonijskoj sredini preciznosti i odziva.

Procena performansi kreiranog modela

- Da bi se adekvatno procenilo koliko je kreirani model dobar, on se mora uporediti sa nekim osnovnim (*baseline*) pristupom.
- U praksi se koriste različiti osnovni pristupi:
 - Klasifikacija
 - Odabir najfrekventnije klase - pristup koji svrstava svaki nov podatak u onu klasu koja se najčešće javlja u skupu za obučavanje.
 - Odabir nasumične klase - pristup koji nasumično svrstava svaki nov podatak u neku od k klasa.
 - Regresija
 - Za svaki nov podatak se kao izlaz predviđa srednja vrednost izlaza svih podataka iz skupa za obučavanje.
- Navođenje samo rezultata modela, bez ikakvog poređenja sa osnovnim pristupima nema smisla
 - Npr. tačnost od 90% na zadatku klasifikacije zvuči kao jako dobar rezultat.
 - Ali šta ako u posmatranom domenu 99% podataka pripada jednoj klasi?
 - Automatskim odabirom te klase dobiće se tačnost od 99%.
- Ispitivanje performansi osnovnih pristupa može pomoći i u zaključivanju da li je korišćena metrika za merenje performansi adekvatna ili ne.

Pitanja?

Hvala na pažnji.