

Probabilistički modeli

Pronalaženje skrivenog znanja, *Elektrotehnički fakultet Univerziteta u Beogradu*
Prof. dr Dražen Drašković

Probabilistički modeli



- Verovatnoća – prirodan okvir za modelovanje neizvesnosti
- Dizajn algoritama probabilističkih modela MU – definisanje raspodele verovatnoće koju je potrebno oceniti iz podataka. Pokušavamo da nađemo zavisnost promenljivih i formu raspodele.
- Uvodimo pretpostavke – npr. forma raspodele normalna, a struktura zavisnosti može biti izabraan da su vrednosti ciljnih promenljivih na različitim instancama nezavisna ili da je zavisnost definisana nekim grafom.
- Izbor pogrešnih pretpostavki utiče na performanse algoritma:
 - Ako pretpostavljena forma raspodele ne odgovara raspodeli podataka, predviđanja će biti lošija, ili će informacija o pouzdanosti koju model priža biti nekorektna.
 - Ukoliko se pretpostavi nezavisnost promenljivih, koje su zavisne, takođe je problematično.

Probabilistički modeli

- Linearna regresija
- Logistička regresija
- Multinomijalna logistička regresija
- Naivni Bajesov algoritam



Linearna regresija


Pronalaženje skrivenog znanja, *Univerzitet u Beogradu - Elektrotehnički fakultet*

Uvod u linearnu regresiju

- Najjednostavniji i najčešće korišćen model mašinskog učenja
- Osnovni tip regresije - predviđanje kontinualnih numeričkih vrednosti
- Prosta/jednostruka linearna regresija - postoji samo jedna ulazna promenljiva/odlika x
- Višestruka linearna regresija - postoji više ulaznih promenljivih/odlika $x_1, x_2, \dots x_n$
- Univarijantna linearna regresija - samo jedna izlazna promenljiva y
- Multivarijantna linearna regresija - više izlaznih promenljivih

Linearna regresija

- Linearna regresija pretpostavlja da zavisnost y od x ima oblik linearne kombinacije odlika (i njihovih težina)
- Dve glavne vrste upotrebe linearne regresije su:
 - Predviđanje vrednosti izlaza y za nove podatke na osnovu poznatih vrednosti tog izlaza sa starim podacima
 - Analiza stepena povezanosti između vrednosti izlaza y i vrednosti promenljivih $x_1, x_2, \dots, x_n$
- Široko korišćena i u prirodnim i u društvenim naukama



Jednostruka univarijantna linearna regresija

- Hipoteza jednodruke univarijantne linearne regresije: $h(x) = w_0 + w_1x$
- w_0, w_1 su težine – parametri modela (negde se označavaju sa θ_0, θ_1)
- Obučavanje modela predstavlja odabir optimalnih vrednosti parametara modela tako da $h(x)$ bude blisko stvarnom y za sve ulazne parove (x, y)
- Da bi se model obučio neophodno je odabrati funkciju cene / greške koja govori koliko hipoteza (sa trenutnim vrednostima parametara) odskake od stvarnih vrednosti y

Funkcija gubitka i funkcija greške

- **Funkcija gubitka** $L(h(x), y)$ (engl. *loss function*) definiše meru odstupanja vrednosti hipoteze $h(x)$ (za neko x , sa trenutnim vrednostima parametara težine w), od tačne vrednosti y na pojedinačnom podatku.
- **Funkcija greške/cene** $J(w)$ (engl. *error/cost function*) je prosek vrednosti funkcije gubitka na svim podacima iz posmatranog skupa:

$$J(w) = \frac{1}{m} \sum_{i=1}^m L(h(x^{(i)}), y^{(i)})$$

gde je m broj podataka u skupu.

- Obučavanje modela se svodi na odabir optimalnih vrednosti parametara modela $w_0, w_1, \dots, w_n$, tako da funkcija greške $J(w)$ bude minimalna za parove (x, y) iz skupa za obučavanje.

Funkcija greške kod linearne regresije

- Najčešća funkcija greške koristi prosek kvadrata odstupanja $h(x)$ od y (engl. *Mean Squared Error*, skr. *MSE*):

$$J(w) = \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2$$

- Moguće je pronaći minimum analitički - podrazumeva računanje inverznih matrica
 - Inverzija može biti preskupa i numerički nestabilna kada je broj atributa (odlika, engl. *features*) veliki, pa se češće koriste iterativne metode (npr. Gradijentni spust).
- Druge funkcije greške kod linearne regresije: MAE (*Mean Absolute Error*), *Huber Loss* (kombinacija MSE i MAE), *Log-Cosh Loss* (glatkija verzija MAE), R^2 skor (koeficijent determinacije).


Obučavanje u linearnoj regresiji

- Metoda gradijentnog spusta se koristi najčešće za obučavanje.
- Gradijentni spust je iterativni metod traženja minimuma funkcije. Zasniva se na korišćenju gradijenta – generalizacije izvoda na veći broj promenljivih.
- Gradijent je vektor čiji su elementi parcijalni izvod funkcije.

- Gradijent funkcije greške:

$$\nabla J(w) = \left(\frac{\partial J(w)}{\partial w_0}, \frac{\partial J(w)}{\partial w_1}, \dots, \frac{\partial J(w)}{\partial w_n} \right)$$

- Parametre $w_0, w_1, \dots, w_n$, treba menjati u smeru opadanja funkcije greške.



Gradijentni spust



- Izraz za ažuriranje težinskih vrednosti w :

$$w_i := w_i - \alpha \frac{\partial J(w)}{\partial w_i}$$

- α je pozitivan broj koji predstavlja brzinu učenja (engl. *learning rate*) - ona određuje koliko će se veliki skokovi niz gradijent praviti pri obučavanju.
- Brzina učenja mora biti pažljivo odabrana
 - Kada je α premalo učenje je veoma sporo, tj. ima veliki broj koraka. U zavisnosti od oblika funkcije greške, moguće je zaglavljivanje u lokalnim minimumima.
 - Kada je α preveliko optimizacija može da preskoči minimum ili čak i da divergira.

Gradijentni spust - primeri

Identify problem with gradient descent





or learning rate is too large

$$w_1 = w_1 + \alpha d_1$$

use a minus sign

$$w_1 = w_1 - \alpha d_1$$

Adjust learning rate



With a small enough α , $J(\vec{w}, b)$ should decrease on every iteration

Ažuriranje vrednosti parametara (primer jednostruke regresije)

- Obavezno treba ažurirati sve težinske vrednosti odjednom, na primer:


$$temp_0 := w_0 - \alpha \frac{\partial J(w)}{\partial w_0}$$

$$temp_1 := w_1 - \alpha \frac{\partial J(w)}{\partial w_1}$$

$$w_0 := temp_0$$

$$w_1 := temp_1$$

- U suprotnom, promena jednog parametra utiče na parcijalne izvode po drugim parametrima - više se ne vrši spust u smeru gradijenta.



Konvergencija

- Gradijentni spust može da konvergira i sa fiksnom vrednošću brzine učenja α : $w_i := w_i - \alpha \frac{\partial J(w)}{\partial w_i}$
- Kako se spust približava minimumu, vrednost parcijalnih izvoda se sama smanjuje, tako da automatski dolazi do konvergencije.
- Vrednost izvoda u minimumu je jednaka nuli, tako da se parametri w više ne menjaju kad dostignu optimalne vrednosti.
- Obučavanje se nekad obustavlja kada promene vrednosti parametara u jednom koraku postane manja od neke predefinisane vrednosti.
- Ako je brzina učenja dobro odabrana, gradijentni spust će uvek konvergirati ka globalnom minimumu
 - Funkcija greške $J(w)$ je kvadratna funkcija što znači da je konveksna, tj. ima samo jedan minimum koji je globalan
 - Broj koraka potrebnih za konvergenciju zavisi od konkretnog zadatka koji se rešava i može značajno da varira
- Kod automatske provere konvergencije: Za dovoljno malo α greška treba da se smanjuje u svakom koraku.

Obučavanje u jednostrukoj linearnoj regresiji pomoću gradijentnog spusta

- U jednostrukoj linearnoj regresiji imamo samo jednu ulaznu promenljivu x : $h_{\theta}(x) = \theta_0 + \theta_1 x$
- Koristimo MSE kao funkciju greške, a $1 / 2m$ stavljamo zbog jednostavnijeg izvoda.

$$J(w) = \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 = \frac{1}{2m} \sum_{i=1}^m (w_0 + w_1 x^{(i)} - y^{(i)})^2$$

$$\frac{\partial J(w)}{\partial w_0} = \frac{1}{m} \sum_{i=1}^m (w_0 + w_1 x^{(i)} - y^{(i)}) = \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})$$

$$\frac{\partial J(w)}{\partial w_1} = \frac{1}{m} \sum_{i=1}^m (w_0 + w_1 x^{(i)} - y^{(i)}) x^{(i)} = \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x^{(i)}$$

Obučavanje u jednostrukoj linearnoj regresiji pomoću gradijentnog spusta (2)

- Algoritam spusta ponavljati iterativno, do konvergenције

$$w_0 := w_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})$$

$$w_1 := w_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})x^{(i)}$$

- Ovakav režim obučavanja se naziva grupni gradijentni spust (engl. *batch gradient descent*), jer se u svakom koraku spusta koristi svih m podataka iz celog skupa za obučavanje.
- Ako je predikcija veća od stvarnog y , gradijent će biti pozitivan => smanjujemo parametar.
- Ako je predikcija manja, gradijent je negativan => povećavamo parametar.
- Iteracijom kroz podatke, linija se postepeno prilagođava tačkama.

Stohastički gradijentni spust

- **Stohastički gradijentni spust** (engl. *Stochastic Gradient Descent*) je varijanta gradijentnog spusta u kojoj se **parametri ažuriraju nakon svakog pojedinačnog primera iz skupa podataka**, umesto nakon celog skupa (kao u grupnom gradijentnom spustu).

randomly shuffle the data

for $i = 1$ to m :

$$w_0 := w_0 - \alpha \frac{1}{m} (h(x^{(i)}) - y^{(i)})$$

$$w_1 := w_1 - \alpha \frac{1}{m} (h(x^{(i)}) - y^{(i)})x^{(i)}$$

Grupni i stohastički gradijentni spust

- **Grupni gradijentni spust** mora da prođe kroz ceo skup podataka za obučavanje da bi napravio jedan korak, što može biti skupa operacija, ako je skup podataka m veliki.
- **Stohastički gradijentni spust** može da krene sa minimizacijom funkcije greške na osnovu samo jednog podatka. Stohastički spust se često približi minimumu znatno brže nego grupni.
- Stohastički spust ima veću varijansu nego grupni, jer je svaki gradijent nešto drugačiji.
 - Veća varijansa usporava konvergenciju.
 - Zahteva da brzina učenja α vremenom opada.
 - Može se desiti da stohastički spust nikada ne konvergira sasvim, već da vrednost w blago osciluje oko minimuma. To uglavnom nije problem, jer su vrednosti oko minimuma obično dovoljno dobre.
- Zbog efikasnosti se kod velikih skupova podataka preferira stohastički spust.
- Stohastički spust je pogodan za onlajn obučavanje – situacije kada novi podaci pristižu sekvencijalno.
- Kao kompromis se često koristi obučavanje na manjim podskupovima podataka (*mini-batch GD*) – koristi male grupe primera (npr. 32 ili 64 primera) u svakom koraku.

Višestruka univarijantna linearna regresija

- Hipoteza višestruke univarijantne linearne regresije:

$$h(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$$

- $w_0, w_1, \dots, w_n$ su težine – parametri modela.
- $x_0, x_1, \dots, x_n$ su odlike koje se koriste u modelu.
- Funkcija greške sada ima oblik:

$$J(w) = \frac{1}{2m} \sum_{i=1}^m \left(w_0 + w_1x_1^{(i)} + w_2x_2^{(i)} + \dots + w_nx_n^{(i)} - y^{(i)} \right)^2$$

Obučavanje u višestrukoj linearnoj regresiji pomoću grupnog gradijentnog spusta

- Algoritam spusta – ponavljati do konvergencije:

$$\frac{\partial J(w)}{\partial w_0} = \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})$$

$$\frac{\partial J(w)}{\partial w_1} = \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})x_1^{(i)}$$

$$\frac{\partial J(w)}{\partial w_2} = \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})x_2^{(i)}$$

⋮

$$w_0 := w_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})$$

$$w_1 := w_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})x_1^{(i)}$$

$$w_2 := w_2 - \alpha \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})x_2^{(i)}$$

⋮

Obučavanje u višestrukoj linearnoj regresiji pomoću stohastičkog gradijentnog spusta

- Algoritam spusta – ponavljati do konvergencije:

randomly shuffle the data

for $i = 1$ to m :

$$w_0 := w_0 - \alpha \frac{1}{m} (h(x^{(i)}) - y^{(i)})$$

$$w_1 := w_1 - \alpha \frac{1}{m} (h(x^{(i)}) - y^{(i)}) x_1^{(i)}$$

$$w_2 := w_2 - \alpha \frac{1}{m} (h(x^{(i)}) - y^{(i)}) x_2^{(i)}$$

$\vdots$

Skaliranje vrednosti odlika

- U grupnom gradijentnom spustu težinske vrednosti se ažuriraju:

$$w_r := w_r - \alpha \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_r^{(i)}$$

- a u stohastičkom:

$$w_r := w_r - \alpha \frac{1}{m} (h(x^{(i)}) - y^{(i)}) x_r^{(i)}$$

- Brzina učenja α je ista za sve težinske parametre, pa mora da se bira prema onom parametru gde je magnituda vrednosti odlike najveća (da bi se sprečila divergencija).
 - Veliki broj koraka u gradijentnom spustu i puno cik-cak kretanja, pošto neki težinski parametri konvergiraju brže od drugih.

Skaliranje vrednosti odlika (2)

- Gradijentni spust brže konvergira kada se vrednosti svih odlika nalaze u sličnim opsezima
 - Put od minimuma je brži i direktniji tj. ima manje cik-cak kretanja.
- Skaliranje vrednosti odlika se obično radi tako da vrednosti budu u opsegu: $-1 \leq x \leq 1$
- Moguće je da se skaliranje vrši tako da srednja vrednost odlike bude jednaka nuli.
- Nije neophodno da vrednosti svih odlika budu u apsolutno identičnim opsezima – manja odstupanja neće znatno uticati na brzinu spusta.
- Primer:
 - x_1 : veličina kuće u m^2 (0 – 2000 m^2) $x_1 = \text{veličina}(m^2) / 2000$
 - x_2 : broj spavaćih soba (0 – 8) $x_2 = \text{broj_sp_soba} / 8$


Polinomijalna regresija

- Moguće je stepenovati vrednosti odlika - time se dobija polinomijalna regresija.
- Jednostruka polinomijalna regresija: $h(x) = w_0 + w_1x + w_2x^2$
- Moguće je kombinovati odlike, čime se dobija višestruka polinomijalna regresija:


$$h(x) = w_0 + w_1x_1 + w_2x_2 + w_3x_1x_2 + w_4x_1^2 + w_5x_2^2$$

- Skaliranje vrednosti odlika je naročito važno kod višestruke polinomijalne regresije.
- Polinomijalni modeli višeg stepena mogu zbog veće složenosti lako postati preterano prilagođeni podacima nad kojima se obučavaju.
- Polinomijalni modeli su uglavnom dosta loši izvan opsega podataka korišćenih pri obučavanju - polinomijalne funkcije imaju "repove".
 - To ih čini veoma lošim za ekstrapolaciju.
- Iako je regresija sada nelinearna, model je i dalje linearan, jer predstavlja linearnu kombinaciju parametara.


Ponašanje jednostruke linearne i polinomijalne regresije



High bias
(underfit)



"Just right"



High variance
(overfit)

Regularizacija


- Regularizacije je način sprečavanja preterane prilagođenosti modela podacima (engl. *overfitting*) penalizovanjem izuzetno velikih magnituda nekih parametara w
 - Jako velike magnitude nekih parametara w nastaju kao posledica pokušaja modela da prilagodi oblik funkcije izlaza šumu i izuzecima u podacima za obučavanje (radi smanjenja funkcije greške).
 - Takvi modeli se u određenim situacijama (tj. za određene vrednosti ulaznog podatka) efektivno rukovode samo malim brojem odlika (ili njihovih kombinacija) koje imaju velike magnitude w .
- Pod regularizacijom se podrazumeva bilo koji postupak koji za cilj ima smanjenje greške generalizacije (tj. greške nad novim podacima / skupom za testiranje), a da se pritom ne poveća greška nad skupom za obučavanje.

Regularizacija - primer

- Primer - predikcija cene akcija na berzi:
- Preterano prilagođen model će možda zaključiti da su uprkos opštim trendovima kretanja cene akcija, akcije kompanije Apple skočile u određenom trenutku, zato što akcije firmi koje imaju kapitalizaciju veću od 105 milijardi \$ (USD) i prethodnu cenu akcijua manju od \$145 rastu tačno 165. dana u godini.
- Model verovatno ne može da zbog ovog neuobičajenog primera menja vrednosti težinskih parametara za odlike/kombinacije odlika koje realno jesu prediktivne, jer će time povećati grešku na svim ostalim podacima.
- Ta veoma specifična kombinacija odlika najverovatnije nema uticaja ni na jedan drugi podatak u skupu za obučavanje, a omogućava modelu da tačno pogodi cenu akcija kompanije Apple u posmatranom trenutku. Zato će model u kombinaciji odlika dati veliku težinu.

Primer javljanja velikih magnituda težinskih parametara kod preterano prilagođenih modela

- Nastaviti sekvencu: 1, 3, 5, 7, ...



- 217341

- Kako smo dobili?

$$f(x) := \frac{18111}{2} x^4 - 90555 x^3 + \frac{633885}{2} x^2 - 452773 x + 217331$$

$$f(1) = 1$$


$$f(2) = 3$$

$$f(3) = 5$$

$$f(4) = 7$$

$$f(5) = 217341$$

Primer



Regularizacija

- Kod preterano prilagođenih modela, funkcija izlaza je veoma vijugava (i samim tim kompleksna) iz nastojanja da se greška na skupu za obučavanje smanji koliko god to fleksibilnost modela dozvoljava.
 - To je posledica postojanja šuma u podacima za obučavanje i/ili nedovoljno podataka.
- Regularizacija je dobila ime po tome što joj je cilj da funkciju izlaza učini regularnijom, tj. pravilnijom, čime se sprečava preterana prilagođenost modela.
- Model se regularizuje tako što se u funkciju greške ubacuje regularizacioni izraz $\lambda R(w)$, čime se forsiraju manje magnitude w
 - λ - hiperparametar modela koji određuje jačinu regularizacije;
 - $R(w)$ - regularizaciona funkcija.

Regularizacija (2)

- Regularizacija smanjuje nelinearnost modela (ako je ima).
- Vrednost hiperparametra λ se obično određuje eksperimentalno, korišćenjem unakrsne validacije
 - Ukoliko se unakrsna validacija koristi i za evaluaciju modela, neophodno je primeniti ugneždenu unakrsnu validaciju za izbor hiperparametra λ .
 - Previše mala vrednost λ - regularizacija neće imati (dovoljnog) efekta.
 - Previše velika vrednost λ :
 - Dovodi do nedovoljne prilagođenosti modela podacima (engl. *underfitting*).
 - Gradijenti spust neće uspeti da konvergira.
- Pošto vrednosti w zavise i od vrednosti odlika, obično se pre regularizacije sprovodi skaliranje vrednosti odlika.

Vrste regularizacije

- Regularizaciona funkcija $R(w)$ je p-norma vektora parametara w (pri čemu se samostalni član w_0 obično izuzima):

$$\|w\|_p = \sqrt[p]{\sum_{j=1}^n |w_j|^p}$$

- U čestoj upotrebi su:

- L_2 / Tihonovljeva regularizacija

- „Gura“ težine ka malim vrednostima (blizu nule).
 - Retko postavlja parametre tačno na nulu – svi atributi ostaju u modelu.
 - Korisno je kada svi atributi doprinose (nema potrebe za selekcijom).
 - Rešenje je analitički moguće – stabilna optimizacija.

$$R(w) = \|w\|_2^2 = \sum_{j=1}^n |w_j|^2 = \sum_{j=1}^n w_j^2$$

- L_1 regularizacija

- „Gura“ mnoge težine tačno na nulu – radi selekciju atributa.
 - Dobar izbor kada verujemo da su samo neki atributi zaista bitni.
 - Optimizacija je složenija.

$$R(w) = \|w\|_1 = \sum_{j=1}^n |w_j|$$

Greben a regresija (sa regularizacijom L_2)

- **Greben a regresija** (engl. *ridge*) - linearna regresija sa L_2 regularizacijom.

- Funkcija greške kod grebene regresije je:

$$J(w) = \frac{1}{2m} \left(\sum_{i=1}^m \left(w_0 + w_1 x_1^{(i)} + \dots + w_n x_n^{(i)} - y^{(i)} \right)^2 + \lambda \sum_{j=1}^n w_j^2 \right)$$

- Parcijalni izvodi kod grebene regresije imaju oblik:

$$\frac{\partial J(w)}{\partial w_r} = \frac{1}{m} \left(\sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_r^{(i)} + \lambda w_r \right)$$



- Parametri w se u greben o j regresiji ažuriraju na sledeći način:

$$w_r := w_r - \alpha \frac{1}{m} \left(\sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_r^{(i)} + \lambda w_r \right) = w_r \left(1 - \alpha \frac{\lambda}{m} \right) - \alpha \frac{1}{m} \left(\sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_r^{(i)} \right)$$

- Pošto regularizacija obično ne obuhvata w_0 , pravilo ažuriranja za w_0 ostaje isto kao u neregularizovanoj regresiji.

Greben regresija

- Ako postoji visoka korelisanost između odlika, funkcija cene neregularizovane linearne regresije nema jedinstven minimum, već "greben" minimalnih vrednosti
 - To čini model nestabilnim - male promene u ulaznim podacima dovode do velikih promena u vrednostima težinskih parametara.
 - Ova nestabilnost otežava interpretaciju parametara.
- L_2 regularizacija zamenjuje greben jedinstvenim minimumom.
- Ilustracija efekta uvođenja L_2 regularizacije →



LASSO regresija

- LASSO (*Least Absolute Shrinkage and Selection Operator*) regresija je termin koji se koristi za linearnu regresiju sa L_1 regularizacijom.

- Funkcija greške kod LASSO regresije je:

$$J(w) = \frac{1}{2m} \left(\sum_{i=1}^m \left(w_0 + w_1 x_1^{(i)} + \dots + w_n x_n^{(i)} - y^{(i)} \right)^2 + \lambda \sum_{j=1}^n |w_j| \right)$$





- L_1 regularizator nije diferencijabilan zbog apsolutne vrednosti.
- Za ažuriranje vrednosti w koriste se napredniji mehanizmi optimizacije, kao što su subgradijentne metode
 - Koorinatni spust (engl. *Coordinate Descent*) - jedna od najčešćih metoda za LASSO.
 - Proksimalne metode (engl. *Proximal Gradient Descent*) - moderne i brze metode koje se koriste u praksi.

LASSO regresija (nastavak)


- L_1 regularizacija uz dovoljno veliku vrednost λ forsira određene težinske vrednosti w da postanu jednake nuli:
 - Time se stvaraju proređeni modeli (engl. *sparse models*) zato što se odlike čije su težine jednake nuli efektivno ignorišu.
 - Kako se vrednost λ povećava, raste i broj težinskih vrednosti postavljenih na nulu.
- Ovo je korisno kada je potrebno istovremeno sprovesti i regularizaciju i selekciju odlika.
 - Može biti dobro kada u modelu postoji ogroman broj odlika.

Oblici funkcija


- Na slici je dat oblik funkcije L_1 regularizacije i njenog izvoda.
- Na slici je dat oblik funkcije L_2 regularizacije i njenog izvoda.



Promena vrednosti w pri gradijentnom spustu kod L_1 regularizacije



Promena vrednosti w pri gradientnom spustu kod L_2 regularizacije



L_1 i L_2 regularizacija

- Minimizacija vrednosti w
 - L_1 regularizacija dovodi da neki parametri postanu jednaki nuli.
 - Vršiti selekciju odlika.
 - Povećava interpretabilnost modela.
 - L_2 regularizacija nema ovu osobinu, pa ne može da se koristi za selekciju odlika.
 - Teorijski je moguće da neki parametar postane jednak 0 za određenu vrednost brzina učenja α , ili kao posledica smanjenja funkcije greške.
- Broj odlika koje utiču na izlaz:
 - Mali broj odlika koje imaju veliki uticaj - L_1 regularizacija.
 - Veliki broj odlika koje imaju međusobno uravnotežen uticaj - L_2 regularizacija.
- L_1 regularizacija je manje stabilna od L_2 .
 - Male promene u podacima za obučavanje mogu dovesti do veliki promena modela, kada se koristi L_1 .
 - L_2 regularizovani modeli su otporniji na ove efekte.
- L_2 regularizacija može da bude brža za izračunavanje.
- Izbor napraviti pomoću unakrsne validacije, na konkretnom skupu podataka.

Prednosti i mane linearne regresije

▪ Prednosti

- Jednostavnost - lagan za implementaciju, brzo se trenira.
- Interpretabilnost - veća težina dodeljena odlici signalizira njenu veću važnost (lako se razumeju odlike).
 - Treba biti oprezan - interpretabilnost je znatno otežana ako postoji međusobna zavisnost između odlika.
- Efikasnost - računski jeftina (osim ako broj odlika nije ekstremno veliki).
- Dobra baza - služi kao polazni model (baseline) za poređenje sa složenijim modelima.
- Dobro radi ako je stvarna relacija približno linearna ili linearizovana transformacijom odlika.

▪ Mane

- Nelinearnost realnih procesa - većina realnih odnosa nije linearna.
- Osetljivost na anomalije (*outliers*) - ekstremne vrednosti snažno utiču na koeficijente.
- Pretpostavke modela - zahteva linearnu zavisnost, normalnost greške, konstantnu varijansu, nezavisnost podataka. Ako pretpostavke nisu zadovoljene, rezultati mogu biti pogrešni.
- Multikolinearnost - ako su odlike međusobno jake korelisane, koeficijenti postaju nestabilni.
- Slaba reprezentativnost kod visoko-dimenzionalnih podataka (ako nema regularizacije).



Logistička regresija

Pronalaženje skrivenog znanja, *Univerzitet u Beogradu - Elektrotehnički fakultet*

Korišćenje linearne regresije za klasifikaciju?

- Pretpostavka - rešavamo problem binarne klasifikacije.
- Izlazna vrednost y može biti 0 ili 1.
- Pitanje - da li se linearna regresija može koristiti u ovakvoj situaciji?
- Odgovor - može, klasa se predviđa tako što se proverava: $h(x) \geq 0.5$
 - Ako je nejednakost tačna, predviđa se klasa 1.
 - Ako je nejednakost netačna, predviđa se klasa 0.
- Problemi
 - Anomalije mogu da dramatično poremete kvalitet predikcije.
 - $h(x)$ može biti dramatično veće od 1 ili manje od 0.

Primer klasifikacije maligniteta tumora pomoću linearne regresije



Logistička regresija

- Jedan od najpopularnijih **algoritama klasifikacije**, nije regresija! (iz istorijskih razloga se zove)
- Osnovna verzija algoritma služi za binarnu klasifikaciju, tj. ciljnu promenljivu **diskretnu**.
 - Najčešće se jedna klasa označava sa $y=1$, a druga sa $y=0$.
- Predstavio ga statističar Dejvid Koks 1958. godine.
- Široko rasprostranjena u ekonomskom, sociološkim i medicinskim analizama.
- Sastavni element mnogih arhitektura neuralnih mreža.
- Probabilistički klasifikator - izlaz modela je $P(y|x)$, a ne samo klasifikaciona odluka.
- Pošto direktno modeluje $P(y|x)$, logistička regresija spada u diskriminativne modele.
- Za razliku od Naivnog Bajesovog klasifikatora (*Naïve Bayes*), logistička regresija ne pretpostavlja statističku nezavisnost odlika.

Logistička regresija

- Ime dobila po logističkoj / sigmoidnoj funkciji koja se koristi u hipotezi i ima oblik:

$$g(z) = \frac{1}{1 + e^{-z}}$$

- Pošto linearna kombinacija može imati vrednost $(-\infty, +\infty)$ koristi se **logistička (sigmoidna) funkcija** da se rezultat prebaci u interval $[0, 1]$.
- Hipoteza logističke regresije je:


$$h(x) = \frac{1}{1 + e^{-(w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n)}}$$

- gde je n broj odlika koje se koriste u modelu.
- $h(x)$ predstavlja **verovatnoću da je izlaz $y = 1$** .
- Odluka se donosi poređenjem sa pragom (tipično 0.5):

$$\hat{y} = \begin{cases} 1 & \text{ako } h(x) \geq 0.5 \\ 0 & \text{ako } h(x) < 0.5 \end{cases}$$

Linearna i logistička regresija

- Razlike u izgledu funkcija



Hipoteza logističke regresije

- Zbog kraće notacije obično se uvodi fiktivna odlika $x_0 = 1$, tako da hipoteza postaje:

$$h(x) = \frac{1}{1 + e^{-(w_0x_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n)}} = \frac{1}{1 + e^{-\sum_{i=0}^n w_i x_i}} = \frac{1}{1 + e^{-W \cdot X}} = \frac{e^{W \cdot X}}{e^{W \cdot X} + 1} = \frac{e^{W^T X}}{e^{W^T X} + 1}$$

- gde je W vektor svih težinskih parametara, X vektor svih vrednosti odlika, a $W \cdot X = W^T \cdot X$ njihov skalarni proizvod.

- Vrednost $h(x)$ predstavlja verovatnoću da je $y = 1$: $P(y = 1|x) = h(x) = \frac{e^{W^T X}}{e^{W^T X} + 1}$

- Verovatnoća za klasu $y = 0$ se dobija kao:

$$P(y = 0|x) = 1 - P(y = 1|x) = 1 - h(x) = 1 - \frac{e^{W^T X}}{e^{W^T X} + 1} = \frac{1}{e^{W^T X} + 1}$$

- Nov podatak se klasifikuje u klasu koja je za njega verovatnija.
- To znači da se podatak klasifikuje u klasu $y = 1$ za $h(x) > 0.5$, a u klasu $y = 0$ za $h(x) < 0.5$.

Hiperravan razdvajanja

- Granica razdvajanja između klasa $y = 1$ i $y = 0$ je na $h(x) = 0.5$.
- Sledi da za granicu razdvajanja važi:

$$h(x) = \frac{e^{W^T X}}{e^{W^T X} + 1} = 0.5$$

$$e^{W^T X} = 1$$

$$W^T X = W \cdot X = 0$$


$$\sum_{i=0}^n w_i x_i = 0$$

Kako nalazimo hiperravan razdvajanja?


- Jednačina $\sum_{i=0}^n w_i x_i = 0$ definiše hiperravan razdvajana klasa (engl. *separating hyperplane*).
- U slučaju samo jedne ulazne promenljive x , hiperravan je zapravo prava: $w_0 + w_1 x = 0$
- U opštem slučaju, hiperravan u prostoru dimenzije $n+1$ je potprostor dimenzije n .
- Sve tačke sa jedne strane hiperravni razdvajanja će biti klasifikovane u jednu klasu, a sve tačke sa druge strane u drugu klasu.
- Što je neka tačka udaljenija od hiperravni razdvajanja, to je već verovatnoća da ona pripada klasi koja se nalazi sa te strane hiperravni.
- Za tačke na samoj hiperravni razdvajanja se uzima da pripadaju jednoj od klasa, obično $y=1$.

Izgled hiperravni razdvajanja

A hyperplane in $\mathbb{R}^2$ is a line



A hyperplane in $\mathbb{R}^3$ is a plane



A hyperplane in $\mathbb{R}^n$ is an $n-1$ dimensional subspace

Nelinearne granice razdvajanja

- Hiperravan razdvajanja predstavlja linearnu granicu razdvajanja.
- Korišćenjem polinomijalnih izraza kao argumenta logističke funkcije dobijaju se nelinearne granice razdvajanja.

- Na primer, ako je hipoteza oblika: $h(x) = \frac{e^{x_1^2+x_2^2-1}}{e^{x_1^2+x_2^2-1} + 1}$

- tada je $y=1$ za: $\frac{e^{x_1^2+x_2^2-1}}{e^{x_1^2+x_2^2-1} + 1} \geq 0.5$


- Dalje sledi:

$$e^{x_1^2+x_2^2-1} \geq 1$$

$$x_1^2 + x_2^2 - 1 \geq 0$$


$$x_1^2 + x_2^2 \geq 1$$

- Za navedeni oblik hipoteze, granica razdvajanja ima oblik kruga poluprečnika 1.



Funkcija greške logističke regresije

- Potrebno je izabrati odgovarajuću funkciju greške, tako da ona bude konveksna.
- Da bi funkcija greške bila konveksna, funkcija gubitka mora da bude konveksna.
- Kvadrat odstupanja $h(x)$ od y nije pogodna funkcija gubitka za logističku regresiju, jer je zbog logističke funkcije u okviru hipoteze takva funkcija gubitka nekonveksna.
- Primer izgleda kvadratne funkcije gubitka u logističkoj regresiji →




Funkcija gubitka logističke regresije

- Pored konveksnosti, funkcija gubitka za logističku regresiju bi trebalo da ispoljava sledeće ponašanje:
 - Kada je $y=1$ potrebno je da greška bude velika kada je vrednost $h(x)$ blizu nuli, a mala kada je vrednost $h(x)$ blizu jedinici.
 - Kada je $y=0$ potrebno je da greška bude velika kada je vrednost $h(x)$ blizu jedinici, a mala kada je vrednost $h(x)$ blizu nuli.
- Sledeća funkcija ispunjava tražene uslove:

$$L(h(x), y) = -\ln(P(y|x)) = \begin{cases} -\ln(P(y = 1|x)) = -\ln(h(x)), & y = 1 \\ -\ln(P(y = 0|x)) = -\ln(1 - h(x)), & y = 0 \end{cases}$$

Oblik funkcije gubitka logističke regresije



Funkcija gubitka / gubitak unakrsne entropije

- Navedena funkcija gubitka se može zapisati kao: $L(h(x), y) = -y \ln h(x) - (1-y) \ln(1-h(x))$
- Ova funkcija gubitka se naziva logističkim (log) gubitkom (engl. *logistic / log loss*) ili gubitkom unakrsne entropije (engl. *cross-entropy loss*).


- Unakrsna entropija između dve raspodele p i q se definiše kao: $H(p, q) = -\sum_i p_i \ln q_i$

- Ako se raspodele p i q definišu kao:

$$p \in \{y, 1 - y\} \quad q \in \{h(x), 1 - h(x)\}$$

$$H(p, q) = -y \ln(h(x)) - (1 - y) \ln(1 - h(x))$$

- Na slici je dat primer izgleda logističke funkcije gubitka u logističkoj regresiji.



Funkcija greške i gradijentni spust

- Funkcija greške ima oblik: $J(w) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} \ln h(x^{(i)}) + (1 - y^{(i)}) \ln(1 - h(x^{(i)}))$
- Cilj obučavanja se opet svodi na traženje minimuma funkcije greške $J(w)$ u zavisnosti od w putem gradijentnog spusta.
- Izraz za ažuriranje težinskih faktora w pri gradijentnom spustu: $w_r := w_r - \alpha \frac{\partial J(w)}{\partial w_r}$
- Da bi se pronašao parcijalni izvod funkcije $J(w)$ potrebno je prvo pronaći parcijalne izvode logističke funkcije g i hipoteze h .
- Parcijalni izvod logističke funkcije $g(z) = \frac{1}{1 + e^{-z}}$

$$\begin{aligned} \frac{\partial g(z)}{\partial z} &= -\frac{1}{(1 + e^{-z})^2} \frac{\partial}{\partial z} (1 + e^{-z}) = \frac{e^{-z}}{(1 + e^{-z})^2} = \frac{1}{1 + e^{-z}} \frac{e^{-z}}{1 + e^{-z}} \\ &= g(z) \frac{(1 + e^{-z}) - 1}{1 + e^{-z}} = g(z) \left(1 - \frac{1}{1 + e^{-z}} \right) = g(z)(1 - g(z)) \end{aligned}$$

Parcijalni izvod hipoteze $h(x)$

$$h(x) = g\left(\sum_{i=0}^n w_i x_i\right) = \frac{1}{1 + e^{-\sum_{i=0}^n w_i x_i}}$$

$$\frac{\partial h(x)}{\partial w_r} = \frac{\partial g(\sum_{i=0}^n w_i x_i)}{\partial w_r}$$

$$= g\left(\sum_{i=0}^n w_i x_i\right) \left(1 - g\left(\sum_{i=0}^n w_i x_i\right)\right) \frac{\partial}{\partial w_r} \sum_{i=0}^n w_i x_i$$

$$= h(x)(1 - h(x))x_r$$

Parcijalni izvod funkcije greške

$$J(w) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} \ln h(x^{(i)}) + (1 - y^{(i)}) \ln (1 - h(x^{(i)}))$$

$$\frac{\partial J(w)}{\partial w_r} = -\frac{1}{m} \sum_{i=1}^m y^{(i)} \frac{1}{h(x^{(i)})} \frac{\partial h(x^{(i)})}{\partial w_r} + (1 - y^{(i)}) \frac{1}{1 - h(x^{(i)})} \frac{\partial}{\partial w_r} (1 - h(x^{(i)}))$$

$$= -\frac{1}{m} \sum_{i=1}^m y^{(i)} (1 - h(x^{(i)})) x_r^{(i)} - (1 - y^{(i)}) h(x^{(i)}) x_r^{(i)}$$

$$= \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_r^{(i)}$$

Obučavanje putem gradijentnog spusta

- Postupak izgleda identično kao kod linearne regresije.

- Simultano ažurirati sve w_k i ponavljati do konvergencije.

- Algoritam grupnog gradijentnog spusta: $w_r := w_r - \alpha \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_r^{(i)}$

- Algoritam stohastičkog gradijentnog spusta:

randomly shuffle the data

for $i = 1$ to m :

$$w_r := w_r - \alpha \frac{1}{m} (h(x^{(i)}) - y^{(i)}) x_r^{(i)}$$

Metode optimizacije funkcije gubitka


- Radi ubrzana gradijentnog spusta u praksi se često koriste naprednije metode optimizacije:
 - **Konjugovani spust** - efikasniji od običnog gradijentnog spusta za kvadratne funkcije (npr. linearna regresija bez regularizacije)
 - **Kvazi-Njutnove metode** - ne računaju pravi Hessian* (što je skupo), već ga aproksimiraju.
 - BFGS (*Broyden-Fletcher-Goldfarb-Shanno*) algoritam - popularna kvazi-Njutn metoda, gradi aproksimaciju Hessiana tokom iteracija.
 - L-BFGS (*Limited memory BFGS*) algoritam - varijanta pogodna za velike probleme jer ne čuva celu matricu, već samo njenu "ograničenu memoriju".
- Mana ovih metoda - velika kompleksnost ili funkcija gubitka ima **ravne regione ili oštre minimume** gde običan gradijentni spust sporo napreduje.
 - Nisu pogodne za samostalnu implementaciju već treba koristiti gotove biblioteke.

* Hessian je matrica koja opisuje zakrivljenost funkcije i igra ključnu ulogu u metodama drugog reda

Preterana prilagođenost modela podacima

- Kao i u regresiji, i u klasifikaciji preterana prilagođenost modela podacima (*overfitting*) dovodi do toga da apsolutne vrednosti nekih težinskih parametara w budu jako velike (u krajnjoj instanci teže $\rightarrow \infty$).
- Primer: klasifikacija dokumenata po tematici između sporta ($y = 1$) i informatike ($y = 0$).
 - Pretpostavimo pristup vreće reči (*bag-of-words*) - svaka reč je jedna odlika.
 - U skupu za obučavanje reč *fudbal* se javlja samo u dokumentima čija je tema sport.
 - Algoritam teži da postavi $P(y = 1 \mid x; x_{\text{fudbal}} \geq 1) = 1$.
 - Pošto se reč *fudbal* javlja samo u dokumentima jedne klase, obučavanje dovodi do visoke vrednosti za w_{fudbal}
$$w_{\text{fudbal}} \rightarrow +\infty \Rightarrow P(y = 1 \mid x; x_{\text{fudbal}} \geq 1) = \frac{1}{1 + e^{-\sum_{i=0}^n w_i x_i}} \rightarrow 1$$
 - Visoka vrednost parametra w_{fudbal} efektivno dovodi do toga da se svaki dokument u kome se javlja reč *fudbal* automatski klasifikuje u sportsku tematiku - sve ostale odlike se ignorišu.
 - Ovo ponašanje nije poželjno, jer može se pojaviti reč *fudbal* i u informatičkom dokumentu, čija je tema opis fudbalskog simulatora. Do neželjenog ponašanja dolazi zbog proređenosti podataka u skupu za obučavanje.
- Kao i kod regresije, regularizacija sprečava preteranu prilagođenost modela podacima ograničavanjem magnituda težinskih parametara. Koriste se i L_1 i L_2 regularizacija.


Primer efekta nedovoljne i preterane prilagođenosti modela podacima u klasifikaciji podataka




$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

(g = sigmoid function)

UNDERFITTING
(high bias)



$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 + \theta_5 x_1 x_2)$$



$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_1^2 + \theta_3 x_1^2 x_2 + \theta_4 x_1^2 x_2^2 + \theta_5 x_1^2 x_2^3 + \theta_6 x_1^3 x_2 + \dots)$$

OVERFITTING
(high variance)

L₂-regularizovana logistička regresija

- Funkcija greške, njen parcijalni izvod i pravilno ažuriranje težinskih faktora za grupni spust u L₂-regularizovanoj logističkoj regresiji:

$$J(w) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} \ln h(x^{(i)}) + (1 - y^{(i)}) \ln (1 - h(x^{(i)})) + \frac{\lambda}{2m} \sum_{j=1}^n w_j^2$$

$$\frac{\partial J(w)}{\partial w_r} = \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_r^{(i)} + \frac{\lambda}{m} w_r$$

$$w_r := w_r \left(1 - \alpha \frac{\lambda}{m} \right) - \alpha \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_r^{(i)}$$

- Kao i kod linearne regresije, težinski parametar w_0 obično ne podleže regularizaciji.


Višeklasna klasifikacija

- Logistička regresija se može primeniti i u slučaju prisustva većeg broja klasa, na dva načina:
- 1) Kombinovanjem rezultata većeg broja binarnih klasifikatora tj. binarnih logističkih regresija.
 - Princip „jedan nasuprot svima“ (engl. *one-versus-all*) / „jedan nasuprot ostalima“ (engl. *one-versus-rest*).
 - Princip „jedan nasuprot jednom“ (engl. *one-versus-one*).
 - Ove metode su primenljive i na ostale binarne klasifikatore (npr. OvO je efikasan za klasifikatore koji rade brzo na malim skupovima podataka, kao što je metod potpornih vektora).
- 2) Multinomijalna (multiklasna) logistička regresija - direktno modelira verovatnoće za sve klase pomoću *softmax funkcije* (umesto sigmoida).
- OvR i OvO su strategije adaptacije binarnih klasifikatora (logističke regresije, SVM, perceptrona...).
- Multinomijalna logistička regresija je poseban model - ona nije kombinacija binarnih modela već direktna generalizacija. U praksi se multinomijalna logistička regresija najčešće koristi sa *softmax funkcijom*, posebno u neuralnim mrežama.


Princip „jedan nasuprot svima“

- Ako je k broj klasa, konstruiše se k binarnih klasifikatora.
- Svaki binarni klasifikator je dodeljen jednoj klasi:
 - Tretira dodeljenu klasu kao jednu klasu, a sve ostale klase zajedno kao drugu klasu.
 - Problem neuravnoteženosti broja primera po klasama - primera druge klase tipično ima daleko više nego primera prve klase.
- Nov podataka se svrstava u onu klasu čiji binarni klasifikator proizvodi najveću verovatnoću pripadnosti tog podatka posmatranoj klasi.

One-vs-all (one-vs-rest):



Class 1: 
Class 2: 
Class 3: 



Princip „jedan nasuprot jednom“

- Ako je k broj klasa, konstruiše se $\frac{k \cdot (k-1)}{2}$ binarnih klasifikatora, po jedan za svaki par (kombinaciju) klasa.
- Nov podatak se svrstava u onu klasu koju je odabralo najviše binarnih klasifikatora - mehanizam glasanja (engl. *majority voting*).
- Broj klasifikatora je u ovoj varijanti znatno veći nego u pristupu „jedan nasuprot svima“.
- U zavisnosti od broja klasa, vreme rada može da bude i kraće nego u pristupu „jedan nasuprot svima“
 - Skup podataka za obučavanje svakog binarnog klasifikatora je znatno manji u pristupu „jedan nasuprot jednom“.

Multinomijalna logistička regresija

Pronalaženje skrivenog znanja, *Univerzitet u Beogradu - Elektrotehnički fakultet*

Multinomijalna logistička regresija

- Prirodno proširenje logističke regresije za rad sa više klasa.
- Naziva se i softmax regresijom, jer se verovatnoća pripadnosti klasi t dobija pomoću *softmax funkcije* čiji je oblik:

$$P(y = t|x) = \frac{e^{\sum_{i=0}^n w_i^{\{t\}} x_i}}{\sum_{j=1}^k e^{\sum_{i=0}^n w_i^{\{j\}} x_i}} = \frac{e^{(w^{\{t\}})^T X}}{\sum_{j=1}^k e^{(w^{\{j\}})^T X}}$$

- gde je k broj klasa, n broj odlika, $w_i^{\{t\}}$ težinski parametar i -te odlike za t -tu klasu, $(W^{\{t\}})^T$ (transponovani) vektor težinskih parametara za t -tu klasu, a X vektor vrednosti odlika.
- Imenilac razlomka služi da normalizuje raspodelu, tako da suma svih verovatnoća bude jednaka 1.
- Izlaz softmax funkcije se koristi da reprezentuje multinomijalnu raspodelu (sa k mogućih ishoda).

Multinomijalna logistička regresija (2)

- Hipoteza multinomijalne logističke regresije je k-dimenzionalni vektor koji izražava verovatnoće pripadnosti podataka svakoj od k klasa:

$$h(x) = \begin{bmatrix} P(y = 1|x) \\ P(y = 2|x) \\ \vdots \\ P(y = k|x) \end{bmatrix} = \frac{1}{\sum_{j=1}^k e^{(W^{(j)})^T x}} \begin{bmatrix} e^{(W^{(1)})^T x} \\ e^{(W^{(2)})^T x} \\ \vdots \\ e^{(W^{(k)})^T x} \end{bmatrix}$$

- Iako svaka klasa ima svoj vektor težinskih parametara $W^{(i)}$, broj slobodnih vektora je zapravo k-1, pošto zbir verovatnoća svih klasa mora biti jednak 1.
- Model je „preterano parametrizovan“ (engl. *overparameterized*), što znači da za svaki skup podataka za obučavanje postoji veći broj vrednosti parametara koje proizvode identičnu hipotezu $h(x)$.
- Iz ovoga se može izvesti i dokaz da je binarna logistička regresija samo jednostavniji slučaj multinomijalne.

Ekvivalentnost binarne i multinomijalne logističke regresije za k=2

- Ako postoje samo dve klase $y=0$ i $y=1$ može se proizvoljno usvojiti da su vrednosti svih težinskih parametara klase 0 jednaki nuli.

- Sledi:

$$P(y = 1|x) = \frac{e^{(w^{1})^T x}}{e^{(w^{0})^T x} + e^{(w^{1})^T x}} = \frac{e^{(w^{1})^T x}}{e^0 + e^{(w^{1})^T x}} = \frac{e^{(w^{1})^T x}}{1 + e^{(w^{1})^T x}}$$

- što je jedano već viđenom izrazu za hipotezu binarne logističke regresije:

$$P(y = 1|x) = h(x) = \frac{e^{w^T x}}{1 + e^{w^T x}}$$

Funkcija gubitka multinomijalne logističke regresije

- Kao i kod binarne logističke regresije, funkcija gubitka klase t bi u slučaju pripadnosti podatka klasi t trebalo da bude velika, kada je vrednost $h(x)^{\{t\}} = P(y=t|x)$ blizu nuli, a mala kada je vrednost $h(x)^{\{t\}}$ blizu jedinici:

$$\begin{aligned} L(h(x), y)^{\{t\}} &= -\ln h(x)^{\{t\}} = -\ln P(y = t|x) = -\ln \frac{e^{(w^{\{t\}})^T X}}{\sum_{j=1}^k e^{(w^{\{j\}})^T X}} \\ &= -\left((w^{\{t\}})^T X - \ln \sum_{j=1}^k e^{(w^{\{j\}})^T X} \right) \end{aligned}$$

- Multinomijalna logistička regresija spada u log-linearne modele - logaritam hipoteze sadrži linearnu kombinaciju parametara: $(w^{\{t\}})^T X$.

Funkcija greške multinomijalne logističke regresije

- Funkcija greške ima sledeći oblik:

$$J(w) = \frac{1}{m} \sum_{i=1}^m \sum_{t=1}^k 1\{y^{(i)} = t\} L(h(x^{(i)}), y^{(i)})\{t\}$$

- gde je $1\{y^{(i)}=t\}$ indikatorska funkcija čija je vrednost 1 kada je $y^{(i)}=t$, odnosno 0 u suprotnom (Kronekerova delta funkcija)

$$\begin{aligned} J(w) &= -\frac{1}{m} \sum_{i=1}^m \sum_{t=1}^k 1\{y^{(i)} = t\} \ln \frac{e^{(w^{(t)})^T x^{(i)}}}{\sum_{j=1}^k e^{(w^{(j)})^T x^{(i)}}} \\ &= -\frac{1}{m} \sum_{i=1}^m \sum_{t=1}^k 1\{y^{(i)} = t\} \ln P(y^{(i)} = t | x^{(i)}) \end{aligned}$$

Ekvivalentnost funkcije greške binarne i multinomijalne logističke regresije za $k=2$

- Funkcija greške binarne logističke regresije se može transformisati na sledeći način:

$$J(w) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} \ln h(x^{(i)}) + (1 - y^{(i)}) \ln (1 - h(x^{(i)}))$$

$$J(w) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} \ln P(y^{(i)} = 1 | x^{(i)}) + (1 - y^{(i)}) \ln P(y^{(i)} = 0 | x^{(i)})$$

$$J(w) = -\frac{1}{m} \sum_{i=1}^m \sum_{t=0}^1 1\{y^{(i)} = t\} \ln P(y^{(i)} = t | x^{(i)})$$

- čime se dobija oblik funkcije greške ekvivalentan onom za multinomijalnu logističku regresiju.

Parcijalni izvod funkcije gubitka multinomijalne logističke regresije

$$\begin{aligned}\frac{\partial}{\partial w_r^{\{t\}}} L(h(x), y)^{\{t\}} &= -\frac{\partial}{\partial w_r^{\{t\}}} \left((W^{\{t\}})^T X - \ln \sum_{j=1}^k e^{(W^{\{j\}})^T X} \right) = -\frac{\partial}{\partial w_r^{\{t\}}} \left(\sum_{i=0}^n w_i^{\{t\}} x_i - \ln \sum_{j=1}^k e^{\sum_{i=0}^n w_i^{\{j\}} x_i} \right) \\ &= -x_r + \frac{e^{\sum_{i=0}^n w_i^{\{t\}} x_i}}{\sum_{j=1}^k e^{\sum_{i=0}^n w_i^{\{j\}} x_i}} x_r = -x_r (1 - P(y = t|x))\end{aligned}$$

$$\frac{\partial}{\partial w_r^{\{t\}}} L(h(x), y)^{\{q|q \neq t\}} = -\frac{\partial}{\partial w_r^{\{t\}}} \left((W^{\{q\}})^T X - \ln \sum_{j=1}^k e^{(W^{\{j\}})^T X} \right) = -\frac{\partial}{\partial w_r^{\{t\}}} \left(\sum_{i=0}^n w_i^{\{q\}} x_i - \ln \sum_{j=1}^k e^{\sum_{i=0}^n w_i^{\{j\}} x_i} \right)$$

$$= \frac{e^{\sum_{i=0}^n w_i^{\{t\}} x_i}}{\sum_{j=1}^k e^{\sum_{i=0}^n w_i^{\{j\}} x_i}} x_r = P(y = t|x) x_r$$

Parcijalni izvod funkcije greške multinomijalne logističke regresije

$$J(w) = \frac{1}{m} \sum_{i=1}^m \sum_{t=1}^k 1\{y^{(i)} = t\} L(h(x^{(i)}), y^{(i)})^{(t)}$$

$$\frac{\partial}{\partial w_r^{(t)}} L(h(x), y)^{(t)} = -x_r (1 - P(y = t|x))$$

$$\frac{\partial}{\partial w_r^{(t)}} L(h(x), y)^{(q|q \neq t)} = P(y = t|x) x_r$$

$$\frac{\partial J(w)}{\partial w_r^{(t)}} = -\frac{1}{m} \sum_{i=1}^m x_r^{(i)} \left(1\{y^{(i)} = t\} - P(y^{(i)} = t|x^{(i)}) \right)$$

Ekvivalentnost parcijalnog izvoda funkcije greške binarne i multinomijalne logističke regresije za k=2

$$\frac{\partial J(w)}{\partial w_r^{\{t\}}} = -\frac{1}{m} \sum_{i=1}^m x_r^{(i)} \left(1\{y^{(i)} = t\} - P(y^{(i)} = t | x^{(i)}) \right)$$

- Ako postoje samo dve klase $y = 0$ i $y = 1$, može se proizvoljno usvojiti da su vrednosti svih težinskih parametara klase 0 jednaki nuli.

$$\frac{\partial J(w)}{\partial w_r} = \frac{1}{m} \sum_{i=1}^m x_r^{(i)} (P(y^{(i)} = 1 | x^{(i)}) - 1\{y^{(i)} = 1\})$$

$$\frac{\partial J(w)}{\partial w_r} = \frac{1}{m} \sum_{i=1}^m (P(y^{(i)} = 1 | x^{(i)}) - y^{(i)}) x_r^{(i)}$$

$$\frac{\partial J(w)}{\partial w_r} = \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_r^{(i)}$$

Regularizacija multinomijalne logističke regresije

- Izgled funkcije greške sa L_2 regularizacijom:

$$J(w) = \frac{1}{m} \sum_{i=1}^m \sum_{t=1}^k 1\{y^{(i)} = t\} L(h(x^{(i)}), y^{(i)})^{\{t\}} + \frac{\lambda}{2m} \sum_{j=1}^n \sum_{s=1}^k (w_j^{\{s\}})^2$$

- Parcijalni izvod funkcije greške sa L_2 regularizacijom:

$$\frac{\partial J(w)}{\partial w_r^{\{t\}}} = -\frac{1}{m} \sum_{i=1}^m x_r^{(i)} \left(1\{y^{(i)} = t\} - P(y^{(i)} = t | x^{(i)}) \right) + \frac{\lambda}{m} w_r^{\{t\}}$$

Model maksimalne entropije


- Multinomijalna logistička regresija se javlja i pod imenom **modela maksimalne entropije** (engl. *Maximum Entropy Models*).
- Entropija raspodele slučajne promenljive x se definiše kao: $H(x) = - \sum_x P(x) \log P(x)$
- Intuicija modela maksimalne entropije je da probabilistički model koji se izgrađuje treba da poštuje sva ograničenja koja mu se zadaju, ali da sem toga sledi princip Okamove oštrice
 - Treba da donosi zaključke na osnovu što manje dodatnih pretpostavki o izgledu raspodele verovatnoće.
- Ako bi se zanemarila sva ograničenja, model sa maksimalnom entropijom bi bio onaj koji svim klasama daje podjednaku verovatnoću, a model sa minimalnom onaj koji svu verovatnoću daje samo jednoj klasi.
- Moguće je pokazati da model koji ima maksimalnu entropiju jeste upravo model multinomijalne logističke regresije čiji težinski faktori w maksimizuju uslovne verovatnoće $P(y^{(i)}|x^{(i)})$ nad podacima za obučavanje.

Multinomijalna logistička regresija naspram kombinovanja binarnih klasifikatora


- Binarni klasifikatori nisu u stanju da modeluju celu složenost problema kada je broj klasa veći od dve
 - Ignorišu se interakcije između klasa pri optimizaciji parametara w
- Kombinovanje binarnih klasifikatora je osetljivije na anomalije nego multinomijalni pristup.
- Multinomijalni pristup omogućava globalni probabilistički izlaz modela
 - Ovo je primereno kada podaci mogu da pripadaju samo jednoj od k klasa.
 - Ako podaci mogu da pripadaju većem broju klasa u različitoj meri, onda je primerenije koristiti kombinaciju binarnih klasifikatora.

Poređenje kombinacije binarnih klasifikatora i jednog multinomijalnog klasifikatora


Multiple binary classifiers



Multinomial classifier




Prikaz probabilističkog izlaza multinomijalnog klasifikatora pri radu sa 3 klase



Diskriminativni modeli

- Diskriminativni modeli direktno modeluju odluku (granice ili uslovne verovatnoće $P(y|x)$)
- Diskriminativni modeli se fokusiraju samo na što pravilnije razlikovanje članova različitih klasa, tj. na modelovanje granice između klasa (ne nužno i verovatnoće $P(y|x)$).
- Ne zanima ih proces generisanja parova (x, y) , za razliku od generativnih modela.
 - Model ne uči ono što nije potrebno za rešavanje konkretnog zadatka.
- Pored logističke regresije, u diskriminativne modele spadaju:
 - Stabla odlučivanja (engl. *Decision Trees*),
 - Metoda potpornih vektora (engl. *Support Vector Machines*),
 - Uslovna nasumična polja (engl. *Conditional Random Fields*),
 - Neur

Razlike između diskriminativnih i generativnih modela



Diskriminativni nasuprot generativnim modelima

- Modelovanje klasifikacione granice:
 - Diskriminativni - eksplicitno.
 - Generativni - implicitno, tamo gde jedna klasa postaje verovatnija od druge.
- Količina podataka za obučavanje:
 - Srednja/velika - diskriminativni modeli obično daju bolje performanse.
 - Mala - generativni modeli obično daju bolje performanse.
- Korišćenje neobebeženih podataka u obučavanju:
 - Diskriminativni modeli - teže, modeli po prirodi zahtevaju obeležene podatke za obučavanje.
 - Generativni modeli mogu lakše da iskoriste i neobeležene podatke.

Primer za generativni i diskriminativni pristup

- Zadatak: Određivanje na kom jeziku neka osoba govori.
- Generativni pristup
 - Nauči svaki jezik.
 - Odabрати onaj naučeni jezik kome je jezik govornika najsličniji.
- Diskriminativni pristup
 - Naučiti lingvističke razlike između jezika, bez učenja samih jezika.
 - Koristeći naučene razlike odrediti jezik govornika.
 - Mnogo lakši pristup.

Prednosti i nedostaci logističke regresije

- Prednosti:

- Jednostavna implementacija i brza obuka – pogotovo u poređenju sa složenijim modelima (npr. neuralnim mrežama).
- Laka interpretacija koeficijenata – znak i veličina težina w_i pokazuju uticaj odlika.
- Manje sklona preobučavanju od složenih modela (ako se koristi regularizacija).
- Dobro funkcioniše kad su klase linearno separabilne ili blizu toga.
- Može da radi i sa kontinuiranim i sa diskretnim odlikama.

- Nedostaci:

- Pretpostavlja linearnu granicu odlučivanja u prostoru odlika - loše radi kod nelinearnih odnosa osim ako se ručno dodaju polinomske ili interakcione odlike.
- Osetljiva na multikolinearnost (kada su odlike međusobno zavisne - koeficijenti postaju nestabilni).
- Lošije performanse kada je broj odlika vrlo veliki u odnosu na broj uzoraka (*curse of dimensionality*).
- Nije pogodna za kompleksne nelinearne probleme gde npr. SVM ili neuralne mreže daju znatno bolje rezultate.
- Može biti sporija od Naivnog Bayesa na ogromnim skupovima podataka, jer nema zatvoreno formulu već zahteva optimizaciju.

Naivni Bajesov algoritam

Pronalaženje skrivenog znanja, *Univerzitet u Beogradu - Elektrotehnički fakultet*

Naivni Bajesov algoritam

- Naivni Bajesov algoritam se zasniva na modelovanju raspodele ciljne promenljive y pri datim vrednostima promenljive x , korišćenjem Bajesove formule:

$$P(y|x) = \frac{P(y, x)}{P(x)} = \frac{P(x|y)P(y)}{P(x)}$$

- y je klasa, x je podatak;
 - $P(y)$ - prethodna/apriorna verovatnoća klase (engl. *prior probability*);
 - $P(y|x)$ - aposteriorna verovatnoća klase (engl. *posterior probability*);
 - $P(y, x)$ - zajednička verovatnoća klase i podatka (engl. *joint probability*);
 - $P(x|y)$ - funkcija izvesnosti (engl. *likelihood function*).
- Najčešće se primenjuje na problem klasifikacije, pa se govori o Naivnom Bajesovom klasifikatoru.
 - Engleski statističar i filozof, Thomas Bayes (1701-1761).

Primer

(iz knjige Mašinsko učenje - Dr Mladen Nikolić)

- Kod lekara dolazi pacijent koji se žali na osećaj hladnoće i blagu glavobolju. Lekar nije bas najstručniji i pokušava da pretpostavi dijagnozu preturajući po kartonima drugih

pacijenata, pokušavajući da ustanovi kakve su simptome imali pacijenti koji su imali grip, a kakve oni koji nisu. Kako nema mnogo vremena, mora da odlučuje na osnovu malog uzorka. U tabeli su dati podaci o nekoliko pacijenata čije je kartone našao. Da je dobar matematičar, lekar bi na osnovu ovog uzorka izračunao odgovarajuće proizvode koji su proporcionalni uslovnim verovatnoćama da pacijent ima grip i da nema grip:

$$p(Da|Da, Ne, Blaga, Ne) \sim p(H = Da|Da)p(C = Ne|Da)p(Gl = B|Da)p(Gr = Ne|Da)p(Grip = Da)$$

$$= \frac{3}{5} \frac{1}{5} \frac{2}{5} \frac{1}{5} \frac{5}{8} = \frac{3}{500}$$

$$p(Ne|Da, Ne, Blaga, Ne) \sim p(H = Da|Ne)p(C = Ne|Ne)p(Gl = B|Ne)p(Gr = Ne|Ne)p(Grip = Ne)$$

$$= \frac{1}{3} \frac{2}{3} \frac{1}{3} \frac{2}{3} \frac{3}{8} = \frac{1}{54}$$

Iako nije izračunao tačne verovatnoće da pacijent ima ili nema grip, lekar može da zaključi da je verovatnije da pacijent NEMA GRIP.

Hladnoća	Curenje iz nosa	Glavobolja	Groznica	Grip
Da	Ne	Blaga	Da	Ne
Da	Da	Ne	Ne	Da
Da	Ne	Jaka	Da	Da
Ne	Da	Blaga	Da	Da
Ne	Ne	Ne	Ne	Ne
Ne	Da	Jaka	Da	Da
Ne	Da	Jaka	Ne	Ne
Da	Da	Blaga	Da	Da

Primena Bajesove teoreme u klasifikaciji

- Klasifikaciona odluka - podataka svrstati u onu klasu koja je za njega najverovatnija tj. ima najveću aposteriornu verovatnoću.
$$P(y|x) = \frac{P(y, x)}{P(x)} = \frac{P(x|y)P(y)}{P(x)}$$
- Ovakvo odlučivanje se naziva *Maximum a posteriori* - MAP:
$$y_{MAP} = \operatorname{argmax}_y P(y|x)$$
$$= \operatorname{argmax}_y \frac{P(x|y)P(y)}{P(x)}$$
$$= \operatorname{argmax}_y P(x|y)P(y)$$
- Da bi se izvršila klasifikacija potrebni su nam $P(y)$ i $P(x|y)$.
- $P(y)$ je zastupljenost klase y u skupu podataka za obučavanje: $P(y) = \frac{\text{Count}(y)}{\text{Count}(x)}$
- Podatak x se predstavlja pomoću nekih njegovih odlika, kojih ima n : $P(x|y) = P(x_1, x_2, x_3, \dots x_n|y)$
- Koristeći pravilo ulančavanja uslovnih verovatnoća sledi:
$$P(x_1, x_2, x_3, \dots x_n|y) = P(x_1|y) \cdot P(x_2, x_3, \dots x_n|y, x_1) = P(x_1|y) \cdot P(x_2|y, x_1) \cdot P(x_3, \dots x_n|y, x_1, x_2) = P(x_1|y) \cdot P(x_2|y, x_1) \dots \cdot P(x_n|y, x_1, x_2, \dots x_{n-1})$$

Naivna pretpostavka o statističkoj nezavisnosti odlika

- Pretpostavka: odlike koje se koriste pri odlučivanju nisu statistički zavisne jedna od druge - poznavanje vrednosti jedne odlike ništa ne govori o vrednosti neke druge.
- Ako je tako, onda važi:

$$P(x|y) = P(x_1, x_2, x_3, \dots x_n|y) = P(x_1|y)P(x_2|y) \dots P(x_n|y) = \prod_{i=1}^n P(x_i|y)$$

- Time uslovna verovatnoća svake odlike zavisi samo od klase podataka.
- Raspodela te verovatnoće - multinomijalna, Bernulijeva, Gausova,...
- Iako je praktično uvek pogrešna, pretpostavka o međusobnoj statističkoj nezavisnosti odlika znatno olakšava modeliranje.
- Naivni Bajesovi modeli u praksi često ostvaruju dobre rezultate - za pravilnu klasifikaciju nije neophodno poznavanje tačnih vrednosti $P(y|x)$ za sve y , već samo njihovog međusobnog redosleda.

Formula za određivanje pripadnosti klasi

$$y_{MAP} = \operatorname{argmax}_y P(x|y)P(y) = \operatorname{argmax}_y P(y) \prod_{i=1}^n P(x_i|y)$$

- Broj odlika je često veoma veliki, a verovatnoće su u opsegu $[0,1]$.
- Da bi se izbegao *Floating point underflow*, umesto množenja verovatnoća, vrši se sabiranje njihovih logaritama:

$$y_{MAP} = \operatorname{argmax}_y \left(\log P(y) + \sum_{i=1}^n \log P(x_i|y) \right)$$

Raspodele uslovnih verovatnoća odlika

- Različite raspodele $P(x_t|y)$ su pogodne za različite tipove vrednosti odlika x_t .
- **Multinomijalna raspodela**
 - Pogodna za odlike sa vrednostima koje predstavljaju broj javljanja nečega.
 - Tipično korišćena kod tekstualnih podataka (npr. bag-of-words model), gde je odlika broj pojavljivanja neke reči u dokumentu.
 - Može da radi i sa brojem događaja u kategorijama.
- **Bernulijeva raspodela** - pogodna za odlike sa binarnim/indikatorskim vrednostima.
- **Gausova raspodela**
 - Pogodna za odlike sa kontinualnim numeričkim vrednostima.
 - Pretpostavlja da svaka odlika unutar klase ima normalnu raspodelu.
 - Ako ova pretpostavka ne važi, performanse mogu biti slabije.
- **Eksponencijalna raspodela** - za pozitivne kontinualne vrednosti (npr. vreme čekanja).
- **Poasonova raspodela** - za broj događaja u intervalu (alternativa multinomijalnoj u nekim slučajevima).

Multinomijalni naivni Bajesov klasifikator

- engl. *Multinomial Naive Bayes*
- Pogodan kada vrednosti odlika predstavljaju broj javljanja nečega.
- Verovatnoća $P(x_t|y)$ - odnos između zbirne vrednosti odlike x_t u podacima klase y i zbirne vrednosti svih odlika u podacima te klase:

$$P(x_t|y) = \frac{\text{Count}(x_t, y)}{\sum_{i=1}^n \text{Count}(x_i, y)}$$

- Ovakav metod određivanja verovatnoća $P(x_t|y)$ se naziva metod najveće izvesnosti (engl. *Maximum Likelihood Estimation*, skr. *MLE*), jer se njime maksimizuje uslovna verovatnoća/funkcija izvesnosti podataka nad kojima se model obučava.

Metod najveće izvesnosti

- Šta se dešava kada se odlika x_t nikad ne javlja u podacima klase y , u skupu za obučavanje?
 - $P(x_t | y) = 0$
 - Model odbacuje klasu y na osnovu samo jedne odlike.
- Ovako rezonovanje je problematično, jer odsustvo odlike x_t u podacima klase y iz skupa za obučavanje može da bude slučajno
 - Naročito ako je broj odlika veliki, a skup za obučavanje mali - problem proređenosti podataka (engl. *data sparsity*).
 - Preterana prilagođenost modela (engl. *overfitting*).
- Korekcija - umesto $P(x_t | y) = 0$, staviti da je $P(x_t | y)$ jednako nekoj maloj nenuljoj vrednosti.

Laplasovo poravnanje

- **Laplasovo poravnanje** (engl. *Laplace smoothing*) ili aditivno poravnanje - brojanje zbirne vrednosti odlika u svakoj klasi ne počinje od nule, već od neke predefinisane vrednosti α .
- Obično se uzima $\alpha = 1$.
- Verovatnoća $P(x_t | y)$ se stoga računa kao:

$$P(x_t|y) = \frac{\text{Count}(x_t, y) + 1}{\sum_{i=1}^n (\text{Count}(x_i, y) + 1)} = \frac{\text{Count}(x_t, y) + 1}{n + \sum_{i=1}^n \text{Count}(x_i, y)}$$

- Laplasovo poravnanje se može smatrati oblikom regularizacije modela.
- Deo verovatnoća javljanja odlika viđenih u klasi y u skupu za obučavanje se preraspoređuje na odlike koje u toj klasi nisu (još uvek) opažene.

Poziciona nezavisnost odlika

- Multinomijalni naivni Bajesov model implicitno pretpostavlja da ne postoji zavisnost između uslovne verovatnoće odlika i njihove pozicije u podacima.
- Primer: raspored reči u tekstu pri klasifikaciji dokumenata.
- Ukoliko su podaci tako strukturirani da postoji redosled između odlika koje se razmatraju, taj redosled se u modelu ignoriše.
- U modeliranju tekstualnih podataka ovaj pristup je poznat kao vreća reči (engl. *bag-of-words*), pri čemu su individualne reči odlike koje se uzimaju u obzir.
- Prednost: drastično smanjenje parametara modela, odnosno složenosti modela (ne moramo da pamtimo sve moguće redoslede reči, što bi bilo eksponencijalno mnogo).
- Mana: gubi se informacija o strukturi i kontekstu (npr. „pas ujeda čoveka“ i „čovek ujeda psa“ su isti skup reči u vreći reči) => ovo se u NLP rešava drugim modelima (RNN, LSTM, Transformer).

Multinomijalni naivni Bajesov klasifikator

- $Count(x_t, y)$ govori o zbirnoj vrednosti odlike x_t u podacima klase y .
- Ponekad se odlike binarizuju - tada $Count(x_t, y)$ govori u koliko podataka klase y se odlika x_t javlja, a ne koja je njena zbirna vrednost u tim podacima.
- U računanju $P(x|y)$ učestvuju samo one odlike koje se javljaju (imaju nenultu vrednost) u podatku x .

Primer klasifikacije teksta: Multinomijalni NBK

	Doc	Reči u dokumentu	Klasa
Skup za obučavanje	1	Chinese Beijing Chinese	C
	2	Chinese Chinese Shanghai	C
	3	Beijing Macao	C
	4	Tokyo Japan Chinese	J
Skup za testiranje	5	Chinese Chinese Chinese Tokyo Japan	?

$$P(C) = \frac{3}{4}$$

$$P(J) = \frac{1}{4}$$

$$P(\text{Chinese}|C) = \frac{4+1}{6+8} = \frac{5}{14}$$

$$P(\text{Chinese}|J) = \frac{1+1}{6+3} = \frac{2}{9}$$

$$P(\text{Tokyo}|C) = \frac{0+1}{6+8} = \frac{1}{14}$$

$$P(\text{Tokyo}|J) = \frac{1+1}{6+3} = \frac{2}{9}$$

$$P(\text{Japan}|C) = \frac{0+1}{6+8} = \frac{1}{14}$$

$$P(\text{Japan}|J) = \frac{1+1}{6+3} = \frac{2}{9}$$

$$P(C|d5) \propto P(C)P(\text{Chinese}|C)^3P(\text{Tokyo}|C)P(\text{Japan}|C) = \frac{3}{4} \times \left(\frac{5}{14}\right)^3 \times \frac{1}{14} \times \frac{1}{14} \approx 0,000174$$

$$P(J|d5) \propto P(J)P(\text{Chinese}|J)^3P(\text{Tokyo}|J)P(\text{Japan}|J) = \frac{1}{4} \times \left(\frac{2}{9}\right)^3 \times \frac{2}{9} \times \frac{2}{9} \approx 0,000135$$

Multivarijacioni Bernulijev naivni Bajesov klasifikator

- U čestoj upotrebi u klasifikaciji teksta je i multivarijacioni Bernulijev naivni Bajesov klasifikator (engl. *Multivariate Bernoulli Naive Bayes*).
- Odlike su binarnog/indikatorskog tipa.
- $Count(x_t, y)$ govori u koliko podataka klase y se odlika x_t javlja.
- U računanju $P(x|y)$ učestvuju sve odlike koje se koriste u modelu, čak i one koje se ne javljaju (imaju nultu vrednost) u podatku x .
- Pretpostavka o pozicionoj nezavisnosti odlika ovde nije neophodna, jer Bernulijev model po definiciji uzima u obzir samo prisustvo/odsustvo odlika.

Multivarijacioni Bernulijev naivni Bajesov klasifikator (2)

- Verovatnoća $P(x_t|y)$ - procenat podataka klase y u kojima je odlika x_t prisutna:

$$P(x_t|y) = \frac{\text{Count}(x_t, y)}{\text{Count}(y)}$$

- Laplasovo poravnanje:

$$P(x_t|y) = \frac{\text{Count}(x_t, y) + 1}{K + \text{Count}(y)} = \frac{\text{Count}(x_t, y) + 1}{2 + \text{Count}(y)}$$

- K je broj mogućih ishoda tj. vrednosti odlike x_t .
- $K = 2$ kad je odlika x_t binarna.

Primer klasifikacije teksta - multivarijacioni Bernulijev naivni Bajesov klasifikator

	Doc	Reči u dokumentu	Klasa
Skup za obučavanje	1	Chinese Beijing Chinese	C
	2	Chinese Chinese Shanghai	C
	3	Beijing Macao	C
	4	Tokyo Japan Chinese	J
Skup za testiranje	5	Chinese Chinese Chinese Tokyo Japan	?

$$P(C) = \frac{3}{4}$$

$$P(J) = \frac{1}{4}$$

$$P(Beijing|C) = \frac{2+1}{2+3} = \frac{3}{5}$$

$$P(Beijing|J) = \frac{0+1}{2+1} = \frac{1}{3}$$

$$P(Shanghai|C) = \frac{1+1}{2+3} = \frac{2}{5}$$

$$P(Shanghai|J) = \frac{0+1}{2+1} = \frac{1}{3}$$

$$P(Macao|C) = \frac{1+1}{2+3} = \frac{2}{5}$$

$$P(Macao|J) = \frac{0+1}{2+1} = \frac{1}{3}$$

$$P(Chinese|C) = \frac{2+1}{2+3} = \frac{3}{5} \quad P(Tokyo|C) = \frac{0+1}{2+3} = \frac{1}{5} \quad P(Japan|C) = \frac{0+1}{2+3} = \frac{1}{5}$$

$$P(Chinese|J) = \frac{1+1}{2+1} = \frac{2}{3} \quad P(Tokyo|J) = \frac{1+1}{2+1} = \frac{2}{3} \quad P(Japan|J) = \frac{1+1}{2+1} = \frac{2}{3}$$

$$P(C|d5) \propto P(C) \times P(Chinese|C) \times P(Tokyo|C) \times P(Japan|C)$$

$$\times (1 - P(Beijing|C)) \times (1 - P(Shanghai|C)) \times (1 - P(Macao|C)) = \frac{3}{4} \times \frac{3}{5} \times \frac{1}{5} \times \frac{1}{5} \times \frac{2}{5} \times \frac{3}{5} \times \frac{3}{5} \approx 0,0026$$

$$P(J|d5) \propto P(J) \times P(Chinese|J) \times P(Tokyo|J) \times P(Japan|J)$$

$$\times (1 - P(Beijing|J)) \times (1 - P(Shanghai|J)) \times (1 - P(Macao|J)) = \frac{1}{4} \times \frac{2}{3} \times \frac{2}{3} \times \frac{2}{3} \times \frac{2}{3} \times \frac{2}{3} \times \frac{2}{3} \approx 0,022$$

Razlike između multinomijalnog i Bernulijevog modela u klasifikaciji teksta

	Multinomijalni model	Bernulijev model
$Count(x_t, y)$	Broje se (sabiraju) vrednosti odlike x_t u podacima klase y .	Broje se javljanja odlike x_t u podacima klase y .
x_t	Nije binarnog tipa (ali se može binarizovati).	Binarnog tipa.
$P(x_t y)$	Odnos zbirne vrednosti odlike x_t i zbirne vrednosti svih odlika u podacima klase y .	Procenat podataka klase y u kojima je odlika x_t prisutna.
$P(x y)$	Uključuje samo odlike koje se javljaju (imaju nenultu vrednost) u podatku x .	Uključuje sve odlike koje se koriste u modelu.
Laplasovo poravnanje	$\frac{Count(x_t, y) + 1}{n + \sum_{i=1}^n Count(x_i, y)}$	$\frac{Count(x_t, y) + 1}{K + Count(y)}$

- Pretpostavka o pozicionoj nezavisnosti odlika:
 - Multinomijalni model - potrebna
 - Bernulijev model - nepotrebna
- **Binarizovan multinomijalni model nije jednak Bernulijevom!**

Gausov naivni Bajesov klasifikator

- Mnoge odlike po prirodi imaju kontinualne numeričke vrednosti.
 - Npr. temperatura u nekom mestu, cena akcija na berzi, visina plate, starost, itd.
- Čest pristup: pretpostaviti normalnu/Gausovu raspodelu vrednosti za uslovne verovatnoće takvih odlika $P(x_t | y)$.
- Srednja vrednost odlike x_t u podacima klase y :
$$\mu_y = \frac{1}{m_y} \sum x_t \quad , \quad m_y - \text{broj podataka klase } y$$
- Standardna devijacija vrednosti odlike x_t u podacima klase y :
$$\sigma_y = \sqrt{\frac{1}{m_y} \sum (x_t - \mu_y)^2}$$
- Gausova/normalna raspodela vrednost uslovnih verovatnoća odlika $P(x_t | y)$:
$$P(x_t | y) = \frac{1}{\sqrt{2\pi}\sigma_y} e^{-\frac{(x_t - \mu_y)^2}{2\sigma_y^2}}$$
- Moguće je primenjivati različite raspodele vrednosti uslovnih verovatnoća za različite odlike.
 - Npr. Gausova raspodela za odlike sa kontinualnim numeričkim vrednostima i Bernulijeva raspodela za odlike sa binarnim/indikatorskim vrednostima.

Gausov naivni Bajesov klasifikator - primer upotrebe

	Podatak	Tempe- ratura	Vlažnost	Klasa
Skup za obučavanje	d1	32	84	Kiša
	d2	29	80	Suvo
	d3	26	92	Kiša
	d4	37	78	Suvo
Skup za testiranje	d5	33	82	?

$$P(Ki\dot{s}a) = \frac{1}{2}$$

$$P(Suvo) = \frac{1}{2}$$

Temperatura

$$\mu_{ki\dot{s}a} = \frac{32 + 26}{2} = 29$$

$$\mu_{suvo} = \frac{29 + 37}{2} = 33$$

$$\sigma_{ki\dot{s}a} = \sqrt{\frac{3^2 + 3^2}{2}} = 3$$

$$\sigma_{suvo} = \sqrt{\frac{4^2 + 4^2}{2}} = 4$$

Vlažnost

$$\mu_{ki\dot{s}a} = \frac{84 + 92}{2} = 88$$

$$\mu_{suvo} = \frac{80 + 78}{2} = 79$$

$$\sigma_{ki\dot{s}a} = \sqrt{\frac{4^2 + 4^2}{2}} = 4$$

$$\sigma_{suvo} = \sqrt{\frac{1^2 + 1^2}{2}} = 1$$

Gausov naivni Bajesov klasifikator - primer upotrebe (2)

	Podatak	Temperatura	Vlažnost	Klasa
Skup za obučavanje	d1	32	84	Kiša
	d2	29	80	Suvo
	d3	26	92	Kiša
	d4	37	78	Suvo
Skup za testiranje	d5	33	82	?

$$P(\text{Temperatura} = 33 | \text{Kiša}) = \frac{1}{3\sqrt{2\pi}} e^{-\frac{(33-29)^2}{2 \cdot 9}} \approx 0,0547$$

$$P(\text{Temperatura} = 33 | \text{Suvo}) = \frac{1}{4\sqrt{2\pi}} e^{-\frac{(33-33)^2}{2 \cdot 16}} \approx 0,0998$$

$$P(\text{Vlažnost} = 82 | \text{Kiša}) = \frac{1}{4\sqrt{2\pi}} e^{-\frac{(82-88)^2}{2 \cdot 16}} \approx 0,0324$$

$$P(\text{Vlažnost} = 82 | \text{Suvo}) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(82-79)^2}{2 \cdot 1}} \approx 0,0044$$

$$P(\text{Kiša} | d5) \propto P(\text{Kiša}) \times P(\text{Temperatura} = 33 | \text{Kiša}) \times P(\text{Vlažnost} = 82 | \text{Kiša}) \\ \approx 0,00089$$

$$P(\text{Suvo} | d5) \propto P(\text{Suvo}) \times P(\text{Temperatura} = 33 | \text{Suvo}) \times P(\text{Vlažnost} = 82 | \text{Suvo}) \\ \approx 0,00022$$

Generativni modeli

- Modeliraju zajedničku verovatnoću klase i podataka $P(y,x)$.
- Na taj način se modelira proces generisanja podataka određenog tipa.
- Naivni Bajesov klasifikator je generativni model - aposteriorna verovatnoća klase se dobija iz zajedničke verovatnoće preko Bajesove teoreme:

$$P(y|x) = \frac{P(y, x)}{P(x)}$$

- U generativne modele spadaju:
 - Skriveni Markovljevi lanci (engl. *Hidden Markov Models*, skr. *HMM*)
 - Bajesovske mreže (engl. *Bayesian networks*)
 - Latentna Dirihleova alokacija (engl. *Latent Dirichlet Allocation*, skr. *LDA*)

Prednosti naivnog Bajesovog klasifikatora

- **Jednostavnost.**
- **Brzina učenja i klasifikacije** - dovoljan jedan prolaz kroz podatke.
- Nije osetljiv na irelevantne odlike.
- Dobro se ponaša kada postoji veći broj podjednako važnih odlika.
- **Interpretabilnost** - veća težina pridružena određenoj odlici znači da je ona važnija pri odlučivanju.
- Direktno je **primenjiv na višeklasnu klasifikaciju.**
- **Model se lako može ažurirati novopristiglim podacima** (bez ponovnog treniranje od nule).
- **Robustan kod malih količina podataka** - zbog jakih pretpostavki (nezavisnost odlika), može da generalizuje i sa malo trening primera.
- **Manje sklon preteranoj prilagođenosti modela podacima** u poređenju sa složenim modelima, posebno kad se koristi regularizacija (npr. Laplasovo poravnanje).

Nedostaci naivnog Bajesovog klasifikatora

- Pretpostavka o nezavisnosti odlika - dolazi do duplog brojanja informacija i pogrešnih procena.
 - Kada su dve odlike korelisane dolazi do duplog brojanja - daje iskrivljene procene o važnosti odlika.
- Vrednosti aposteriornih verovatnoća koje model daje su često znatno iskrivljene.
 - Model često daje previše sigurne ili prenapumpane procene, iako mu tačnost klasifikacije može biti solidna.
- Problemi sa vrednostima koje nisu viđene u trening skupu - ako se u testu pojavi kombinacija atributa ili vrednost koju model nije video u obuci, verovatnoća može biti izračunata kao nula (*zero-frequency problem*). Ovo se obično rešava Laplasovim poravnanjem.
- Osetljivost na nerelevantne i redundantne odlike - nerelevantne osobine mogu negativno uticati na performanse, a redundantne dodatno pojačavaju problem zavisnosti između odlika.
- Linearnost odlučujućih granica u prostoru osobina – iako Bajes može raditi na složenim problemima, naivni Bajes najčešće implicitno gradi linearne granice, pa ima ograničene mogućnosti za razdvajanje kompleksnih skupova podataka.

Upotreba naivnog Bajesovog klasifikatora

- Često se koristi kao *baseline*, zbog svoje jednostavnosti i brzine.
- Postiže bolje performanse od složenijih modela kada je dostupno malo podataka za obučavanje.
- Zbog brzine je kompetitivan i kada je dostupno puno podataka.
- Raširen algoritam u klasifikaciji tekstualnih podataka:
 - Multinomijalna varijanta (sa binarizovanim odlikama) obično najbolja.
 - Primene - detekcija spam poruka, analiza sentimenta, klasifikacija teksta po temama, analiza autorstva, itd.
- Koriste se i u medicinskoj dijagnostici, analizi genomskih podataka, kod sistema za preporuku (npr. kategorizacija korisnika), kod sistema za prepoznavanje lica ili slika,...

Pitanja?

Hvala na pažnji.