

Modeli zasnovani na širokom pojasu (*large margin*)

Pronalaženje skrivenog znanja, *Elektrotehnički fakultet Univerziteta u Beogradu*
Prof. dr Dražen Drašković

Modeli zasnovani na širokom pojasu

- Ovaj termin potiče iz teorije učenja i odnosi se na modele koji **prave razdvajanje (granice odlučivanja) između klasa sa što većom marginom**.
 - **Margina** = rastojanje između granice odlučivanja i primera iz skupa podataka najbližih toj granici (tzv. *support vectors* kod SVM).
 - Ideja je da što je margina veća, model je otporniji na šum i greške u podacima i bolje generalizuje na nove podatke.
- Drugim rečima, *large margin* pristup teži **maksimizaciji sigurnosti klasifikacije** - nije dovoljno samo klasifikovati tačno, već i sa „što većom rezervom“.
- *Large margin* modeli $\neq$ linearni modeli. Oni mogu koristiti kernel trik (npr. kod SVM) da pronađu granicu odlučivanja u nelinearnom prostoru.
- Pojam *large margin* je više koncept/okvir učenja nego jedan algoritam - odnosi se na klasu metoda koje eksplicitno teže maksimizaciji margine.

Algoritmi koji spadaju u ovu grupu



- *Support Vector Machines* (SVM) - Metod potpornih vektora za klasifikaciju (koristi hard margin ili soft margin pristup)
- *Support Vector Regression* (SVR) - Metod potpornih vektora za regresiju
- Drugi algoritmi:
 - *Max-Margin Markov Models* (M^3) - kombinacija Markovljevih modela i ovog principa sa marginama.
 - *Structured SVM* - proširenje SVM za predviđanje strukturisanih izlaza.
 - *Perceptron* sa marginom – modifikacija klasičnog perceptrona gde se ažuriranje vrši samo ako je margina manja od zadate vrednosti.
 - *Boosting* metode u max-margin interpretaciji - npr. *AdaBoost* koji maksimizuje marginu nad podacima.

Metod potpornih vektora

Pronalaženje skrivenog znanja, *Univerzitet u Beogradu - Elektrotehnički fakultet*

Uvod u SVM

- **Metod potpornih vektora** (engl. *Support Vector Machines*, skr. *SVM*)
- **Binarni klasifikator**
 - Najčešće se jedna klasa označava sa $y=+1$, a druga sa $y=-1$.
- Osnovna verzija algoritma je **Linearni klasifikator**.
- Neprobabilistički klasifikator - izlaz modela je samo klasifikaciona odluka.
- Pošto direktno modeluje granicu između klasa, metoda potpornih vektora spada u diskriminativne modele.

Metoda potpornih vektora - istorijat

- 1963. - Vladimir Vapnik i Aleksej Červonenkis uvode osnovnu (linearno separabilnu) verziju SVM-a.
- 1979. - Vapnik i Červonenkis dodatno formalizuju VC teoriju i koncept margine (teorijski okvir za SVM).
- 1992. - Boser, Guyon i Vapnik objavljuju rad u kojem uvode kernel trick, što omogućava proširenje na nelinearne slučajeve.
- 1993-1995. - Corinna Cortes i Vapnik razvijaju i objavljuju **soft margin SVM**, koji rešava problem kada podaci nisu potpuno separabilni.

Izbor hiperravni razdvajanja

- Pri klasifikaciji podataka potrebno je pronaći hiperravan koja razdvaja podatke koji pripadaju različitim klasama.
- Ako su podaci linearno separabilni moguće je pronaći beskonačno mnogo hiperravni koje su u stanju da izvrše razdvajanje podataka iz skupa za obučavanje.
- Pitanje: po kom kriterijumu odabrati jednu od njih?
 - Logistička regresija - kriterijum je maksimalna entropija modela
 - Metoda potpornih vektora - kriterijum je maksimalna margina između klasa


Maksimalna margina razdvajanja i potporni vektori

- Ako su podaci linearno separabilni, onda je moguće zamisliti dve paralelne hiperravni takve da razdvajaju podatke različitih klasa i da se između njih ne nalazi ni jedan podatak.
- Oblast prostora između ovih zamišljenih hiperravni se naziva marginom.
- Cilj obučavanja modela u metodi potpornih vektora je da se pronađe maksimalna margina.
- Obe zamišljene hiperravni efektivno naležu na jedan ili više podataka svoje klase - ti podaci su potporni vektori (engl. *support vectors*).
 - Potporni vektori podupiru zamišljene hiperravni.
 - Naziv vektor potiče od posmatranja svakog podatka kao vektora/tačke u n-dimenzionalnom prostoru.
- Intuitivno gledano, hiperravan razdvajanja koja prolazi kroz sredinu praznine između podataka dveju klasa, ima više smisla od one koja se nalazi blizu podataka bilo jedne bilo druge klase.

Maksimalna margina razdvajanja i potporni vektori (2)

- Biranjem hiperravni razdvajanja koja se nalazi najdalje od uočenih podataka, efektivno se minimizuje greška generalizacije modela (tj. greška na novim podacima).
 - Pod pretpostavkom da će i novi podaci biti generisani iz iste raspodele kao i postojeći.
- Ovo se razlikuje od pristupa u logističkoj regresiji gde se minimizuje empirijska greška na već raspoloživim podacima za obučavanje (tj. maksimizuju performanse modela na njima).
- Pri traženju hiperravni razdvajanja sa maksimalnom marginom položaj podataka koji su udaljeniji od hiperravni razdvajanja nije bitan - oni ne utiču na marginu razdvajanja podataka.
- Hiperravan razdvajanja je određena malim brojem podataka obe klase koji su joj najbliži.
 - Oni su najvažniji za pravilnu klasifikaciju kako postojećih, tako i novih podataka.
- Ovo je drugačije od logističke regresije gde hiperravan razdvajanja zavisi od položaja svih podataka.

Prikaz veličine margine razdvajanja



Hipoteza metode potpornih vektora

- U metodi potpornih vektora model predstavlja jednačinu hiperravni razdvajanja.
- Ako je n broj odlika koje se koriste u modelu, tj. broj dimenzija prostora, onda je hipoteza oblika:
- $h(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n = W^T X + w_0$
- Često se umesto oznake w_0 koristi oznaka b (engl. *bias term*).
- Jednačina hiperravni razdvajanja je: $h(x) = W^T X + w_0 = 0$.
- Vektor W je vektor normale na hiperravan razdvajanja.

Skaliranje jednačine hiperravni razdvajanja

- Jednačina hiperravni razdvajanja se može pomnožiti/podeliti bilo kojim pozitivnim brojem bez promene položaja hiperravni.
- Iako je faktore W i w_0 moguće proizvoljno skalirati, konvencionalno se usvaja takva kanonska vrednost da za potporne vektore $X^{(sv)}$ važi: $y^{(sv)}(W^T X^{(sv)} + w_0) = 1$
- To znači da jednačina hiperravni koja naleže na potporne vektore iz klase $y = 1$ postaje:
 $W^T X + w_0 = 1$
- dok je jednačina hiperravni koja naleže na potporne vektore iz klase $y = -1$:
 $W^T X + w_0 = -1$

Širina margine razdvajanja

- Udaljenost neke tačke/podatka $X^{(a)}$ od hiperravni razdvajanja Π je:


$$\text{dist}(X^{(a)}, \Pi) = \frac{|W^T X^{(a)} + w_0|}{\|W\|_2}$$

- Zašto delimo sa $\|W\|_2$?
- Sledi da je udaljenost potpornih vektora $X^{(sv)}$ od hiperravni razdvajanja:

$$\text{dist}(X^{(sv)}, \Pi) = \frac{|W^T X^{(sv)} + w_0|}{\|W\|_2} = \frac{1}{\|W\|_2}$$

- Pošto se potporni vektori nalaze sa ove strane hiperravni razdvajanja, širina margine je dvostruko veća - nju treba maksimizovati:

$$\operatorname{argmax}_{W, w_0} \frac{2}{\|W\|_2}$$



Cilj obučavanja u metodi potpornih vektora

- Pošto marginu treba maksimizovati, sledi da treba minimizovati L2 (Euklidsku) normu $\|W\|_2$
- Ona predstavlja geometrijsku dužinu vektora od koordinatnog početka do tačke koju definišu njegove komponente.
- Pošto je $\|W\|_2 = \sqrt{w_1^2 + w_2^2 + \dots + w_n^2}$
- sa stanovišta optimizacije lakše je izbeći korenu funkciju i minimizovati $\frac{1}{2} \|W\|_2^2$
 - Ovu zamenu je moguće sprovesti jer minimizovanje kvadrata norme minimizuje i samu normu.
- Stoga je cilj obučavanja u metodi potpornih vektora pronaći $\operatorname{argmin}_{W, w_0} \frac{1}{2} \|W\|_2^2$
- Kod L1 norme sabiraju se apsolutne vrednosti, ali se u mašinskom učenju u kod SVM koristi L2 kao standard, jer direktno odgovara pojmu udaljenosti u fizičkom prostoru, i koristi se u optimizaciji (regularizaciji), jer „kažnjava“ velike težine strožije nego male.

Uslovi pri traženju maksimalne margine

- Prilikom pronalaženja maksimalne margine treba sprečiti da neki podatak bilo prve bilo druge klase upadne u marginu, što znači da treba da važi:

$$W^T X^{(+1)} + w_0 \geq 1 \quad \text{i} \quad W^T X^{(-1)} + w_0 \leq -1$$

- gde su $X^{(+1)}$ podaci klase $y=+1$, odnosno i $X^{(-1)}$ podaci klase $y=-1$.
- Navedeni uslovi se mogu uprostiti na: $y^{(i)}(W^T X^{(i)} + w_0) \geq 1$

Optimizacioni problem

- Optimizacioni problem ima sledeći oblik:

$$\operatorname{argmin}_{W, w_0} \frac{1}{2} \|W\|_2^2, \quad y^{(i)}(W^T X^{(i)} + w_0) \geq 1, \quad i = 1, 2, \dots, m$$

- gde je m broj podataka u skupu za obučavanje.
- Ovo je problem konveksne optimizacije sa ograničenjem, tj. kvadratnog programiranja.
- Do rešenje se može doći tehnikom Lagranžovih multiplikatora uz *Karush-Kuhn-Tucker* (KKT) uslove.
- Ovo rešenje podrazumeva kreiranje tzv. dualne reprezentacije problema u kojoj se za svaku nejednakost navedenog oblika kreira po jedan Lagranžov multilikator α_k .

Dualna formulacija hipoteze metode potpornih vektora

- U dualnoj reprezentaciji problema, koristimo Lagranžov multiplikator i dobija se da je:

$$W = \sum_{i=1}^m \alpha_i y^{(i)} X^{(i)}$$
$$h(x) = W^T X + w_0 = \sum_{i=1}^m \alpha_i y^{(i)} (X^{(i)})^T X + w_0$$

- Pokazuje se da su optimalne vrednosti α_i dodeljene svakoj tački jednake nuli, za sve tačke osim za potporne vektore.
 - Njih obično ima mnogo manje od ukupnog broja tačaka.
- Stoga vrednosti hipoteze (i jednačina hiperravni razdvajanja) zavise samo od potpornih vektora.

Dualna formulacija hipoteze metode potpornih vektora (2)

- Vrednost hipoteze $h(x^{(k)})$ za neki nov podatak $x^{(k)}$ zavisi od proizvoda

$$(X^{(i)})^T X^{(k)} = X^{(i)} \cdot X^{(k)}$$

- odnosno od sličnosti potpornih vektora $X^{(i)}$ sa vektorom novog podatka $X^{(k)}$.
- Klasifikovanje podataka predstavlja proveru sa koje strane hiperravni razdvajanja se on nalazi:

$$y = \text{sign}(h(x))$$

Meka margina

- Insistiranje na linearnoj separabilnosti klasa, čak i ako je ona moguća, može da dovede do preterane prilagođenosti modela podacima.
 - Pravi probleme u slučaju prisustva anomalija - pronađeno rešenje će imati malu marginu, tj. slabu generalizaciju na nove podatke.
- Umesto toga, bolje je (u ograničenoj meri) dozvoliti ulaske podataka u marginu, ili njihov prelazak na pogrešnu stranu hiperravni razdvajanja.
- Margina u kojoj je ovo dozvoljeno se naziva mekom marginom (engl. *soft margin*).

Korišćenje meke margine

- Korišćenje meke margine dovodi do reformulacije optimizacionog problema:


$$\operatorname{argmin}_{W, w_0} \frac{1}{2} \|W\|_2^2, \quad y^{(i)}(W^T X^{(i)} + w_0) \geq 1 - \xi_i, \quad \xi_i \geq 0$$
$$i = 1, 2, \dots, m$$

- gde su ξ_i prekoračenja u položaju svake tačke izvan granice njene klase (engl. *slack variables*).

Ukoliko je:

- $\xi_i = 0$, podatak je pravilno klasifikovan, ali unutar margine.
- $1 \geq \xi_i > 0$, podatak je pravilno klasifikovan, ali unutar margine.
- $\xi_i > 1$, podatak nije pravilno klasifikovan, nalazi se sa suprotne strane hiperravni razdvajanja u odnosu na njegovu klasu.

Meka margina u metodi potpornih vektora



Funkcija gubitka kod SVM sa mekom marginom

- Svaki podatak koji uđe u marginu ili pređe na pogrešnu stranu hiperravni razdvajanja treba penalizovati proporcionalno njegovoj udaljenosti od ivice margine na strani klase kojoj pripada.
- Funkcija gubitka može imati dva oblika:
 - L_1 oblik funkcije gubitka: $L(h(x), y) = \xi$
 - L_2 oblik funkcije gubitka: $L(h(x), y) = \xi^2$

Gubitak u obliku šarke

- Funkcija gubitka SVM sa mekom marginom se naziva i gubitkom u obliku šarke (engl. *hinge loss*).
- Uslov meke margine za jedan podatak se može preformulisati kao:

$$y(W^T X + w_0) \geq 1 - \xi$$

$$yh(x) \geq 1 - \xi$$

$$\xi \geq 1 - yh(x)$$

- Ako se uzme u obzir i uslova da je $\xi \geq 0$, sledi: $\xi = \max(0, 1 - yh(x))$
- Ako se usvoji da je $z = y(W^T X + w_0)$, onda je gubitak u obliku šarke: $\xi = \max(0, 1 - z)$

Reformulacija logističke funkcije gubitka za $y \in \{-1, 1\}$

- Logistička funkcija gubitka ima sledeći oblik za $y \in \{0, 1\}$:

$$L(h(x), y) = -\ln(P(y|x)) = \begin{cases} -\ln(P(y = 1|x)) = -\ln(h(x)), & y = 1 \\ -\ln(P(y = 0|x)) = -\ln(1 - h(x)), & y = 0 \end{cases}$$

- Ako se koriste oznake za $y \in \{-1, 1\}$ za klase, onda važi:

$$P(y = 1|x) = \frac{1}{1 + e^{-(W^T X + w_0)}}$$

$$P(y = -1|x) = \frac{1}{1 + e^{W^T X + w_0}}$$

$$P(y|x) = \frac{1}{1 + e^{-y(W^T X + w_0)}}$$

Reformulacija logističke funkcije gubitka za $y \in \{-1, 1\}$ (nast.)

- Sledi da je za $y \in \{-1, 1\}$:

$$-\ln(P(y|x)) = -\ln \frac{1}{1 + e^{-y(W^T X + w_0)}} = \ln(1 + e^{-y(W^T X + w_0)})$$

- Logistička funkcija gubitka za $y \in \{-1, 1\}$ se obično skalira sa $\frac{1}{\ln 2}$:


$$L(h(x), y) = \frac{1}{\ln 2} \ln(1 + e^{-y(W^T X + w_0)})$$

- Razlog za skaliranje - ako se usvoji da je $z = y(W^T X + w_0)$, onda logistička funkcija gubitka

$$L(z) = \frac{1}{\ln 2} \ln(1 + e^{-z})$$

- prolazi kroz tačku (0,1).

Poređenje oblika različitih funkcija gubitka



Legenda:

0-1 gubitak (crna),
gubitak u obliku šarke (plava),
logistička funkcija gubitka (crvena),
kvadratna funkcija gubitka (zelena)

Funkcija greške kod SVM sa mekom marginom

- U metodi potpornih vektora sa mekom marginom postoje dva različita (i ponekad suprotstavljena) cilja optimizacije
 - Maksimizacija margine
 - Minimizacija greške klasifikacije na pojedinačnim primerima tj. gubitka u obliku šarke

- Funkcija greške kod SVM sa mekom marginom ima oblik:

$$J(w) = C \sum_{i=1}^m L(h(x^{(i)}), y^{(i)}) + \frac{1}{2} \sum_{j=1}^n w_j^2$$

- gde je C hiperparametar modela koji određuje balans između dva cilja optimizacije.
- Cilj obučavanja je minimizacija funkcije greške $J(w)$.

Funkcija greške kod SVM sa mekom marginom (2)

- Ukoliko se koristi L_1 oblik funkcije gubitka, onda je funkcija greške:

$$J(w) = C \sum_{i=1}^m \xi_i + \frac{1}{2} \sum_{j=1}^n w_j^2 = C \sum_{i=1}^m \max(0, 1 - y^{(i)} h(x^{(i)})) + \frac{1}{2} \sum_{j=1}^n w_j^2$$

- Ukoliko se koristi L_2 oblik funkcije gubitka, onda je funkcija greške:

$$J(w) = C \sum_{i=1}^m \xi_i^2 + \frac{1}{2} \sum_{j=1}^n w_j^2 = C \sum_{i=1}^m \left(\max(0, 1 - y^{(i)} h(x^{(i)})) \right)^2 + \frac{1}{2} \sum_{j=1}^n w_j^2$$

- L_2 oblik funkcije gubitka:

- Rešenje je stabilnije (male promene u podacima za obučavanje manje utiču na rešenje).
- Manja otpornost na uticaj anomalija.

- L_1 oblik funkcije gubitka:

- Rešenje je manje stabilno (male promene u podacima za obučavanje više utiču na izgled rešenja).
- Veća otpornost na uticaj anomalija.

Regularizacija kod SVM sa mekom marginom


- Veća margina povećava generalizaciju modela - minimizovanje norme vektora W predstavlja regularizaciju modela.
- Moguće je koristiti L_1 ili L_2 regularizaciju:
 - U L_2 regularizaciji se minimizuje do sada korišćen izraz $\frac{1}{2} \|W\|_2^2$
 - U L_1 regularizaciji se minimizuje vrednost $\|W\|_1$
 - Sve ranije prikazane razlike između ova dva tipa regularizacije važe i kod metoda potpornih vektora.

Hiperparametar C


- Velika vrednost C - model se pri obučavanju fokusira na smanjivanje greške klasifikacije, po cenu manje margine razdvajanja, čime se smanjuje stepen regularizacije.
- Mala vrednost C - model se pri obučavanju fokusira na povećanje margine razdvajanja, čime se povećava stepen regularizacije, po cenu veće greške klasifikacije.
- Po svojoj funkciji hiperparametar C je inverzan hiperparametru λ koji određuje jačinu regularizacije u linearnoj i logističkoj regresiji:

$$C = \frac{1}{\lambda}$$

Ilustracija efekta vrednosti hiperparametra C na odabir optimalne hiperravni razdvajanja



Large value for
parameter C




Small value for
parameter C

Nelinearna klasifikacija

- Metod potpornih vektora se može lako proširiti tako da je u stanju da se nosi i sa klasama podataka koje nisu linearno separabilne.
- To se ostvaruje preslikavanjem problema u veći broj dimenzija:
 - Ako podaci nisu linearno separabilni u zadanom broju dimenzija, moguće ih je preslikati u prostor sa većim brojem dimenzija, u kome će biti moguće linearno ih razdvojiti.
 - Linearna granica razdvajanja u prostoru sa više dimenzija, nakon preslikavanja nazad u originalni broj dimenzija, može da bude ekvivalentna sa nelinearnom granicom proizvoljnog oblika.
 - Problem - transformacija svih podataka u prostor sa većim brojem dimenzija je računski izuzetno zahtevna operacija.

Linearna separacija podataka kroz projekciju u veći broj dimenzija



Kernel funkcije

- Hipoteza metode potpornih vektora je sledećeg oblika (u dualnom domenu) za neki podatak $x^{(k)}$:

$$h(x^{(k)}) = \sum_{i=1}^m \alpha_i y^{(i)} (X^{(i)})^T X^{(k)} + w_0 = \sum_{i=1}^m \alpha_i y^{(i)} X^{(i)} \cdot X^{(k)} + w_0$$

- Potrebna je vrednost skalarnih proizvoda vektora tj. mera njihove sličnosti.
- Postoje funkcije koje za zadate vektore $X, Z \in \mathbb{R}^n$ implicitno računaju njihov skalarni proizvod u nekom prostoru sa više dimenzija $\mathbb{R}^q$.
- To računanje se ostvaruje bez eksplicitnog transformiranja vektora X i Z u prostor $\mathbb{R}^q$.
- Takve funkcije se nazivaju **kernel funkcijama**: $K(X, Z) = \phi(X) \cdot \phi(Z)$
- Korišćenjem kernel f-ja skup podataka se implicitno prebacuje u višedimenzionalni prostor: $\mathbb{R}^n \rightarrow \mathbb{R}^q$ (gde je: $q > n$). Pri tome se ne troši nikakva dodatna računarska memorija, a cena računanja se svodi na računanje $K(X, Z)$ - kernelski trik (engl. *kernel trick*).

Kernel funkcije (2)

- Ovo omogućava da SVM efikasno nauči nelinearne granice razdvajanja zamenom skalarnih proizvoda vektora odabranom kernel funkcijom:

$$h(x^{(k)}) = \sum_{i=1}^m \alpha_i y^{(i)} \phi(X^{(i)}) \cdot \phi(X^{(k)}) + w_0 = \sum_{i=1}^m \alpha_i y^{(i)} K(X^{(i)}, X^{(k)}) + w_0$$

- Kernel funkcija $K(X^{(i)}, X^{(k)})$ se sada koristi kao mera sličnosti vektora.
- Ono što se eksplicitno bira je kernel funkcija K , a ne funkcija preslikavanja ϕ
 - Funkcija preslikavanja ϕ je implicitno definisana odabirom kernel funkcije K .
 - Eksplicitne reprezentacije podataka u višedimenzionalnom prostoru - $\phi(X)$ se ne konstruišu.
- Kernel funkcija mora da ispunjava uslove da bi mogla da se koristi kao mera sličnosti vektora:
 - $K(X, X) = 1$
 - $0 \leq K(X, Z) \leq 1$
 - $K(X, Z) = K(Z, X)$

Tipovi kernel funkcija

- Linearni kernel - $K(X,Z) = X \cdot Z$
- Polinomijalni kernel
- Kerneli sa radijalnom osnovom
- Kerneli za strukturirane podatke
 - String kerneli
 - Kerneli stabla
 - Grafovski kerneli

Polinomijalni kerneli

- Imaju oblik: $K(X, Z) = (c + \gamma X \cdot Z)^d$
 - Za $d=1$, $c=0$, $\gamma=1$, dobija se već prikazan model bez kernela, tj. linearni kernel.
 - Često se koristi i kvadratni kernel koji se dobija za $d=2$.
- Polinomijalni kerneli omogućavaju modeliranje kombinacija odlika, sve do stepena polinoma.
- Primer-funkcija preslikavanja ϕ polinomijalnog kernela za $n=2$, $d=2$, $c=0$ i $\gamma=1$:

$$\begin{aligned} K(X, Z) &= (X \cdot Z)^2 = ((x_1, x_2) \cdot (z_1, z_2))^2 = (x_1 z_1 + x_2 z_2)^2 = x_1^2 z_1^2 + 2x_1 z_1 x_2 z_2 + x_2^2 z_2^2 \\ &= (x_1^2, \sqrt{2}x_1 x_2, x_2^2) \cdot (z_1^2, \sqrt{2}z_1 z_2, z_2^2) = \phi(X) \cdot \phi(Z) \end{aligned}$$

- Sledi da je za navedene vrednosti parametara funkcija preslikavanja polinomijalnog kernela:

$$\phi(X) = (x_1^2, \sqrt{2}x_1 x_2, x_2^2)$$

Kerneli sa radijalnom osnovom

- Kerneli sa radijalnom osnovom (engl. *radial basis function kernels*, skr. *RBF*) imaju oblik:

$$K(X, Z) = \phi(\|X - Z\|_2)$$

- Najčešće korišćena varijanta kernel funkcije sa radijalnom osnovom je Gausova, u obliku:


$$K(X, Z) = e^{-\frac{\|X-Z\|_2^2}{2\sigma^2}} = e^{-\gamma\|X-Z\|_2^2}$$

- gde je $\gamma = \frac{1}{2\sigma^2}$ preciznost, a σ^2 širina Gausove krive (engl. *bandwidth*).
- Kernel funkcije sa radijalnom osnovom su ekvivalentne mapiranju u prostor sa beskonačno mnogo dimenzija.


Gausov RBF kernel

- Parametar γ kod Gausovog RBF kernela ima veliki uticaj na ponašanje modela.
- γ je inverzno širini Gausove krive
 - Jako mala vrednost γ znači da je Gausova kriva izuzetno široka i da svaki potporni vektor X donekle ima efekat na klasifikaciju svih podataka.
 - Izlaz hipoteze se menja vrlo polako sa promenom vrednosti ulaza - veliko sistematsko odstupanje (engl. bias) modela tj. nedovoljna prilagođenost modela podacima.
 - Jako velika vrednost γ znači da je Gausova kriva izuzetno uska i da svaki potporni vektor X ima efekat na klasifikaciju samo onih podataka koji se nalaze u njegovoj neposrednoj blizini.
 - Izlaz hipoteze se menja izuzetno brzo sa promenom vrednosti ulaza-velika varijansa modela tj. preterana prilagođenost modela podacima.


Izgled različitih vrednosti hiperparametra γ kod Gausovog RBF kernela




Izgled ponašanja različitih SVM kernela - raspodela podataka




Ilustracija ponašanja različitih SVM kernela - linearni kernel (SVM bez kernela) za $C=1$




Ilustracija ponašanja različitih SVM kernela - Gausov RBF kernel za $\gamma=0.01$ i $C=1$




Ilustracija ponašanja različitih SVM kernela - Gausov RBF kernel za $\gamma=1$ i $C=1$




Ilustracija ponašanja različitih SVM kernela - Gausov RBF kernel za $\gamma=10$ i $C=1$




Ilustracija ponašanja različitih SVM kernela - Gausov RBF kernel za $\gamma=100$ i $C=1$




Ilustracija ponašanja različitih SVM kernela - Gausov RBF kernel za $\gamma=0.01$ i $C=10$




Ilustracija ponašanja različitih SVM kernela - Gausov RBF kernel za $\gamma=0.01$ i $C=1000$



Ilustracija ponašanja različitih SVM kernela - Gausov RBF kernel za $\gamma=0.01$ i $C=100000$



Ilustracija povezanosti efekata hiperparametara γ i C kod Gausovog RBF kernela



Odabir kernela

- Odabiranje najpogodnijeg kernela zavisi od konkretnog zadatka i može da bude netrivialno.
- Bez obzira koji kernel je odabran, njegovi parametri su hiperparametri modela.
 - I izbor kernela može da se tretira kao hiperparametar.
- Vrednosti hiperparametara je neophodno optimizovati da bi se dobile dobre performanse klasifikacije.
 - To se čini putem (ugneždene) unakrsne validacije.
 - Vrednosti različitih hiperparametara mogu da interaguju, tako da je potrebno pretraživanje po mreži (engl. *grid search*).

SVM optimizacija u primalnom domenu

- Funkciju greške je moguće minimizovati i u primalnom domenu, bez korišćenja Lagranžovih multiplikatora i prelaska u dualni domen.
- Dualni pristup može biti spor kada je količina podataka u skupu za odlučivanje jako velika, pošto je tada obično i broj potpornih vektora veliki.
- Ograničenja u primalnom domenu - nepostojanje kernela.
 - Moguće je rešavanje samo za linearni SVM.
- Primenuju se naprednije tehnike numeričke optimizacije, kao što je subgradijentni spust.
 - Često se traži aproksimacija optimalnog rešenja, a ne tačno rešenje.
- Kada je broj odlika znatno veći od broja podataka u skupu za obučavanje, preporučivo je da se optimizacija radi u dualnom domenu.

Višeklasna klasifikacija

- Metod potpornih vektora se može primeniti i u slučaju prisustva većeg broja klasa, i to kombinovanjem rezultata većeg broja nezavisnih binarnih klasifikacija.
- Princip "jedan nasuprot svima" (OvA) / "jedan nasuprot ostalima" (OvR)
 - Podatak se svrstava u onu klasu čiji binarni klasifikator klasifikuje dati podatak u tu klasu, sa najvećom udaljenošću između njegove hiperravni razdvajanja i podatka (umesto najveće verovatnoće pripadanja određenoj klasi u slučaju logističke regresije).
- Princip "jedan nasuprot jednom" (OvO)
- Postoje i pristupi koji istovremeno modeluju prisustvo više klasa.
 - Crammer & Singer algoritam

Prednosti i nedostaci metode potpornih vektora

- Prednosti:

- Veoma dobre performanse na širokom spektru problema.
- Metoda sama odabira koji podaci su potporni vektori i koliko ih ima.
- Manja sklonost preobučavanja od mnogih drugih modela.
- Interakcije odlika se mogu implicitno modelovati preko kernela.

- Nedostaci:

- Svm može da bude приметно sporiji od drugih metoda, u zavisnosti od broja odlika i količine podataka u skupu za obučavanje.
 - Korišćenje kernela dodatno usporava rad algoritma.
- Izlaz nije probabilističnog tipa.
 - Moguća probabilistička procena preko udaljenosti od hiperravni razdvajanja.
- Varijanta sa čvrstom marginom je osetljiva na anomalije.

Pitanja?

Hvala na pažnji.